

כד באלול התשע"ו 27.09.2016

פרופ' הלל בר גרא

מודלים של רגרסיה ליניארית

364-1-1061

תאריך הבחינה:

המרצה:

שם הקורס:

מספר קורס:

מיועד לתלמידי הנדסת תעשייה וניהול

שנה: 2016 סמסטר: ב' מועד: ג'

שלוש שעות.

משך הבחינה:

מחשבון, 5 דפי נוסחאות (משני הצדדים), טבלאות סטטיסטיות.

חומר עזר:

הנחיות חשובות:

- יש לפתור את כל השאלות
- יש ללוות את דרך הפתרון בהסברים מילוליים קצרים
- ניתן להשתמש בכל הנוסחאות והתוצאות שפותחו או הוצגו בכיתה ואין צורך להוכיחן מחדש, אלא אם כן זה נדרש במפורש
- בכל מבחן השערות יש לנסח את ההשערות הנבדקות, לציין מהו סטטיסטי המבחן וכיצד הוא מתפלג, ולכתוב מהו אזור הדחייה (זאת כמובן בנוסף לתוצאת המבחן)
- יש לכתוב את כל התשובות במחברת ולא על גיליון המבחן

שאלה 1 (40 נק')

במשרד הבריאות האמריקאי רצו לבדוק את הקשר שבין קצב פעימות הלב (פעימות בדקה) לבין טמפ' הגוף (במעלות פרנהייט). נאספו 130 תצפיות, ולכל תצפית צוין בנוסף מין הנבדק. לאחר הרצת מודל רגרסיה ליניארית התקבל הפלט הבא:

```
Call:
lm(formula = tempdata$temp ~ tempdata$rate + tempdata$gender.fac,
    data = tempdata)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-1.86363 -0.45624  0.01841  0.47366  2.33424
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    96.52022    0.655530  147.240 < 2e-16 ***
tempdata$rate     0.025267    0.008762   2.884  0.00462 **
tempdata$gender.facF -0.269406    0.123277  -2.185  0.03070 *
```

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.7017 on 127 degrees of freedom
Multiple R-squared:  0.09825, Adjusted R-squared:  0.08405
F-statistic: 6.919 on 2 and 127 DF, p-value: 0.001406
```

בנוסף נתונות המטריצות הבאות:

$$X^t X = \begin{pmatrix} 130 & 9589 & 65 \\ & 713733 & 4820 \\ & & 65 \end{pmatrix}$$

$$(X^t X)^{-1} = \begin{pmatrix} 0.8547 & -0.01144 & -0.0064 \\ & 0.00015 & -0.00012 \\ & & 0.03086 \end{pmatrix}$$

א. (8 נק') בנו רווח סמך (ברמת סמך של 0.95) למקדם של המגדר במודל. האם על פי המודל קיים הבדל מובהק (ברמת סמך של 0.95) בטמפ' הגוף בין גברים לנשים בעלי אותו קצב לב?

$$\beta_2 \in \widehat{\beta}_2 \pm t_{n-p, 0.975} \sqrt{\widehat{V}(\widehat{\beta}_2)} = -0.2694 \pm 1.9788 * 0.123277$$

$$\beta_2 \in [-0.5133, -0.0254]$$

ע"פ הפלט ניתן לראות שהמקדם של משתנה הדמה של קבוצת הנשים הוא מובהק ולכן יש הבדל מובהק בין טמפ' גוף הנשים לטמפ' גוף הגברים.

ב. (8 נק') בנו רווח סמך להבדל בטמפ' הגוף בין בני זוג (גבר ואישה) בעלי קצב פעימות לב זהה (אפשר להניח אי תלות בין התצפיות, במובן המקובל).

נבנה וקטורי עזר:

$$C_M^t = (1 \ x \ 0), \quad C_F^t = (1 \ x \ 1), \quad C_d^t = (0 \ 0 \ -1)$$

נגדיר:

$$y_d = y_M - y_F, \quad \widehat{y}_d = \widehat{y}_M - \widehat{y}_F,$$

נבנה משתנה ציר:

$$\frac{y_d - \widehat{y}_d - E(y_d - \widehat{y}_d)}{\sqrt{V(y_d - \widehat{y}_d)}} \sim t_{n-p}$$

$$E(y_d - \widehat{y}_d) = 0$$

$$\begin{aligned} V(y_d - \widehat{y}_d) &= V(y_d) + V(\widehat{y}_d) - 2cov(y_d, \widehat{y}_d) = V(y_M - y_F) + V(\widehat{y}_M - \widehat{y}_F) \\ &= V(y_M) + V(y_F) - 2cov(y_M, y_F) + V\left((C_M^t - C_F^t)\underline{\hat{\beta}}\right) \\ &= 2\sigma^2 + \sigma^2(C_d^t(X^t X)^{-1}C_d) \end{aligned}$$

$$\begin{aligned} \widehat{V}(y_d - \widehat{y}_d) &= MSE(2 + (0 \ 0 \ -1) \begin{pmatrix} 0.8547 & -0.01144 & -0.0064 \\ -0.01144 & 0.00015 & -0.00012 \\ -0.0064 & -0.00012 & 0.03086 \end{pmatrix} \begin{pmatrix} 0 \\ 0 \\ -1 \end{pmatrix}) \\ &= 0.4923 * 2.03086 = 0.999 \end{aligned}$$

$$y_d \in \widehat{y}_d \pm t_{127, 0.975} \sqrt{\widehat{V}(y_d - \widehat{y}_d)} = -0.2694 \pm 1.9788 * 0.999$$

$$y_d \in [-2.248, 1.709]$$

ג. (8 נק') מה דומה ומה שונה ברווח הסמך שמצאתם בסעיפים א' ו ב'? מה הסיבה להבדלים?

מרכז רווחי הסמך זהה, אבל אורך רווחי הסמך שונים. הסיבה להבדל בתשובות היא שבסעיף ב' לקחנו דגימה עתידית בודדת של גבר ואישה, בעוד שבסעיף א', אמדנו את ההבדל בתוחלת הטמפ' המותנית בין גברים לנשים. לכן למרות שהפרש התוחלות שלילי באופן מובהק סטטיסטית, יש סיכוי די גבוה שעבור זוג ספציפי של גבר ואישה הפרש יהיה בכל זאת חיובי.

ד. (8 נק') אחד החוקרים החליט להציג את מטריצת התצפיות באופן הבא:

$$\begin{pmatrix} GenderM & GenderF & rate \\ 1 & 0 & x_1 \\ 0 & 1 & x_2 \\ \vdots & \vdots & \vdots \end{pmatrix}$$

מה יהיו ערכי האומדים לפרמטרים במודל זה? מה משמעותם?

האומדן למקדם של קצב פעימות הלב לא ישתנה, וכעת במקום קבוצת בסיס ותוספת, יש לנו שתי קבוצות ולכן ווקטור אומדי המקדמים ייראה כך:

$$\underline{\hat{\beta}} = \begin{pmatrix} 96.520220 \\ 96.250814 \\ 0.025267 \end{pmatrix}$$

ה. (8 נק') משרד הבריאות הישראלי רוצה להשתמש במודל האמריקאי, ולשם כך להעביר את המעלות מפרנהייט לצלסיוס לפי הנוסחא:

$$T_c = \frac{5(T_F - 32)}{9}$$

כיצד ישתנה מדד טיב ההתאמה של המודל בעקבות השינוי הנ"ל?

מדד טיב ההתאמה כמדד של פיזור לא ישתנה כלל בעקבות שינוי לינארי במשתנה המוסבר.

שאלה 2 (40 נק')

חובב מירוצי מכוניות אמריקאיים (נאסקאר) רצה לבדוק איך מסלול המירוצים משפיע על המהירות. הוא אסף נתונים על 21 מסלולי מרוץ, ובדק איך המהירות המקסימלית שהושגה במסלול מושפעת משיפוע הצד (banking) בסיבובים של המסלול (במעלות) ומהיקפו (במיילים). הוא בנה מודל של רגרסיה לינארית (מודל 1), ומודל של רגרסיה פולינומיאלית (מודל 2).

א. (8 נק') נתון הפלט הבא הרלוונטי למודל 1:


One-sample Kolmogorov-Smirnov test

```
data: residuals(fit1)/sqrt(var(residuals(fit1)))  
D = 0.14362, p-value = 0.7269  
alternative hypothesis: two-sided
```


איזו הנחה נבדקה על פי הפלט? מה משמעות ערך הסטטיסטי? מהי המסקנה הרלוונטית? נבדקה הנחת הנורמליות באמצעות מבחן קולמוגורב סמירנוב, אשר משכלל את המרחקים בין התפלגות הנתונים להתפלגות הרצויה (נורמלית במקרה הנ"ל). ערך הסטטיסטי הוא 0.14362, והיות וערכו נמוך והתוצאה מאד לא מובהקת, לא דוחים את השערת ה-0 אשר אומרת שהנתונים מגיעים מהתפלגות הנורמלית.

ב. (8 נק') החוקר התלבט האם עדיף מודל לינארי (להלן מודל 1) או מודל פולינומיאלי (להלן מודל 2). הסתמכו על תרשימי הפיזור הבאים והסבירו איזה מודל עדיף לדעתכם?

להלן התרשים הרלוונטי למודל 1:



להלן התרשים הרלוונטי למודל 2:



בתרשים של מודל 1 התוחלת המותנית של השאריות אינה אפס, בפרט חמשת השאריות הראשונות (משמאל) שליליות, וכך גם ארבעת השאריות האחרונות (מימין), לעומת זאת כל השאריות במרכז חיוביות. מכאן נובע שישנה מגמה פרבולית ברורה בתרשים השאריות, שנובעת מהעובדה שההתנהגות הפרבולית של המסבירים "מתלבשת" על השארית ולכן יש מקום לרגרסיה פולינומיאלית. לעומת זאת במודל 2 ישנם ערכי שאריות חיוביים ושליליים בכל אזור, והם מסודרים באופן סימטרי בערך ביחס לציר.

להלן פלט הרגרסיה הפולינומיאלית:

```
call:
lm(formula = nascar$topSpeed ~ nascar$Banking + nascar$Circumference
+
  nascar$sqrCircu)
```

Residuals:

Min	1Q	Median	3Q	Max
-10.1114	-2.3861	-0.1848	3.6069	8.4004

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11.8199	7.7317	1.529	B
nascar\$Banking	1.4639	0.1437	10.185	1.18e-08 ***
nascar\$Circumference	143.1668	9.3133	15.372	2.10e-11 ***
nascar\$sqrCircu	-32.5218	2.8254	-11.511	1.90e-09 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.279 on 17 degrees of freedom
Multiple R-squared: 0.9747, Adjusted R-squared: 0.9702
F-statistic: **A** on 3 and 17 DF, p-value: XXXXX

ג. (8 נק') השלימו את הערכים החסרים בפלט (B-A).

$$F_{st} = \frac{MSR}{MSE}$$

$$MSE = 5.279^2 = 27.8768$$

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} = 1 - \frac{MSE(n-p)}{SST} = 0.9747 \rightarrow SST = 18725.4 \rightarrow SSR = 18251.67$$

$$F_{st} = \frac{SSR/p}{MSE} = 218.3$$

$$P_{value} = 2 \Pr(|t_{st}| > t_{n-p}) = 2 \Pr(1.529 > t_{17}) \rightarrow 0.1 < P_{value} < 0.2$$

או אם לדייק - $P_{value} = 0.145$

ד. (8 נק') החוקר מצא דוח של nascar שטען שהמהירות המקסימאלית תלויה בעיקר בשיפוע הצד, ושהיקף המסלול פחות חשוב. על סמך הפלט שהוצג לעיל עבור מודל 2, מה דעתכם על טענה זו? האם הפלט הזה מספיק כדי לתת תשובה מלאה לשאלה?

למעט מובהקות המשתנים, אשר בדוגמא הנוכחית אין בהם מספיק על מנת להכריע, אין בפלט נתונים המעידים על חשיבות משתנה אחד על פני האחר. יש לבצע מבחן F חלקי על מנת לבדוק את המודל עם משתנה שיפוע הצד וללא, ובשביל כך יש צורך בנתונים מהמודל החלקי- ללא משתנה שיפוע הצד.

ה. (8 נק') להלן פלט עבור מודל נוסף (מודל 3). האם פלט זה עוזר לענות על השאלה בסעיף ד' אם כן, בצעו את החישוב המלא. אם לא, הסבירו מדוע.

Call:

```
lm(formula = nascar$topSpeed ~ nascar$Banking)
```

Residuals:

Min	1Q	Median	3Q	Max
-64.42	-16.99	11.63	21.07	30.65

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	143.1786	16.4066	8.727	4.5e-08 ***
nascar\$Banking	1.3845	0.7835	1.767	0.0933 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 29.08 on 19 degrees of freedom

Multiple R-squared: 0.1411, Adjusted R-squared: 0.09594

F-statistic: 3.122 on 1 and 19 DF, p-value: 0.09328

נבצע מבחן F חלקי:

$$\begin{cases} h_0: \beta_2 = \beta_3 = 0 \\ h_1: \text{else} \end{cases}$$

$$F_{st} = \frac{(SSE(RM) - SSE(FM)) / l}{MSE(FM)} = \frac{(16067.2816 - 473.753) / 2}{27.836176} = 280.09466 \sim F_{2,17}$$

$$F_{cr} = F_{2,17}^{0.95} = 3.592$$

הסטטיסטי גדול מהקריטי ולכן נדחה את השערת האפס ונגיד כי לפי הנתונים הקף המסלול משפיע על מהירות השיא הנמדדת בו.

מדדי המתאם במודל המלא גבוהים בהרבה. שונות השגיאות קטנה בהרבה. השגיאה הקסימלית בערך מוחלט קטנה בהרבה. המודל המלא מובהק יותר מאשר המודל החלקי.

שאלה 3 (20 נקודות)

א. $A_1 = \frac{1}{n} \begin{pmatrix} 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \dots & 1 \end{pmatrix}$: (10 נקודות) נתונות שתי מטריצות בגודל $n \times n$:

$$A_2 = I - A_1 = \frac{1}{n} \begin{pmatrix} n-1 & -1 & \dots & -1 \\ -1 & n-1 & \dots & -1 \\ \vdots & \vdots & \ddots & \vdots \\ -1 & -1 & \dots & n-1 \end{pmatrix} -$$

הראו כי לכל וקטור $\mathbf{u}$: $Q_1(\mathbf{u}) \equiv \mathbf{u}^t A_1 \mathbf{u} = n \cdot \bar{u}^2$ ו- $Q_2(\mathbf{u}) \equiv \mathbf{u}^t A_2 \mathbf{u} = \sum (u_i - \bar{u})^2$.

$$\begin{aligned} Q_1(\mathbf{u}) \equiv \mathbf{u}^t A_1 \mathbf{u} &= (u_1 \quad \dots \quad u_n) \frac{1}{n} \begin{pmatrix} 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & \dots & 1 \end{pmatrix} \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix} = \frac{1}{n} \left(\sum u_i \quad \dots \quad \sum u_i \right) \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix} \\ &= \bar{u} (1 \quad \dots \quad 1) \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix} = \bar{u} \sum u_i = n \cdot \bar{u}^2 \end{aligned}$$

$$\begin{aligned} Q_2(\mathbf{u}) \equiv \mathbf{u}^t A_2 \mathbf{u} &= (u_1 \quad \dots \quad u_n) \frac{1}{n} \begin{pmatrix} n-1 & -1 & \dots & -1 \\ -1 & n-1 & \dots & -1 \\ \vdots & \vdots & \ddots & \vdots \\ -1 & -1 & \dots & n-1 \end{pmatrix} \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix} = \\ &= \frac{1}{n} \left((n-1)u_1 - \sum_{i=2}^n u_i \quad -u_1 + (n-1)u_2 - \sum_{i=3}^n u_i \quad \dots \quad -\sum_{i=1}^{n-1} u_i + (n-1)u_n \right) \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix} = \\ &= \frac{1}{n} \left(nu_1 - \sum_{i=1}^n u_i \quad nu_2 - \sum_{i=1}^n u_i \quad \dots \quad nu_n - \sum_{i=1}^n u_i \right) \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix} = \\ &= (u_1 - \bar{u} \quad \dots \quad u_n - \bar{u}) \begin{pmatrix} u_1 \\ \vdots \\ u_n \end{pmatrix} = \sum_{i=1}^n (u_i - \bar{u}) u_i = \sum_{i=1}^n (u_i - \bar{u})^2 \end{aligned}$$

ב. (10 נק') מהן התוחלות של $Q_2(\epsilon)$, $Q_1(\epsilon)$, $Q_2(\mathbf{e})$, $Q_1(\mathbf{e})$ במודל רגרסיה ליניארית מרובה עם n תצפיות?

$$\begin{aligned} E[Q_1(\epsilon)] &= E[n\bar{\epsilon}^2] = n(V[\bar{\epsilon}] + E^2[\bar{\epsilon}]) = n\left(\frac{\sigma_\epsilon^2}{n} + 0\right) = \sigma_\epsilon^2 \\ E[Q_2(\epsilon)] &= E\left[\sum_{i=1}^n (\epsilon_i - \bar{\epsilon})^2\right] = E\left[\sum_{i=1}^n \epsilon_i^2 - n\bar{\epsilon}^2\right] = \sum_{i=1}^n E[\epsilon_i^2] - nE[\bar{\epsilon}^2] = nE[\epsilon^2] - nE[\bar{\epsilon}^2] \\ &= n(V[\epsilon] - V[\bar{\epsilon}]) = \sigma_\epsilon^2(n-1) \end{aligned}$$

סכום השאריות שווה תמיד אפס, לכן:

$$\begin{aligned} E[Q_1(\mathbf{e})] &= E[n\bar{e}^2] = 0 \\ E[Q_2(\mathbf{e})] &= E\left[\sum (e_i - \bar{e})^2\right] = E\left[\sum e_i^2 - n\bar{e}^2\right] = E[SSE] - E[n\bar{e}^2] = \sigma_\epsilon^2(n-p) \end{aligned}$$