



אוניברסיטת בן גוריון
המחלקה להנדסת תעשייה וניהול
קורס מודלים של רגרסיה לינארית
364-1-1061
מבחן מועד א' סמסטר א' – תשע"ז
2.2.2017

ד"ר ישראל פרמט

משך המבחן: שלוש שעות

חומר עזר מותר: 5 דפי נוסחאות, טבלאות סטטיסטיות ומחשבון

הנחיות חשובות:

- יש לפתור את כל השאלות
- יש ללוות את דרך הפיתרון בהסברים מילוליים קצרים
- ניתן להשתמש בכל הנוסחאות והתוצאות שפותחו או הוצגו בכיתה ואין צורך להוכיח מחדש אלא אם כן זה נדרש במפורש
- בכל מבחן השערות יש לנסח את ההשערות הנבדקות, לציין מהו סטטיסטי המבחן וכיצד הוא מתפלג, ולכתוב מהו איזור הדחייה (זאת כמובן בנוסף לתוצאת המבחן)

בהצלחה ☺

שאלה 1 (40 נקודות)

במפעל לייצור ממתקים שבדימונה מייצרים קרמבו עם מגוון מילויים. תהליך הייצור כולל הכנת הקרם, זילוף שלו על גבי העוגייה, טבילה בציפוי (שוקולד או וניל) ואריזה ידנית של כל קרמבו. מהנדס התהליך טוען כי עובי הציפוי של הקרמבו משפיע על משך האריזה שלו.

על מנת לנסות ולהבין את אופן ההשפעה של עובי הציפוי נלקח מדגם של 24 תצפיות עבור עובי הציפוי (מיקרון) ומשך האריזה (שניות). מהנתונים שנאספו התקבל ממוצע עובי ציפוי של 16.49 (מיקרון), ממוצע משך אריזה של 98.0256 (שניות) וכן $s_{xy}=3139.086$; $s_{xx}=686.5462$

בנוסף התקבל כי $SSE=1549$ עבור מודל הרגרסיה הפשוטה שהותאם.

בכל סעיפים הבאים הנח כי כל הנחות מודל הרגרסיה הפשוטה מתקיימות:

א. (8 נקודות) חשב את האר"פ במודל עם חותך.

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 22.67$$

$$\hat{\beta}_1 = \frac{s_{xy}}{s_{xx}} = 4.57$$

ב. (8 נקודות) האם עובי הציפוי אכן משפיע על משך האריזה? (בר"מ 5%).

$$H_0: \beta_1 = 0$$

$$H_1: \text{else}$$

$$MSE = \frac{SSE}{n-2} = \frac{1549}{22} = 70.4$$

$$\hat{v}(\beta_1) = \frac{MSE}{s_{xx}} = 0.1025$$

$$t_{st} = \frac{4.57}{0.32} = 14.28$$

$$t_{cr} = t_{22,0.975} = 2.074$$

נדחה את השערת האפס ונאמר כי עובי הציפוי משפיע על משך האריזה בר"מ של 5%.

ג. (8 נקודות) במפעל הכניסו נוהל "האריזה המהירה", עובדים שאורזים חבילות קרמבו (6 יחידות בחבילה) בפחות מעשר דקות מקבלים קרמבו בחינם. מה ניתן לומר על ההסתברות לקבל קרמבו מתנה, כאשר עובי הציפוי של כל קרמבו הוא 20 מיקרון? נבדוק מה הסיכוי לארוז 6 קרמבו בפחות מ-10 דקות, עבור $x=20$.

$$P\left(\sum y_{0,i} < 600\right) = P\left(\frac{\sum y_{0,i} - 6\hat{y}_{0,i} - E(e_0)}{\sqrt{v(e_0)}} < \frac{600 - 6\hat{y}_{0,i} - E(e_0)}{\sqrt{v(e_0)}}\right) =$$

$$P\left(t_{22} < \frac{600 - 684.42 - 0}{\sqrt{572.88}}\right) = P(t_{22} < -3.527) =$$

$$1 - P(t_{22} < 3.527) = 1 - 0.99997 \cong 0$$

נאמר כי בהסתברות קרובה מאוד לאפס הם יצליחו לארוז את כל חבילת הקרמבו בזמן המבוקש ולקבל קרמבו מתנה.

חישובי עזר, שגיאה של סכום 6 תצפיות עתידיות

$$e_0 = \sum e_i = \sum y_{0,i} - 6\hat{y}_{0,i}$$

$$E(\hat{y}_0) = 6(\hat{\beta}_0 + \hat{\beta}_1 x_0) = 6 \cdot (22.67 + 4.57 \cdot 20) = 684.42$$

$$E(e_0) = 0$$

$$\hat{v}(e_0) = \hat{v}\left(\sum y_{0,i} - 6\hat{y}_{0,i}\right) = \hat{v}\left(\sum y_{0,i}\right) + \hat{v}(6\hat{y}_{0,i}) - 2COV\left(\sum y_{0,i}, 6\hat{y}_{0,i}\right)$$

$$= 6\hat{v}(y_0) + \hat{v}\left(6(\hat{\beta}_0 + \hat{\beta}_1 x_0)\right) = 6\hat{v}(y_0) + \hat{v}(6\hat{\beta}_0 + 6\hat{\beta}_1 x_0)$$

$$= 6\hat{v}(y_0) + \hat{v}(6\hat{\beta}_0) + \hat{v}(6\hat{\beta}_1 x_0) + 2\widehat{COV}(6\hat{\beta}_0, 6\hat{\beta}_1 x_0)$$

$$= 6\hat{v}(y_0) + 36\hat{v}(\hat{\beta}_0) + 36x_0^2\hat{v}(\hat{\beta}_1) + 72x_0\widehat{COV}(\hat{\beta}_0, \hat{\beta}_1)$$

$$= 6 \cdot 70.4 + 36 \cdot 30.82 + 36 \cdot 20^2 \cdot 0.1025 + 72 \cdot 20 \cdot (-1.691) = 572.88$$

$$\hat{v}(\hat{\beta}_0) = MSE\left(\frac{1}{n} + \frac{\bar{x}^2}{sxx}\right) = 30.82$$

$$\widehat{COV}(\hat{\beta}_0, \hat{\beta}_1) = -\frac{MSE \cdot \bar{x}}{sxx} = -1.691$$

מהנדס תעשייה וניהול שהגיע זה עתה למפעל טוען שעובי הציפוי תלוי הן במשך הטבילה (מקסימום חצי דקה) (duration, משתנה רציף, נמדד בשניות) והן בטעם הציפוי (type, משתנה דמה המקבל את הערך 1 עבור שוקולד ו-0 עבור וניל) והחליט להמיר את המשתנה המסביר מהמודל הקודם (עובי הציפוי) במשתנים הללו ובאינטראקציה שלהם, המשתנה המוסבר **נשאר** כפי שהיה במודל הפשוט.

לאחר הרצת מודל רגרסיה התקבל הפלט הבא:

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.800e+01			
duration	5.000e+00			
type	-2.398e-08			
type:duration	1.214e-09			

SSE= 2.854657e-14

ד. (8 נקודות) הסבר את משמעות כל אחד מהאר"פים במודל בהתאם לפלט הנ"ל. ציין את סווח הערכים שכל אחד מהמשתנים המסבירים במודל יכול לקבל.

Intercept – זמן האריזה כאשר משך הטבילה הוא אפס והציפוי הוא 0 וניל (אין משמעות אמיתית למצב כזה, שכן משך הטבילה חייב להיות גדול מאפס)
 Duration – כיצד הוספה של יחידה אחת במשך הטבילה משפיעה על זמן האריזה
 Type – כיצד מעבר מציפוי וניל (מצב בסיס) לציפוי שוקולד משפיע על זמן האריזה
 Type:duration – כיצד הוספה של יחידה אחת במשך הטבילה עבור ציפוי שוקולד משפיעה על זמן האריזה
 המשתנים המסבירים:
 Duration – משך הטבילה, נתון: משתנה רציף, נמדד בשניות. מקסימום חצי דקה. לכן הערכים הם 0-30.
 Type – סוג הציפוי, נתון: משתנה דמה המקבל את הערך 1 עבור שוקולד ו-0 עבור וניל. לכן הערכים הם 0 או 1.
 Type:duration – משתנה אינטראקציה. מכפלה של שני המשתנים המסבירים לעיל. לכן הערכים האפשריים הם 0-30.
 ה. (8 נקודות) איזה משני המודלים עדיף? השווה על ידי שני מדדים שונים.

ניתן להשוות על ידי AIC, BIC או R^2_{adj}


	Model I	Model II
$AIC = n \cdot \ln\left(\frac{SSE}{n}\right) + 2p$	104.015	-816.77
$BIC = n \cdot \ln\left(\frac{SSE}{n}\right) + \ln(n) \cdot p$	106.372	-812.055
$R^2_{adj} = 1 - \frac{\frac{SSE}{n-p}}{\frac{SST}{n-1}}$	0.898	1

שאלה 2 (40 נקודות)

במחקר שנערך בארצות הברית נאספו נתונים על הפשיעה ב-42 ערים. קובץ הנתונים כלל את המשתנים הבאים:

Moral – Moral Integration: Composite of crime rate and welfare expenditures.
Hetero – Ethnic Heterogeneity: From percentages of nonwhite and foreign-born white residents.
Mobility – Geographic Mobility: From percentages of residents moving into and out of the city.
Region – A factor with levels: E-Northeast; MW-Midwest; S-Southeast; W-West

א. (8 נקודות) מה ניתן ללמוד מהשרטוט הבא:



יש הבדל ב-moral בין האזורים השונים. נראה שיש הבדל מובהק בין east לבין south.

ב. (8 נקודות) בכדי לבדוק את הקשר בין ה-moral לבין שאר המשתנים החוקרים רצו להתאים את המודל הבא: $\text{lm}(\text{moral} \sim (\text{hetero} + \text{mobility}) * \text{region})$ בעזרת שני הפלטים הבאים ענו מה יהיה המשתנה הראשון שייכנס בבניית המודל בשיטת צעדים לפנים ומה יהיה המשתנה הראשון שיושמט מהמודל בשיטת צעדים לאחור.

פלט 1

```
step(lm(formula = moral ~ 1, data = Angell), direction="forward",
      scope = list( upper=~(hetero+mobility)* region, lower = ~1), test="F")
```

```
Start: AIC=110.47
moral ~ 1
```

	Df	Sum of Sq	RSS	AIC	F value	Pr(>F)	
+ region	3	343.36	192.46	72.444	23.192	8.787e-09	***
+ hetero	1	184.75	351.07	94.291	21.576	3.486e-05	***
+ mobility	1	129.14	406.68	100.613	13.020	0.00083	***
<none>			535.82	110.472			

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

פלט 2

```
res<-lm(formula = moral ~ (hetero+mobility)* region, data = Angell)
Anova(res)
```

Anova Table (Type II tests)

Response: moral

	Sum Sq	Df	F value	Pr(>F)
hetero	29.988	1	6.2528	0.01790 *
mobility	7.372	1	1.5371	0.22435

```

region          33.774   3   2.3474 0.09185 .
hetero:region    9.584   3   0.6661 0.57922
mobility:region  5.465   3   0.3798 0.76822
Residuals      148.675 31
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

בשיטת צעדים לפנים נכניס תחילה את המשתנה הקטגורי **region** (הכי מובהק)
בשיטת צעדים לאחור נשמיט תחילה את המשתנה אינטראקציה **mobility:region** (הכי פחות מובהק)

ג. (8 נקודות) החוקרים התאימו את מודל הרגרסיה המרובה הבא:
`lm(moral ~ (hetero + mobility)*region)`
ולאחר הפעלת שיטה צעדים לאחור קיבלו את המודל הסופי הבא:

```
lm(formula = moral ~ hetero + region)
```

Coefficients:


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	16.51066	0.90493	18.245	< 2e-16
hetero	-0.04870	0.02378	-2.048	0.04753
regionMW	-3.17626	0.91351	-3.477	0.00129
regionS	-6.21870	1.14378	-5.437	3.37e-06
regionW	-5.18795	1.13767	-4.560	5.19e-05

Residual standard error: 2.136 on 38 degrees of freedom
Multiple R-squared: 0.6765, Adjusted R-squared: 0.6425
F-statistic: 19.87 on 4 and 38 DF, p-value: 6.746e-09

מה ניתן ללמוד מפלט זה על השפעת הגורמים השונים על ה-**moral**? על טיב התאמת המודל?
מתוך הפלט ניתן ללמוד שהמשתנים המשפיעים (באופן מובהק) על **moral** הם **hetero** ו-
region. כאשר יש משמעות לרמות השונות של **region** (לעומת מצב הבסיס – **east**). המשתנים
המוצגים משפיעים באופן שלילי על **moral** כך שהוספה של כל יחידה מביאה לירידה ב **moral**.
טיב המודל אינו גבוה מאוד ועומד "רק" על 0.6765.

ד. (8 נקודות) הסבירו במילים מהי בעיית התאמת היתר (**over fitting**) הבאה לידי ביטוי
במדד R^2 . ציינו לפחות דרך אחת כיצד אנו מתמודדים עם הבעיה בבואנו לחשב את המדד.
בעיית התאמת יתר זה מצב בו המודל מתאר באופן מושלם (או כמעט מושלם) את הנתונים
הקיימים, אך ברגע שישתנו מעט הנתונים המודל כבר לא ייצג נאמנה את הנדרש ולא יהיה ניתן
להסיק מסקנות באופן מספק. מחשבים את המדד על סמך חלק מהנתונים ומשתמשים בשאר
הנתונים על מנת לבדוק את נכונות המודל.

ה. (8 נקודות) מה ניתן ללמוד מהשרטוט הבא:



1 נמצא בר"ס ולכן נאמר שהחזקה היא 1 ולא צריך לבצע טרנספורמציה (טרנספורמצית בוקס-קוקס).

שאלה 3 (20 נקודות)

מרצה הקורס ברגרסיה התעניין בשאלה האם ניתן לנבא את הציון הממוצע של המבחן (של כל תלמידי הקורס) בעזרת הציון הממוצע של הבוחן אמצע. לשם כך הוא לקח את התוצאות ב-15 שנים (30 תצפיות) וריכז אותן בקובץ שהכיל 3 עמודות:

Final: ציון הממוצע של המבחן הסופי

Midterm: הציון הממוצע של בוחן האמצע

Size: מספר התלמידים באותו בסמסטר

ענה על הסעיפים הבאים תחת ההנחות הבאות:

1. אין תלות בין התלמידים השונים בתוך מועד
2. אין תלות בין התלמידים במועדים שונים
3. אין תלות בין המועדים
4. לכל תלמיד יש ציון בוחן וציון סופי

א. (10 נקודות) מה הקשר בין הפרמטרים במודל הפרטני $y_{ij} = \delta_0 + \delta_1 x_{ij} + \eta_{ij}$ (כולל שונות הטעויות) לבין הפרמטרים במודל הכיתתי (מצרפי) $\bar{y}_j = \beta_0 + \beta_1 \bar{x}_j + \varepsilon_j$ (כולל שונות הטעויות). כאשר x_{ij} ו- y_{ij} הם ציון הבוחן והציון הממוצע של התלמיד ה- i במועד ה- j בהתאמה ו- $\bar{x}_j$ ו- $\bar{y}_j$ הם ציון הבוחן הממוצע וציון המבחן הסופי הממוצע של במועד ה- j בהתאמה וכמו כן במועד ה- j היו m_j תלמידים.

$$y_{ij} = \delta_0 + \delta_1 x_{ij} + \eta_{ij} \rightarrow \bar{y}_j = \frac{1}{m_j} \sum_{i=1}^{m_j} (\delta_0 + \delta_1 x_{ij} + \eta_{ij}) = \delta_0 + \delta_1 \bar{x}_j + \bar{\eta}_j \rightarrow \delta_0 = \beta_0,$$

$$\delta_1 = \beta_1, V(\bar{y}_j) = \frac{V(y_{ij})}{m_j} \rightarrow \frac{\eta_{ij}}{m_j} = \varepsilon_j$$

ב. (10 נקודות) הצדיקו את השימוש באומדי הריבועים הפחותים המשוקללים רשמו אותם

מפורשות במונחי $\bar{y}_j$ ו- m_j

על מנת לקבל שוויון שונויות במודל הכיתתי צריך להכפיל את המודל ב- $\sqrt{m_j}$.

$$\sqrt{m_j} \bar{y}_j = \sqrt{m_j} \beta_0 + \sqrt{m_j} \beta_1 \bar{x}_j + \sqrt{m_j} \varepsilon_j$$

ולכן פונק' המטרה תראה כך-

$$\min_{\beta_0, \beta_1} \sum (\sqrt{m_j} \bar{y}_j - \sqrt{m_j} \hat{\beta}_0 + \sqrt{m_j} \hat{\beta}_1 \bar{x}_j)^2 = \min_{\beta_0, \beta_1} \sum m_j (\bar{y}_j - \hat{\beta}_0 - \hat{\beta}_1 \bar{x}_j)^2$$

$$\begin{aligned} \frac{\partial SSE}{\partial \hat{\beta}_0} &= -2 \sum m_j (\bar{y}_j - \hat{\beta}_0 - \hat{\beta}_1 \bar{x}_j) = 0 \rightarrow \hat{\beta}_0 \sum m_j = \sum m_j \bar{y}_j - \hat{\beta}_1 \sum m_j \bar{x}_j \rightarrow \hat{\beta}_0 \\ &= \bar{y} - \hat{\beta}_1 \bar{x} \end{aligned}$$

$$\begin{aligned} \frac{\partial SSE}{\partial \hat{\beta}_1} &= -2 \sum m_j (\bar{y}_j - \hat{\beta}_0 - \hat{\beta}_1 \bar{x}_j) \bar{x}_j = 0 \rightarrow \hat{\beta}_1 \sum m_j \bar{x}_j^2 = \sum m_j \bar{y}_j \bar{x}_j - \hat{\beta}_0 \sum \bar{x}_j m_j \\ &= \sum m_j \bar{y}_j \bar{x}_j - (\bar{y} - \hat{\beta}_1 \bar{x}) \sum \bar{x}_j m_j \\ &= \sum m_j \bar{y}_j \bar{x}_j - \bar{y} \sum \bar{x}_j m_j + \hat{\beta}_1 \bar{x} \sum \bar{x}_j m_j \rightarrow \hat{\beta}_1 \sum m_j \bar{x}_j^2 - \hat{\beta}_1 \bar{x} \sum \bar{x}_j m_j \\ &= \sum m_j \bar{y}_j \bar{x}_j - \bar{y} \sum \bar{x}_j m_j \rightarrow \hat{\beta}_1 = \frac{\sum m_j \bar{y}_j \bar{x}_j - \bar{y} \sum m_j \bar{x}_j}{\sum m_j \bar{x}_j^2 - \bar{x} \sum m_j \bar{x}_j} = \frac{\sum m_j (\bar{y}_j - \bar{y}) \bar{x}_j}{\sum m_j (\bar{x}_j - \bar{x}) \bar{x}_j} \end{aligned}$$