



אוניברסיטת בן גוריון
המחלקה להנדסת תעשייה וניהול
קורס מודלים של רגרסיה לינארית
364-1-1061
מבחן מועד ב' סמסטר א' – תשע"ז
26.2.2017

פרופ. ישראל פרמט

משך המבחן: שלוש שעות
חומר עזר מותר: 5 דפי נוסחאות, טבלאות סטטיסטיות ומחשבו
הנחיות חשובות:
- יש לפתור את כל השאלות
- יש ללוות את דרך הפיתרון בהסברים מילוליים קצרים
- ניתן להשתמש בכל הנוסחאות והתוצאות שפותחו או הוצגו בכיתה ואין צורך להוכיח מחדש אלא אם כן
זה נדרש במפורש
- בכל מבחן השערות יש לנסח את ההשערות הנבדקות, לציין מהו סטטיסטי המבחן וכיצד הוא מתפלג,
ולכתוב מהו איזור הדחייה (זאת כמובן בנוסף לתוצאת המבחן)

בהצלחה ☺

שאלה 1 (40 נקודות)

חוקר רצה לבדוק את הקשר בין לחץ הדם, p (נמדד ב-mmHg, מ"מ כספית), לבין גיל, age (נמדד בשנים). לשם כך דגם 7 חולים מבית החולים וקיבל את הנתונים הבאים:

נבדק	1	2	3	4	5	6	7
age	42	74	48	35	56	26	60
p	98	130	120	88	182	80	135

א. (7 נקודות) התאימו את קו הריבועים הפחותים של לחץ הדם על הגיל.

$$\begin{aligned}\sum x_i &= 341 \rightarrow \bar{x} = 48.714; \sum x_i^2 = 18181; \sum y_i = 833 \rightarrow \bar{y} \\ &= 119; \sum y_i^2 = 106397; \sum x_i y_i = 42948 \\ \hat{\beta}_1 &= \frac{s_{xy}}{s_{xx}} = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2} = \frac{2369.238}{1569.623} = 1.5; \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 45.929\end{aligned}$$

ב. (8 נקודות) רשמו את טבלת ניתוח השונות של המודל שהתקבל וחשבו את R^2 .

	SS	df	MS	F_{st}
Regression	$\hat{\beta}_1^2 S_{xx} = 3531.651$	$k = 1$	3531.651	$\frac{MSR}{MSE} = 4.723$
Error	$SST - SSR = 3738.349$	$n - p = 5$	747.67	
Total	$\sum y_i^2 - n\bar{y}^2 = 7270$	$n - 1 = 6$		

$$R^2 = \frac{SSR}{SST} = 0.485$$

ג. (6 נקודות) בדקו את ההשערה שהגיל לא משפיע על לחץ הדם. רשמו את ההשערות ברישום השערות סטטיסטי ובדקו את ההשערה בר"מ של 5%.

$$\begin{cases} h_0: \beta_1 = 0 \\ h_1: \text{else} \end{cases}$$

$$F_{st} = 4.723 \sim F_{1,5}$$

$$F_{cr} = F_{1,5}^{0.95} = 6.6079$$

לכן נאמר שאין בידינו מספיק נתונים על מנת לדחות את השערת ה-0 ולהגיד שהגיל משפיע על לחץ הדם.

ד. (5 נקודות) למרפאה נכנס חולה בן **13** ורופא בעזרת המודל העריך שלחץ הדם שלו הינו 65.09. מה יש לכם לומר על "אמינות" הערכה זו.

לחזות על סמך 7 תצפיות עבור תצפית שנמצאת רחוק מחוץ לטווח המדגם אינה אמינה כלל היות וזוהי אקסטרפולציה של הנתונים.

ה. א. (4 נקודות) מה יקרה לאומד לחותך ולשיפוע אם במקום להשתמש בשנים יחשבו גיל בחודשים?


השינוי הוא ביחידות של המסביר. השיפוע יקטן פי 12 (עכשיו צריך 12 יח' זמן בשביל להגיע לשינוי שקודם הושג ביחידת זמן אחת). החותך יישאר ללא שינוי (גיל 0 הוא גיל 0 גם בחודשים וגם בשנים).

א. (4 נקודות) מה יקרה לאומד לחותך ולשיפוע אם במקום להשתמש במ"מ כספית כיחידות לחץ ייעשה שימוש באטמוספרות (760 מ"מ כספית שווה לאטמוספירה אחת)?

השינוי הוא ביחידות של המוסבר. השיפוע יקטן פי 760 (עכשיו עבור כל יחידת זמן יש יחידה אחת של המוסבר לעבור עבור שינוי של 760 יחידות קודם). עבור החותך-

$$\widehat{\beta}_{0_{new}} = \bar{Y}_{new} - \widehat{\beta}_{1_{new}} \bar{x}_{new} = \frac{\bar{Y}}{760} - \frac{1}{760} \widehat{\beta}_1 \bar{x} = \frac{1}{760} \widehat{\beta}_{0_{old}}$$

א. (6 נקודות) מה ניתן ללמוד מהשרטוט הבא? למה הוא נעשה? מה ניתן ללמוד בעזרתו? מה תמליצו לחוקר?



תרשים Box Cox אשר מציג את הנראות של פרמטר פונקציית החזקה הרצויה על מנת לבצע טרנספורמציה על המשתנה המוסבר על מנת לפתור בעיית אי שוויון שונויות והנורמליות. רווח הסמך של הפרמטר גדול מאד במובהקות של 5%, והערך 0 נמצא בתוך רווח הסמך ולכן נמליץ להשתמש בו ונבצע התמרת חז. הסיבה לבחירת ה-0 היא פשטות ההבנה של המודל אשר יתקבל בעקבות התמרה זו.

שאלה 2 (40 נקודות)

קובץ הנתונים הינו מערך נתונים כלכליים ישנים על 50 ארצות שונות, הנתונים הם ממוצע על פני השנים 1960-1970 לכל מדינה בכל משתנה. הקובץ מכיל את המשתנים הבאים:

sr – savings rate - personal saving divided by disposable income

(חיסכון אישי מחולק בהכנסה פנויה)

pop15 – percent population under age of 15

pop75 – percent population over age of 75

dpi – per-capita disposable income in dollars (הכנסה פנויה לנפש בדולרים)

ddpi – percent growth rate of *dpi*

א. (10 נקודות) בתחילה התאימו החוקרים מודל פשוט שבו הוסבר שיעור החיסרון (*sr*) על ידי

שיעור האוכלוסייה מעל גיל 15 (*pop15*) בלבד והתקבלו התוצאות הבאות (תרשימים בעמוד

הבא):

```
lm(formula = sr ~ pop15)
```


Coefficients:


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	17.49660	2.27972	7.675	6.85e-10
<i>pop15</i>	-0.22302	0.06291	-3.545	0.000887

Residual standard error: 4.03 on 48 degrees of freedom

Multiple R-squared: 0.2075, Adjusted R-squared: 0.191

F-statistic: 12.57 on 1 and 48 DF, p-value: 0.0008866





מה אתם למדים על הקשר בין שני המשתנים? טיב התאמת המודל? הנחות המודל?

נראה שהמודל מחולק לשתי קבוצות של תצפיות. טיב התאמת המודל נמוכה מאד, גם עבור האומדן המתוקנן. נראה שיש שוויון שונות גם בין שתי הקבוצות. הקשר בין הנתונים נראה לינארי אך עקב ה"חור" במדגם קשה להסיק. תרשים ה-QQ מרמז על התפלגות שאינה נורמלית אך רמת המובהקות של מבחן KS מעידה על נתונים נורמליים.

ב. (5 נקודות) החוקרים חשבו שיתכן כי ישנם שני מודלים של רגרסיה, עבור $pop15$ נמוך מ-35% או גבוה מערך זה. לשם כך הציע החוקר הראשון להגדיר את המשתנה הבא:

$$I_{35} = \begin{cases} 0 & pop15 \geq 35 \\ 1 & pop15 < 35 \end{cases}$$

ולהתאים את המודל הבא: $E(sr|pop15) = \beta_0 + \beta_1 pop15 + \beta_2 I_{35} + \beta_3 pop15 * I_{35}$. כלומר המודל כולל את $pop15$, I_{35} ואת האינטראקציה ביניהם. החוקר השני טען שישנה "בעיה" בהצעה של הראשון והציע להגדיר את שני המשתנים הבאים:

$$lhs = \begin{cases} 0 & pop15 \geq 35 \\ pop15 - 35 & pop15 < 35 \end{cases}$$

$$rhs = \begin{cases} pop15 - 35 & pop15 \geq 35 \\ 0 & pop15 < 35 \end{cases}$$

ולהתאים את המודל הבא: $E(sr|pop15) = \delta_0 + \delta_1 lhs + \delta_2 rhs$

מה המשמעות של המודל הראשון (מה משמעות המקדמים)? מה המשמעות של המודל השני (מה משמעות המקדמים)? מה הבעיה שהמודל השני בא לפתור?

במודל הראשון ישנה בעיה של אי רציפות בנקודה שבה $pop15=35$. המודל השני פותר זאת, כאשר החותך שלו מציין את תוחלת החסכונות עבור מדינות בהן אחוז בני 15 ומטה שווה ל-35, וכל אחד משני המקדמים האחרים מציינים את השינוי בחסכונות עבור שינוי באחוז בני 15 ומטה.

ג. (8 נקודות) החוקרים התאימו בנוסף למודל ב-א' גם את שני המודלים ב-ב' וקיבלו את הטבלה הבאה:

Model 1: $sr \sim pop15 + I35 + pop15:I35$
 Model 2: $sr \sim lhs + rhs$
 Model 3: $sr \sim pop15$

	Res.Df	SSE
Model 1	46	731.57
Model 2	47	771.91
Model 3	48	779.51

באיזה משלושת המודלים הייתם ממליצים לחוקרים להשתמש ומדוע?

יש לחשב כל מדד שהוא לא SSE היות ולא ניתן להשוות בין מודלים בעלי מספר פרמטרים שונה באמצעות SSE. לפי AIC BIC המודל השלישי ייבחר. לפי MSE ו- R_{adj}^2 ייבחר המודל הראשון.

ד. (5 נקודות) החוקרים רצו להתאים את המודל המלא הכולל את $pop115$, $pop75$, $pop15$ ו- $ddpi$ והם התלבטו לגבי המשתנה dpi בטענה שהוא "כבר נלקח בחשבון". מה הייתה כוונתם?

המשתנה מגולם בחישוב המשתנה המוסבר.

ה. (4 נקודות) בכדי לבחור את המודל הטוב ביותר החליטו החוקרים להשתמש בהתאמת כל המודלים האפשריים ומהם לבחור את הטוב ביותר וקבלו את הטבלה הבאה:

Model	P	R ²	SSE	R ² _{adj.}	Cp	BIC	MSE ^{0.5}
<i>pop15</i>	2	0.2075	780	0.191	7.91	-3.805	4.03
<i>pop75</i>	2	0.1002	885	0.0814	15.21	2.546	4.29
<i>Ddpi</i>	2	0.0929	892	0.074	15.7	2.949	4.31
<i>Dpi</i>	2	0.0486	936	0.0287	18.72	5.335	4.42
<i>pop15-ddpi</i>	3	0.2878	701	0.2575	4.45	-5.233	3.86
<i>pop15-pop75</i>	3	0.2617	726	0.2303	6.22	-3.437	3.93
<i>pop15-dpi</i>	3	0.2435	744	0.2113	7.46	-2.216	3.98
<i>pop75-ddpi</i>	3	0.1883	798	0.1538	11.21	1.304	4.12

<i>ddpi-ddpi</i>	3	0.1616	825	0.1259	13.03	2.926	4.19
<i>pop75-dpi</i>	3	0.1024	883	0.0642	17.06	6.337	4.33
<i>pop15-pop75-ddpi</i>	4	0.3365	653	0.2933	3.13	-4.866	3.77
<i>pop15-dpi-ddpi</i>	4	0.3026	686	0.2572	5.44	-2.374	3.86
<i>pop15-pop75-dpi</i>	4	0.2744	714	0.227	7.36	-0.386	3.94
<i>pop75-dpi-ddpi</i>	4	0.189	798	0.1361	13.17	5.174	4.16
<i>pop15-pop75-dpi-ddpi</i>	5	0.3385	651	0.2797	5	-1.099	3.8

בעזרת הטבלה לעיל החליטו החוקרים לעבוד עם המודל הכולל את *pop15* ו-*ddpi* בלבד.
לפי מה הם בחרו מודל זה ומדוע.

לפי מדד BIC היות והוא הנמוך ביותר עבור מודל זה מבין כל המודלים.

ו. (8 נקודות) בעזרת הטבלה של סעיף ה', מה יהיה המודל הסופי בעזרת צעדים קדימה? מה יהיה המודל הסופי בעזרת צעדים אחורה?

רגרסיה באמצעות מבחן F-ה SSE של מודל ללא מסבירים הוא הפיזור של המשתנה המוסבר. בשתי הרגרסיות מתקבל אותו המודל כמו בסעיף הקודם. ניתן לבצע גם באמצעות BIC, אך יש לחשב את המדד עבור מודל ללא מסבירים בשביל להראות את השיפור במדד במעבר למודל עם מסביר בודד.

שאלה 3 (20 נקודות)

חוקר התאים מודל רגרסיה עם k משתנים מסבירים.

א. (10 נקודות) החוקר רצה לבדוק ההשערות הבאות:

$$H_0: \beta_{r+1} = \beta_{r+2} = \dots \beta_k = 0$$

$$H_1: \text{Not } H_0$$

הוצע לו לבדוק את ההשערות בעזרת הסטטיסטי הבא:

$$F = \frac{(R_F^2 - R_R^2) / (k - r)}{(1 - R_F^2) / (n - k - 1)} \sim F_{k-r, n-k-1}$$

הוכיחו שהמבחן שהוצע הינו זהה למבחן F חלקי לבעיה.

$$\frac{(R_F^2 - R_R^2) / (k - r)}{(1 - R_F^2) / (n - k - 1)} = \frac{SST}{SST} \frac{(R_F^2 - R_R^2) / (k - r)}{(1 - R_F^2) / (n - k - 1)} = \frac{(SSR_F - SSR_R) / (k - r)}{SSR_F / (n - k - 1)}$$

וזה בדיוק הסטטיסטי של מבחן F חלקי.

ב. (10 נקודות) החוקר אסף את הנתונים משני אזורים שונים. הסבירו כיצד במבחן F חלקי תוכלו

לבדוק את ההשערה האם ניתן להתאים מודל רגרסיה זהה לשני האזורים (H_0) או לא (H_1).

(רמז: הגדירו משתנה דמה ואינטראקציות).

יש להגדיר משתנה דמה המבדיל בין האזורים, ומשתני אינטראקציה עם כל המסבירים, ולבצע מבחן F חלקי על כל המקדמים של משתנה הדמה ומשתני האינטראקציה. אם לא נדחה את המבחן סימן שניתן להתאים מודל רגרסיה זהה לשני האזורים.

דרך נוספת- ביצוע מבחן CHOW. בדרך זו אין צורך במשתני דמה ואינטראקציה, יש לחלק את התצפיות לשני האזורים, להתאים מודל רגרסיה לכל אחד בנפרד ולבצע את המבחן.