

תאריך הבחינה:	09:00, 13.02.2018
שם המרצה:	ד"ר יואב קרנר
שם הקורס:	מודלים של רגרסיה ליניארית
מספר הקורס:	364-1-1061
שנה:	2018 סמסטר: א' מועד: א'
משך הבחינה:	משך המבחן – 3 שעות, יש לענות על כל השאלות
חומר עזר:	מחשבון

שאלה 1 (45 נקודות)

מנהל במסעדה, המקבל תלונות על זמני המתנה ארוכים, מעוניין לבדוק את הקשר בין זמני ההמתנה בפועל ובין זמני ההמתנה הסובייקטיביים שאותם חשים הצרכנים שחיו. לשם כך דגם המנהל 31 צרכנים שהמתנו בתור, מדד את הזמן שהמתנו בפועל וכן שאל כל צרכן כמה זמן המתין. המנהל התאים לנתונים מודל רגרסיה פשוטה: $Y_i = \beta X_i + \varepsilon_i$. כאשר $\varepsilon_i \sim N(0, \sigma^2)$ ב"ת.

$$\sum_{i=1}^{31} X_i Y_i = 5205, \sum_{i=1}^{31} Y_i^2 = 5303, \sum_{i=1}^{31} X_i^2 = 5120$$

תמצית הנתונים שנאספו:

- א. (4 נק') הסבר במשפט אחד מדוע המודל המתאים הוא מודל ללא חותך.
 ב. (4 נק') הסבר במשפט אחד מדוע הזמן שהצרכנים המתו בפועל הוא המשתנה המסביר והזמן הסובייקטיבי שאותו חשו הצרכנים הוא המשתנה המוסבר.

ג. (7 נק') הראה כי אומד הריבועים הפחותים ל- β הוא $\hat{\beta} = \frac{\sum_{i=1}^{31} X_i Y_i}{\sum_{i=1}^{31} X_i^2}$ וכן ששונתו היא

$$\frac{\sigma^2}{\sum_{i=1}^{31} X_i^2}$$

ד. (5 נק') הראה כי: $SSE = \sum_{i=1}^{31} Y_i^2 - \hat{\beta}^2 \sum_{i=1}^{31} X_i^2$.

ה. (6 נק') בדוק, ברמת מובהקות 5%, את ההשערות $H_0: \beta = 1$, $H_1: \beta > 1$. מה תוכל להגיד על ה-p-value?

ו. (4 נק') האם מסקנתך לגבי דחיית השערת האפס בסעיף הקודם הייתה שונה לו H_1 הייתה דו צדדית? ענה ללא חישובים נוספים.

ז. (8 נק') מוצע אומד אחר ל- β : $\tilde{\beta} = \frac{\bar{Y}}{\bar{X}}$. הראה כי $\tilde{\beta}$ חסר הטיה, חשב את שונתו, האם

היא גדולה מזו של $\hat{\beta}$? הוכח תשובתך ללא תלות בנתונים.

ח. (7 נק') חשב את $COV(\hat{Y}_i, e_i)$ עבור i כלשהו ללא תלות בנתונים.

שאלה 2 (29 נקודות)

במודל רגרסיה מרובה עם שלושה משתנים מסבירים וחותר, אחד המשתנים הוא משתנה קטגוריאלי עם שתי רמות נלקחו 125 דגימות ובוצעה רגרסיה ליניארית תוצאות הניתוח מוצגת בטבלה הבא:

```
> FM <- lm(Y ~ X1 + X2 + D + X1*D + X2*D, data=Q2)
> summary(FM)
```

Call:

```
lm(formula = Y ~ X1 + X2 + D + X1 * D + X2 * D, data = Q2)
```

Residuals:

Min	1Q	Median	3Q	Max
-34.771	-8.797	-1.589	9.272	40.154

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	38.1462	13.7997	C	0.00661 **
X1	-5.4666	2.5772	-2.121	0.03599 *
X2	0.8952	0.9368	0.956	0.34124
D1	-26.3267	16.1520	-1.630	0.10576
X1:D1	6.9351	2.9901	2.319	0.02208 *
X2:D1	-1.4074	1.0280	-1.369	0.17358

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 13.75 on **A** degrees of freedom

Multiple R-squared: 0.08626, Adjusted R-squared: **B**

F-statistic: 2.247 on 5 and **D** DF, p-value: 0.05404

א. (8 נק') מצא את הערכים A,B,C,D המופיעים בפלט זה.

ב. (5 נק') בנה טבלת ANOVA עבור המודל.

בוצעה רגרסיה לאחור (backward) תוצאות הניתוח מוצגות בטבלאות הבאות:

```
> reg1 <- step(FM, direction="backward", k=log(125))
```

Start: AIC=678

Y ~ X1 + X2 + D + X1 * D + X2 * D

	Df	Sum of Sq	RSS	AIC
- X2:D	1	354.1	22838	675.12
<none>			22484	678.00
- X1:D	1	1016.4	23500	678.70

Step: AIC=675.12

Y ~ X1 + X2 + D + X1:D

	Df	Sum of Sq	RSS	AIC
- X2	1	95.01	22933	670.81
<none>			22838	675.12
- X1:D	1	1334.34	24172	677.39

Step: AIC=670.81

Y ~ X1 + D + X1:D

	Df	Sum of Sq	RSS	AIC
<none>			22933	670.81
- X1:D	1	1354.7	24288	673.16

```
> BM <- lm(Y ~ X1 + D + X1*D, data=Q2)
> summary(BM)
```

```
Call:
lm(formula = Y ~ X1 + D + X1 * D, data = Q2)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-33.512  -8.319  -1.069   9.031  37.745
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  43.374      12.688   3.418 0.000859 ***
X1           -5.970       2.527  -2.363 0.019719 *
D1          -35.547      14.858  -2.393 0.018271 *
X1:D1         7.833       2.930   2.674 0.008542 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Multiple R-squared:  0.06801, Adjusted R-squared:  0.0449
F-statistic: 2.943 on 3 and 121 DF,  p-value: 0.03579
```

ג. (4 נק') חשב את ערך הסטטיסטי F-חלקי עבור הצעד הראשון ברגרסיה לאחר (זה שנעשה בפועל).

ד. (4 נק') מדוע התכנה בדקה את האפשרות להוציא רק חלק מהמשתנים המסבירים?

ה. (4 נק') חשב את ערך הסטטיסטי F-חלקי עבור הצעד האחרון ברגרסיה למול המודל המלא.

החוקרים הריצו את המודל עם הוספת משתנה ריבועי של משתנה X2, באופן הבא:

```
> Q2$X22 <- X2*X2
> FM_SQR2 <- lm(Y ~ X1 + X2 + X22 + D + X1*D + X2*D + X22*D, data=Q2)
> summary(FM_SQR2)
```

```
Call:
lm(formula = Y ~ X1 + X2 + X22 + D + X1 * D + X2 * D + X22 *
    D, data = Q2)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-34.049  -8.144  -1.328   8.849  37.428
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  39.1549      13.6843   2.861 0.0050 **
X1           -5.2022       2.5651  -2.028 0.0448 *
X2           -1.4194       2.8958  -0.490 0.6249
X22           0.3088       0.3661   0.844 0.4006
D1          -30.2843      16.0644  -1.885 0.0619 .
X1:D1         6.5651       2.9708   2.210 0.0291 *
X2:D1         2.8623       3.0762   0.930 0.3540
X22:D1        -0.4566       0.3731  -1.224 0.2234
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 13.58 on 117 degrees of freedom
Multiple R-squared:  0.1233, Adjusted R-squared:  0.07088
F-statistic: 2.351 on 7 and 117 DF,  p-value: 0.02777
```

ו. (4 נק') האם נכון להוסיף את המשתנה הריבועי? תן נימוק אחד בעד ונימוק אחד נגד.

שאלה 3 (31 נקודות)

נתבונן במודל הרגרסיה הפשוטה עם שונויות שונות שלמדנו בכיתה: $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$, כאשר $\varepsilon_i \sim N(0, c_i \sigma^2)$. הגדרנו את המטריצה האלכסונית בעלת n עמודות ו- n שורות:

$$W = \begin{pmatrix} \frac{1}{c_1} & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \frac{1}{c_n} \end{pmatrix}$$

בכיתה הצגנו את האר"פ המשוקללים למודל זה בכתיבה מטריציונית, עבור המודל המרחבה:

$$\hat{\beta} = (X^T W X)^{-1} X^T W Y$$

א. (6 נק') רשום אומדים אלו עבור המקרה הפרטי של הרגרסיה הפשוטה, כלומר רשום את

$$\hat{\beta}_0, \hat{\beta}_1 \text{ במונחי: } i=1, \dots, n, Y_i, X, c_i$$

ב. (5 נק') בכיתה ראינו שתי בעיות אופטימיזציה שהאר"פ המשוקללים פותרים. רשום אחת מהן.

ג. (15 נק') נתבונן כעת במודל הרגרסיה הפשוטה עם תצפיות חוזרות. כלומר, המודל בו ישנם

רק m ערכי X שונים. נסמן, כפי שמסומן בדף הנוסחאות, ב- Y_{ij} את התצפית ה- i מבין אלו

שערך המשתנה המסביר שלהן הוא X_j , ב- n_j את מספר התצפיות עבורן ערכו של

$$\bar{Y}_j = \frac{1}{n_j} \cdot \sum_{i=1}^{n_j} Y_{ij} \text{ , כמו כן, } X_j \text{ המשתנה המסביר הוא } X_j$$

הראה כי כאשר משתמשים במוצעים $\bar{Y}_1, \bar{Y}_2, \dots, \bar{Y}_m$ בלבד ומפעילים עליהם את המודל

המופיע בתחילת השאלה (כלומר מודל עם m תצפיות ושונויות לא שוות), האר"פ

המשוקללים זהים לאר"פ הרגילים במודל הרגרסיה הפשוטה הרגיל (עם כל n התצפיות)

המתעלם מהחזרות על ערכי X .

ד. (5 נק') כל אחד מהמודלים בסעיף הקודם מניב אומד חסר הטיה ל- σ^2 . מי מבין אומדים אלו עדיף? נמק.

מודלים של רגרסיה לינארית - דף נוסחאות למבחן מסכם

הרגרסיה הפשוטה

המודל: $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$ כאשר $\varepsilon_i \sim N(0, \sigma^2)$ ב"ת.

X_i קבועים ידועים, $\beta_0, \beta_1, \sigma^2$ פרמטרים לא ידועים. Y_i נצפים.

$$SXX = \sum_{i=1}^n (X_i - \bar{X})^2, SXY = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$$
 סכומי ריבועים של המשתנים:

$$\hat{\beta}_1 = \frac{SXY}{SXX}, \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$
 אומדי הריבועים הפחותים:

$$Var(\hat{\beta}_1) = \frac{\sigma^2}{SXX}, Var(\hat{\beta}_0) = \frac{\sigma^2}{n} + \bar{X}^2 Var(\hat{\beta}_1)$$
 שוניות האומדים:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i = \bar{Y} + \hat{\beta}_1 (X_i - \bar{X})$$
 התחזיות:

$$SST = SSY, SSR = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2, SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$
 סכומי הריבועים במודל:

משוואות הנורמליות:

$$\sum_{i=1}^n e_i = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = 0$$

$$\sum_{i=1}^n e_i X_i = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) X_i = 0$$

$$MSE = \frac{SSE}{n-2} : \sigma^2 \text{ אחר"ל}$$

$$F = \frac{SSR}{MSE} \quad t_{\hat{\beta}_1} = \frac{\hat{\beta}_1}{\sqrt{MSE/SXX}}, t_{\hat{\beta}_0} = \frac{\hat{\beta}_0}{\sqrt{MSE \left(\frac{1}{n} + \frac{\bar{X}^2}{SXX} \right)}}$$
 סטטיסטיים:

רווח סמך לתוחלת תצפית חדשה עבורה ערך המשתנה המסביר הוא x_0 :

$$\bar{Y} + \hat{\beta}_1 (x_0 - \bar{X}) \pm t_{n-2, 1-\alpha/2} \sqrt{MSE \left(\frac{1}{n} + \frac{(x_0 - \bar{X})^2}{SXX} \right)}$$

רווח חיזוי לתצפית חדשה עבורה ערך המשתנה המסביר הוא x_0 :

$$\bar{Y} + \hat{\beta}_1 (x_0 - \bar{X}) \pm t_{n-2, 1-\alpha/2} \sqrt{MSE \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{SXX} \right)}$$

מודל הרגרסיה המרובה

כאשר $Y_i = X_i\beta + \varepsilon_i$ הוא שורה באורך p .

בכתיבה מטריציונית: $Y = X\beta + \varepsilon$ כאשר $Y \in \mathbb{R}^n$ וקטור התצפיות, $\beta \in \mathbb{R}^p$ וקטור המקדמים, $X \in \mathbb{R}^{n \times p}$ מטריצת המשתנים המסבירים ו- $\varepsilon \in \mathbb{R}^n$ וקטור השגיאות, המקיים אותן הנחות כמו במודל הרגרסיה הפשוטה.

האר"פ $\hat{\beta} = (X^T X)^{-1} X^T Y$. מטריצת השוננויות המשותפות של האומדים: $Cov(\hat{\beta}) = \sigma^2 (X^T X)^{-1}$

וקטור התחזיות: $\hat{Y} = X\hat{\beta}$

סכומי ריבועים: $SSE = (Y - \hat{Y})^T (Y - \hat{Y})$, $SSR = \hat{Y}^T \hat{Y} - n\bar{Y}^2$, $SST = Y^T Y - n\bar{Y}^2$

הסקה על תוחלת תצפית עתידית $E(Y_0)$ (במודל עם חותר)

הסקה על הרמה הממוצעת של הפרטים המקיימים $\underline{X} = \underline{x}_0$, $\underline{C}^T = [1, \underline{x}_0^T]$

סטטיסטי המבחן:

$$t_{st} = \frac{C^T \hat{\beta} - C^T \beta|_{H_0}}{\sqrt{\hat{V}(C^T \hat{\beta})}}$$

$$V(C^T \hat{\beta}) = C^T V(\hat{\beta}) C = \sigma^2 C^T (X^T X)^{-1} C$$

ר"ס ברמת סמך $1-\alpha$ לתוחלת תצפית עתידית $E(Y_0)$: $E(Y_0) \in \underline{C}^T \hat{\beta} \pm t_{n-k-1, 1-\frac{\alpha}{2}} \sqrt{\hat{V}(\underline{C}^T \hat{\beta})}$

הסקה על תצפית עתידית Y_0 (במודל עם חותר)

נרצה לחזות את התגובה עבור פרט ספציפי אשר ערך המשתנה המסביר שלו הוא $\underline{x}_0$, נשתמש

בשארית $e_0 = Y_0 - \hat{Y}_0$ כך ש:

$$t_{st} = \frac{e_0 - 0}{\sqrt{\hat{V}(e_0)}} = \frac{(Y_0 - \hat{Y}_0) - 0}{\sqrt{\hat{\sigma}^2 (1 + \underline{C}^T (X^T X)^{-1} \underline{C})}}$$

רווח חיזוי ל- Y_0 (תצפית עתידית):

$$Y_0 \in \hat{Y}_0 \pm t_{n-k-1, 1-\frac{\alpha}{2}} \sqrt{\hat{V}(e_0)} = \underline{C}^T \hat{\beta} \pm t_{n-k-1, 1-\frac{\alpha}{2}} \sqrt{MSE \left(1 + \underline{C}^T (X^T X)^{-1} \underline{C} \right)}$$

השוואה בין מודל מלא ומודל חלקי באמצעות מבחן "F חלקי":

מודל חלקי (RM) - בעל p מקדמים ($p=k+1$)

מודל מלא (FM) - בעל $p+1$ מקדמים

א- מספר המשתנים אותם נבחן להוצאה מהמודל

$$F_{1...l|l+1...l+p-1} = \frac{[SSR(X_1, \dots, X_k, X_{k+1}, \dots, X_{k+l}) - SSR(X_1, \dots, X_k)]/l}{SSE(X_1, \dots, X_k, X_{k+1}, \dots, X_{k+l})/(n-p-l)}$$

$$= \frac{[SSR(FM) - SSR(RM)]/l}{MSE(FM)} \sim F_{l, n-p-l}$$

מדדים לטיב מודל:

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \quad \text{1. מדד } R^2$$

$$R_{adj}^2 = 1 - \frac{SSE/n-p}{SST/n-1} \quad \text{2. מדד } R_{adj}^2$$

$$AIC = n \ln(SSE/n) + 2p \quad \text{3. מדד } AIC \text{ (מודל רגרסיה)}$$

$$BIC = n \ln(SSE/n) + \ln(n)p \quad \text{4. מדד } BIC \text{ (מודל רגרסיה)}$$

LOF

$$\sum_{j=1}^m \sum_{i=1}^{n_j} (Y_{ij} - \hat{Y}_j)^2 = \sum_{j=1}^m \sum_{i=1}^{n_j} (Y_{ij} - \bar{Y}_j)^2 + \sum_{j=1}^m n_j (\bar{Y}_j - \hat{Y}_j)^2$$

$$SSE = SSPE + SSLF$$

$$F_{st} = \frac{MSLF}{MSPE} = \frac{SSLF/m-2}{SSPE/n-m} \geq F_{m-2, n-m}^{1-\alpha}$$

רגרסיה לוגיסטית

$\pi = \pi(X)$ - הסתברות להצלחה כתלות בווקטור המשתנים המסבירים X

$$\log \left(\frac{\pi(X_i)}{1 - \pi(X_i)} \right) = X_i \beta \quad \text{המודל:}$$

בדיקת השערות לבדיקת ההשערה שחלק מה β הן 0:

$$H_0 : \beta_1 = \beta_2 = \dots \beta_l = 0$$

$$H_1 : ELSE$$

מבחן LRT

$$Dev = -2 \log(L(\hat{\beta})) \quad \text{כאשר } \chi_{st}^2 = Dev(RM) - Dev(FM) \sim \chi_l^2 \quad \text{הסטטיסטי הוא}$$

מבחן Wald: סטטיסטי מבוסס על תבניות ריבועיות של האומדים שברוח משפט קוקרן מפולגות חי בריבוע