



הנחיות חשובות:

- יש לפתור את כל השאלות
- יש ללוות את דרך הפתרון בהסברים מילוליים קצרים
- ניתן להשתמש בכל הנוסחאות והתוצאות שפותרו או הוצגו בכיתה ואין צורך להוכיח מחדש אלא אם כן זה נדרש במפורש
- בכל מבחן השערות יש לנסח את ההשערות הנבדקות, לציין מהו סטטיסטי המבחן וכיצד הוא מתפלג, ולכתוב מהו אזור הדחייה (זאת כמובן בנוסף לתוצאת המבחן)
- אם לו צוין אחרת יש להשתמש בר"מ של 5%

תאריך הבחינה:	31.01.2019
שם המרצה:	פרופ' ישראל פרמט ומר איגור רוחלין
שם הקורס:	מודלים של רגרסיה לינארית
מספר הקורס:	364.1.1091
שנה:	2019
סמסטר:	א'
מועד:	א'
משך הבחינה:	3 שעות
חומר עזר:	5 דפי נוסחאות + טבלאות סטטיסטיות + מחשבון


בהצלחה ©

שאלה מספר 1 (38 נק')

חוקר אסף נתונים על מקרי לידה ומדדים סוציו-דמוגרפים שונים על 50 המדינות ובמחוז קולומביה (district of Colombia) בארצות הברית. בעזרת הנתונים הללו רצה החוקר, בין השאר, לחקור את הקשר בין שיעור מקרי הלידה בקרב מתבגרות בגילאים 15-17 (Brth15to17), Y, ושיעור העוני (PovPct), X. המשתנה Brth15to17 הינו מספר הלידות לאלף בנות בטווח הגילאים 15-17, והמשתנה PovPct הינו אחוז מאוכלוסיית המדינה המתגוררת במשקי בית עם הכנסה מתחת לרמת העוני המוגדרת על ידי הממשל הפדרלי. לנוחיותכם הנתונים הבאים:

$$\begin{aligned} \text{sum(PovPct)} &= 669 & \text{sum(PovPct}^2) &= 9690.44 \\ \text{sum(Brth15to17)} &= 1136.4 & \text{sum(Brth15to17}^2) &= 28556.56 \\ \text{sum(PovPct*Brth15to17)} &= 16163.14 \end{aligned}$$

- א. (7 נק') התאימו את קו הריבועים הפחותים בהתאם לנתוני השאלה.
- ב. (7 נק') רשמו את טבלת ניתוח השונות של המודל שהתקבל וחשבו את R^2 .
- ג. (6 נק') בדקו את ההשערה ששיעור העוני מעלה את שיעור מקרי הלידה בקרב מתבגרות. רשמו את ההשערות ברישום השערות סטטיסטי, מהי רמת המובהקות המינימלית (p-value)? מה תהיה ההחלטה בר"מ של 5%?
- ד. (4 נק') מה יקרה לאומדים של החותך והשיפוע אם במקום להשתמש בשנים, יחשבו מספר לידות ל-10000 בקרב בנות בטווח הגילאים 15-17?
- ה. (4 נק') מה יקרה לאומד של החותך והשיפוע אם במקום להשתמש באחוז מספר המשפחות היו משתמשים בפרופורציית מספר המשפחות החיות במשקי בית עם הכנסה מתחת לרמת העוני?
- ה. (10 נק') מה ניתן ללמוד על מכל אחד מהשרטוטים הבאים על הנחות המודל.




שאלה מספר 2 (40 נק')

נערך מחקר הבדוק את נזקי העישון בילדים ובני נוער. במחקר נדגמו 654 בני נוער מאזור מזרח בוסטון בטווח הגילאים 3 עד 19. המשתנה התלוי במחקר היה FEV (forced expiratory volume), הוצאה מהירה של האוויר ומדידת ספיקת האוויר במהלך השנייה הראשונה (תלויה בזמן). נתוני המחקר רוכזו בקובץ נתונים המכיל את העמודות הבאות:

Label Description

fev	the amount of air an individual can exhale in the first second of a forceful breath in liters.
age	participant age (years)
ht	participant height (inches)
gender	Female coded 0, Male coded 1
smoke	Nonsmoker coded 0, Smoker coded 1

א. (6 נק') מה ניתן ללמוד מהתרשימים הבאים, על המודל והנחותיו? מה ניתן ללמוד על המולטי קוליאנאריות בין המנבאים השונים?



ב. (6 נק') חוקר התאים את הרגרסיה הבאה:


$\text{lm}(\text{formula} = \text{fev} \sim \text{ht} + \text{age} + \text{gender} + \text{smoke})$

וקיבל את התוצאות הבאות:

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-4.456974	0.222839	-20.001	< 2e-16
ht	0.104199	0.004758	21.901	< 2e-16
age	0.065509	0.009489	6.904	1.21e-11
gender	0.157103	0.033207	4.731	2.74e-06
smoke	-0.087246	0.059254	-1.472	0.141

Residual standard error: 0.4122 on 649 degrees of freedom
Multiple R-squared: 0.7754, Adjusted R-squared: 0.774
F-statistic: 560 on 4 and 649 DF, p-value: < 2.2e-16



מה ניתן ללמוד מהפליטים? מה טיב התאמת המודל? מה ניתן להגיד על הנחות המודל? האם יש צורך בכל המשתנים המסבירים? במידה ולא, איזה ניתן לדעתך להוציא ראשון מהמודל?

ג. (6 נק') לא מרוצה מהתוצאות, החוקר החליט להתאים את המודל הבא:


`lm(formula = fev ~ ht + I(ht^2) + age + gender + smoke)`

וקיבל את התוצאות הבאות:


Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	6.8945787	1.4993579	4.598	5.12e-06
ht	-0.2742341	0.0496850	-5.519	4.92e-08
I(ht^2)	0.0031251	0.0004086	7.649	7.35e-14
age	0.0694646	0.0091089	7.626	8.66e-14
gender	0.0945352	0.0328613	2.877	0.00415
smoke	-0.1332112	0.0571079	-2.333	0.01997


Residual standard error: 0.3951 on 648 degrees of freedom
Multiple R-squared: 0.794, Adjusted R-squared: 0.7924
F-statistic: 499.4 on 5 and 648 DF, p-value: < 2.2e-16



מה היו השיקולים בשינוי המודל? האם השינוי שיפר את טיב התאמת המודל? מה ניתן להגיד על הנחות המודל לאחר השינוי? האם יש צורך בכל המשתנים המסבירים כעת? במידה ולא, איזה ניתן לדעתך להוציא ראשון מהמודל?
ד. (5 נקודות) החוקר החליט לבדוק את הצורך בהתמרה של המשתנה התלוי ולשם כך התאים את המודל של BOX ו-COX לנתונים וקיבל את הגרף הבא:



במודל זה איזה משפחה של התמרות נבדקת? על סמך הגרף איזו התמרה תמליץ לחוקר?
נמק!!!
ה. (5 נק') לפני שהתאים את המודל החדש קיבל את הגרפים הבאים:



מה ניתן ללמוד מהתרשימים הנ"ל, על המודל והנחותיו?

ו. (6 נק') בעקבות ממצאיו האחרונים החליט החוקר להתאים את המודל


`lm(formula = log(fev) ~ ht + I(ht^2) + age + gender + smoke)`

וקיבל את התוצאות הבאות:

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-2.4370738	0.5521375	-4.414	1.19e-05
ht	0.0592338	0.0182965	3.237	0.00127
I(ht^2)	-0.0001357	0.0001505	-0.902	0.36727
age	0.0232154	0.0033543	6.921	1.08e-11
gender	0.0320371	0.0121011	2.647	0.00831
smoke	-0.0440710	0.0210299	-2.096	0.03650

Residual standard error: 0.1455 on 648 degrees of freedom
Multiple R-squared: 0.8109, Adjusted R-squared: 0.8094
F-statistic: 555.7 on 5 and 648 DF, p-value: < 2.2e-16



מה ניתן להגיד על הנחות המודל לאחר השינוי? האם יש צורך בכל המשתנים המסבירים כעת? במידה ולא, איזה ניתן לדעתך להוציא ראשון מהמודל?

ז. (6 נק') המודל הסופי שהחוקר בחר לעבוד אתו הוא:

`lm(formula = log(fev) ~ ht + age + gender + smoke)`

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1.943998	0.078639	-24.721	< 2e-16
ht	0.042796	0.001679	25.489	< 2e-16
age	0.023387	0.003348	6.984	7.1e-12
gender	0.029319	0.011719	2.502	0.0126
smoke	-0.046068	0.020910	-2.203	0.0279

Residual standard error: 0.1455 on 649 degrees of freedom
Multiple R-squared: 0.8106, Adjusted R-squared: 0.8095
F-statistic: 694.6 on 4 and 649 DF, p-value: < 2.2e-16

מה ניתן ללמוד ממודל זה על השפעת המשתנים השונים על **המשתנה fev**?

שאלה 3 (22 נק')

נערך מחקר על 800 בנים על הקשר בין מצב סוציו-אקונומי וחברות בצופים אל מעורבות בעבריינות נוער. קובץ הנתונים מכיל שלושה משתנים המשתנה התלוי, מעורבות (Delinquent), משתנה בעל שתי רמות, מעורב (Yes) ולא מעורב (No), חברות בצופים (boy_scout), משתנה בעל שתי רמות: חבר (Yes) ולא חבר (No) והמשתנה השלישי מצב סוציו-אקונומי, משתנה בעל שלוש רמות: נמוך (Low), בינוני (Medium) וגבוה (High).



- א. (6 נק') החוקר החליט להתאים מודל של רגרסיה לוגיסטית. מה היה השיקול המרכזי של החוקר לבחור במודל זה?
ב. (6 נק') החוקר התאים את סדרת המודלים הבאה:

```
1. resF <-glm(Delinquent ~ Socioeconomic * Boy_scout , family=binomial)
2. resM <-glm(Delinquent ~ Socioeconomic + Boy_scout , family=binomial)
3. resS <-glm(Delinquent ~ Socioeconomic , family=binomial)
4. resB <-glm(Delinquent ~ Boy_scout , family=binomial)
5. resN <-glm(Delinquent ~ 1 , family=binomial)
```

וקיבל את התוצאות הבאות:

Model Number	Deviance	AIC	BIC
1. Full	24.92407	36.92407	35.67463
2. Main	25.07836	33.07836	32.24540
3. Socioeconomics only	25.08640	31.08640	30.46168
4. Boy scout only	53.72617	57.72617	57.30969
5. Null	61.33874	63.33874	63.13050

מהו המודל שהייתי ממליץ לחוקר לבחור? נמק תשובתך!!!!
ג. (10 נק') החוקר החליט לעבוד עם המודל

```
glm(Delinquent ~ Socioeconomic, family=binomial)
```

וקיבל את התוצאות הבאות:

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-3.2387	0.3224	-10.047	< 2e-16
SocioeconomicLow	1.8524	0.3571	5.188	2.13e-07
SocioeconomicMedium	1.3012	0.3709	3.508	0.000451

מה ניתן להסיק על שאלת המחקר מהמודל הסופי שהותאם? האם גורמי הסיכון שבבדקו נמצאו כמשפיעים? אם כן, איך?