



הנחיות חשובות:

- יש לפתור את כל השאלות
- יש ללוות את דרך הפתרון בהסברים מילוליים קצרים
- ניתן להשתמש בכל הנוסחאות והתוצאות שפותחו או הוצגו בכיתה ואין צורך להוכיח מחדש אלא אם כן זה נדרש במפורש
- בכל מבחן השערות יש לנסח את ההשערות הנבדקות, לציין מהו סטטיסטי המבחן וכיצד הוא מתפלג, ולכתוב מהו אזור הדחייה (זאת כמובן בנוסף לתוצאת המבחן)
- אם לא צוין אחרת יש להשתמש בר"מ של 5%

תאריך הבחינה:	07.07.2019
שם המרצה:	פרופ' הלל בר-גרא ומר איגור רחלין
שם הקורס:	מודלים של רגרסיה לינארית
מספר הקורס:	364.1.1091
שנה:	2019 סמסטר: ב' מועד: א'
משך הבחינה:	3 שעות
חומר עזר:	5 דפי נוסחאות + טבלאות סטטיסטיות + מחשבון

בהצלחה ☺

שאלה מספר 1 (35 נק')

צוות מחקר רפואי בבי"ח סורוקה ביצע מדידות כמותיות לנפח המנומל של טרשת העורקים בממ"ק (NTAV - normalized total atheroma volume) כתלות בגיל הנבדק. לפניכם סיכום הנתונים:


$$\sum x_i y_i = 507930 \quad \sum y_i = 7914.798 \quad \sum x_i = 7318$$

$$\sum y_i^2 = 611123.8 \quad \sum x_i^2 = 476786$$

א. (7 נק') אמדו משוואת הרגרסיה ואת שונת המודל.

$$\widehat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = 0.38; \widehat{\beta}_0 = \bar{y} - \widehat{\beta}_1 \bar{x} = 44.33; MSE = \frac{SSE}{n-2} = S_{yy} - \widehat{\beta}_1^2 S_{xx} \cong 573$$

החוקרים רצו לבדוק האם ישנו הבדל בין דברים לנשים, לשם כך הוסף משתנה ה-SEX.
ב. (7 נק') מה ניתן ללמוד מהגרף הבא על ההבדל בהשפעה בין גברים לנשים על המדד הנמדד של טרשת העורקים?



לפי המודל ישנו הבדל התחלתי (בחיתוך) בין גברים לנשים, אך ההשפעה של גיל (שיפועי הקווים) דומים בשתי הקבוצות.

ג. (7 נק') הציגו דוגמא אחת או שתיים לתצפית (או תצפיות) שלהערכתכם תקבל (יקבלו) ערך גבוה יחסית של מינוף, ודוגמא אחת או שתיים לתצפית שתקבל ערך גבוה יחסית של השפעה. יש לציין את טווח הערכים של שני המשתנים במשבצת שבה נמצאת אותה תצפית. מה המשמעות של המדדים הללו?

מינוף גבוה: אישה בגיל 85 עם מדד NATV 75, שני הגברים בגיל 35 עם NATV סביב 50. מדד המינוף מצביע על ערך חריג מבחינת המשתנים המסבירים. השפעה גבוהה: הגבר בגיל קצת מתחת ל 70, עם מדד NATV קצת מתחת ל 175. מדד זה מצביע על ערך חריג מבחינת השינוי במודל במידה ונוציא את התצפית מהמדגם.

החוקרים הריצו מודל רגרסיה ללא אינטראקציה וקיבלו את הפלט הבא

```
Call:
lm(formula = NTAV ~ age + sex, data = radial)

Residuals:
    Min       1Q   Median       3Q      Max
-46.025 -12.687  -1.699   5.784  89.419

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  17.8697    14.3846   1.242  0.21673
age           0.6379     0.2134   2.989  0.00344 **
sexM          20.5476     4.1943   4.899 3.27e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 21.82 on 112 degrees of freedom
Multiple R-squared:  0.1969,    Adjusted R-squared:  0.1825
F-statistic: 13.73 on 2 and 112 DF,  p-value: 4.659e-06
```

ד. (7 נק') מה ניתן להגיד על ההוספה של משתנה זה עבור המודל (לעומת המודל בו רק הגיל הוא המסביר)? אם היית צריך להשמיט את אחד או יותר מהמשתנים במודל במי היית חושד? בצע מבחן המסתמך על החשד.

משתנה המגדר מובהק, ולכן תוספת משתנה זה תורמת למודל. המדד R^2 ו- R^2_{adj} השתפרו. מבין שני המשתנים לגיל יש ערך p-value נמוך יותר, ולכן הוא החשוד מבין השניים. אבל גם משתנה זה מובהק סטטיסטית (מבחן t או מבחן F חלקי), ולכן לא כדאי להוציא אף אחד מהמשתנים מהמודל.

ה. (7 נק') החוקרים החליטו לבחון את האפשרות לאמוד מודל נפרד לנשים ומודל נפרד לגברים. על סמך הפלטים שהתקבלו (להלן), מה ניתן ללמוד על הנחות המודל המשותף? אם אפשר, גבו את מסקנותיכם במבחנים סטטיסטיים.

For Females:

```
Call:
lm(formula = NTAV ~ age, data = radial)

Residuals:
    Min       1Q   Median       3Q      Max
-32.603  -7.285  -1.067   4.883  40.657

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  13.5846    14.3535   0.946  0.34807
```

```
Age          0.7028      0.2155      3.261      0.00191 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 14.21 on 55 degrees of freedom
Multiple R-squared:  0.1621,    Adjusted R-squared:  0.1468 
F-statistic: 10.64 on 1 and 55 DF,  p-value: 0.001907
```

For Males:

```
Call:
lm(formula = NTAV ~ age, data = radial)

Residuals:
    Min       1Q   Median       3Q      Max
-45.529 -16.634  -4.638   5.902  89.776

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    41.2502     21.8224   1.890  0.0639 .
Age             0.5917      0.3512   1.684  0.0977 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 27.45 on 56 degrees of freedom
Multiple R-squared:  0.04822,    Adjusted R-squared:  0.03123 
F-statistic: 2.837 on 1 and 56 DF,  p-value: 0.09766
```

בפלט הנוסף ניתן לראות שיש פער גדול בין ה MSE במודל של הגברים ל MSE במודל של הנשים. ממצא זה מעלה ספק לגבי הנחת שוויון השוניות. ניתן לראות זאת גם בתרשים. אפשר לבדוק את ההשערה של שוויון שוניות על ידי מבחן F.

שאלה מספר 2 (35 נק')

מיקי זכה בסכום כסף גדול בירושה, ורצה להתפנק ברכב מסוג פורש. הוא החליט לעשות סקר שוק ולכן אסף נתונים על מחירי מכוניות פורש, זמן הרכבים על הכביש (בשנים) והמיילים (ביח' של אלפים) שהם עברו. מיקי קיבל את הפלט הבא:

```
Residuals:
    Min       1Q   Median       3Q      Max
-18.930  -3.795  -0.309   4.116  12.811

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    70.9192     2.4835  28.556 < 2e-16 ***
Age            -0.1302     0.4568  -0.285  0.778
Mileage        -0.5613     0.1141  -4.921 3.76e-05 ***
---

```

signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 7.291 on 27 degrees of freedom
Adjusted R-squared: 0.7799

א. (7 נק') השלימו את טבלת ניתוח השונות של המודל, נסחו את ההשערה וענו עליה.

<i>Source</i>	<i>SS</i>	<i>df</i>	<i>MS</i>	<i>F_{st}</i>
<i>R</i>	28.28	2	14.14	52.37
<i>E</i>	7.291	27	0.27	
<i>T</i>	35.579	29		

$$\begin{cases} h_0: \beta_1 = \beta_2 = 0 \\ h_1: \text{else} \end{cases} \rightarrow F_{st} = 52.37 \sim F_{27}$$

ולכן בר"מ של 5% נדחה את ההשערה, ונאמר שעל סמך נתונים ישנו קשר בין כמות המיילים שהרכב עבר וזמן הרכב על הכביש לבין מחירו.

סוחר המכוניות הוותיק דון אלברטו, טוען שאין שום קשר בין המרחק שהרכב עבר למחירו, ולראייה הביא את הפלט הבא:

Call:

lm(formula = Price ~ Age)

Residuals:

Min	1Q	Median	3Q	Max
-14.9801	-8.9233	0.2371	8.0747	19.6250

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	63.375	2.643	23.982	< 2e-16 ***
Age	-2.071	0.312	-6.637	3.36e-07 ***


signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 9.861 on 28 degrees of freedom
Multiple R-squared: 0.6114, Adjusted R-squared: 0.5975
F-statistic: 44.04 on 1 and 28 DF, p-value: 3.36e-07

ב. (7 נק') דון אלברטו טוען שעל פי הפלט, ניתן לראות שמחיר הרכב מושפע על ידי הגיל בלבד. חוו דעתכם על טענתו של הדון. (רצוי להיעזר בסעיף א)

הטענה לא מתאימה לנתונים. מדד ה- R^2_{adj} גרוע יותר במודל שמבוסס רק על גיל. המקדם של משתנה המיילים במודל המקורי מובהק. לכן יש להשאיר את משתנה המיילים במודל. ייתכן שכדאי לשקול להוציא את משתנה הגיל, ולהשאיר רק את משתנה המיילים. בנוסף- ישנו חשש למולטי קולינאריות בין המשתנים המסבירים, דבר אשר עלול למסך את ההשפעות השונות של המשתנים במודל המרובה.

דון אלברטו החליט לנסות לשפר עוד יותר את המודל המוצלח לטענתו שבנה, והסתכל על התרשימים הבאים:



ובנוסף הסתכל בתרשים BOX-COX. בעקבות התרשימים החליט לבצע טרנספורמציה log למשתנה המחיר.

ג. (7 נק') הסבירו מה ראה דון אלברטו בתרשים ה- BOX-COX שגרם לו להחליט על טרנספורמציה זו.

מתרשים השאריות ניתן להסיק שישנה בעיה של שוויון שוניות, כמו גם קשר לוגריתמי בין המשתנים. סביר להניח שראה בתרשים ה- BOXCOX שהערך $\lambda=0$ נמצא ברווח הסמך האופטימלי, ולכן יש לבחור בטרנספורמציה log.

ד. (7 נק') השוו בין המודלים באמצעות שני מדדים שונים.

ניתן להשוות באמצעות מדד R_{adj}^2 (MSE) הנתון בפלט, ולחשב מדדי AIC או BIC

ה. (7 נק') נתונה השורה הבאה עבור המודל בו המחיר מוסבר באמצעות המיילים (קרי-
(Price~Mileage)

Residual standard error: 7.17

בצעו רגרסיה לפנים ולאחור. האם קיבלתם את אותו המודל? האם ניתן היה להסתפק בכיוון אחד? נמקו.

ניתן לחשב את ערך ה- SST לפי מדד טיב ההתאמה המתוקן מהפלט של המודל המלא (הפלט הראשון)

$$R_{adj}^2 = 1 - \frac{MSE}{\frac{SST}{n-1}} = 1 - \frac{9.861^2}{\frac{SST}{29}} = 0.7799 \rightarrow SST = 12812$$

על פי הפלטים:

ה- SSE של המודל החלקי הראשון (כאשר המסביר הוא זמן הרכב על הכביש) הוא

$$MSE(RM_1) = 9.861^2 = 97.239 \rightarrow SSE(RM_1) = 2722.7$$

ה- SSE של המודל החלקי השני (כאשר המסביר הוא מספר המיילים) הוא

$$MSE(RM_2) = 7.17^2 = 51.4089 \rightarrow SSE(RM_2) = 1439.45$$

ה- SSE של המודל המלא (כאשר שניהם מסבירים) הוא

$$SSE(FM) = 2625.46$$

מבחן F חלקי נתון על פי

$$F_{st} = \frac{(SSE(RM) - SSE(FM))/l}{MSE(FM)}$$

כאשר היות ומדובר ברגרסיה בצעדים מספר הפרמטרים, $l = 1$.



צעד ראשון לאחר ניתן לעשות על סמך הפלט הראשון, היות ומבחן t שקול למבחן F (חלקי ב מקרה זה). משתנה הגיל אינו מובהק ומשתנה המיילים כן, ולכן נבחר להוריד את משתנה הגיל.

כעת נבחן האם להוציא את משתנה הגיל ולהישאר עם מודל ריק-

$$F_{st} = \frac{MSR}{MSE} = \frac{\frac{SST - SSE}{1}}{MSE} = \frac{11372.55}{1439.45} = 7.9 \sim F_{1,28}$$

באמצעות הטבלה עבור ר"מ של 5% נדחה את ההשערה ולכן נשאר עם המודל בו המסביר הוא המיילים.

צעדים לפנים- בצעד הראשון מהמודל הריק נבחר להכניס את משתנה המיילים (כי ה-SSE אשר מתקבל באמצעותו נמוך יותר מאשר זה המתקבל באמצעות המשתנה זמן על הכביש). הצעד השני הוא בדיוק הצעד לאחר שביצענו לעיל.

שאלה 3 (30 נק')

חוקר A הריץ רגרסיה מרובה על בסיס נתונים. חוקר B רצה לשחזר את התוצאות של חוקר A, אך השתמש בטעות ב-וקטור התחזיות שקיבל חוקר A במקום בתצפיות עצמן. חוקר C רצה גם הוא לשחזר את התוצאות של חוקר A, אך השתמש בטעות בווקטור השאריות במקום בתצפיות עצמן.

עבור כל אחד מהמודלים של החוקרים המבולבלים (B,C) ענו על הסעיפים הבאים ונמקו. ניתן להשתמש בכל ערך אגרגטיבי עבור המודל המקורי (שימוש בנוסחה שמחייבת שימוש בערכים המפורטים של כל התצפיות אינו קביל)

א. (10 נק') למה שווה $sign\{R_{adj}^2\}$ (פונק' הסימן) של המודל?

ב. (10 נק') למה שווה R_{adj}^2 ?

ג. (10 נק') אילו הנחות רגרסיה מתקיימות ואלו לא?

חוקר B בעצם חזה את התחזיות מחדש- ולכן יקבל בדיוק את אותם החיזויים. המשמעויות הן התאמה מלאה של הנתונים ו-0 שגיאות ($SSE = 0$ ו- $R_{adj}^2 = 1$). הנחת הלינאריות תתקיים בוודאות (כי הקשר בין הנתונים לערכים החזויים הוא לינארי). השגיאות כולם שוות ל-0 ולכן ניתן להתווכח אם הן נורמליות ב"ת עם תוחלת ושונות 0, או פשוט קבועות. בכל מקרה כל וריאציה מנומקת התקבלה כאן.

חוקר C ניסה לחזות את השאריות לאחר החיזוי באמצעות מטריצת התצפיות- כלומר הוא מנסה לחזות את כל מה שהתצפיות לא הצליחו לחזות. זה אומר שה- $SSR = 0$ מה שמוביל ל-



$$R_{adj}^2 = 1 - \frac{\frac{SSE}{n-p}}{\frac{SSE + SSR}{n-1}} = 1 - \frac{n-1}{n-p}$$

והיות ואנחנו ברגרסיה מרובה, הערך תמיד יתקבל שלילי.

בהנחה שכל הנחות הרגרסיה מתקיימות במודל המקורי (מודל A), נקבל ענן בתרשים השאריות אל מול הערך החזוי. לכן במודל C הנחת הלינאריות לא מתקיים (על מה שמעיד הסימן של מדד טיב ההתאמה המרובה המתוקנן). הנחת הנורמליות ושוויון השונויות תתקיים בהתאם למודל המקורי- כי כעת נראה רק את השאריות (כלומר קו הרגרסיה שיתקבל יהיה $y = 0$).

בהצלחה