



הנחיות חשובות:

- יש לפתור את כל השאלות
- יש ללוות את דרך הפתרון בהסברים מילוליים קצרים
- ניתן להשתמש בכל הנוסחאות והתוצאות שפותחו או הוצגו בכיתה ואין צורך להוכיחן מחדש אלא אם כן זה נדרש במפורש
- בכל מבחן השערות יש לנסח את ההשערות הנבדקות, לציין מהו סטטיסטי המבחן וכיצד הוא מתפלג, ולכתוב מהו אזור הדחייה (זאת כמובן בנוסף לתוצאת המבחן)
- אם לא צוין אחרת יש להשתמש בר"מ של 5%

תאריך הבחינה: 25.07.2019

שם המרצה: פרופ' הלל בר-גרא ומר איגור רחלין

שם הקורס: מודלים של רגרסיה לינארית

מספר הקורס: 364.1.1091

שנה: 2019 סמסטר: ב' מועד: ב'

משך הבחינה: 3 שעות

חומר עזר: 5 דפי נוסחאות + טבלאות

סטטיסטיקות + מחשבון

בהצלחה ☺

שאלה מספר 1 (35 נק')

מגדל עצים קנדי בחן את הקשר בין היקף העץ (girth בס"מ), וגובה העץ (במטרים) לבין הנפח של חומר הגלם שניתן להפיק מכל עץ (בקוב).

א. (7 נק') בשלב ראשון החליט החוקר לנתח את הנתונים באמצעות מודל ליניארי מרובה. הסבירו את המשמעות של ערכי שלושת המקדמים שהתקבלו במודל זה.

Call:

```
lm(formula = volume ~ Girth + Height, data = trees)
```

Residuals:

Min	1Q	Median	3Q	Max
-6.4065	-2.6493	-0.2876	2.2003	8.4847



Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-57.9877	8.6382	-6.713	2.75e-07 ***
Girth	4.7082	0.2643	17.816	< 2e-16 ***
Height	0.3393	0.1302	2.607	0.0145 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.882 on 28 degrees of freedom
Multiple R-squared: 0.948, Adjusted R-squared: 0.9442
F-statistic: 255 on 2 and 28 DF, p-value: < 2.2e-16

ב. (7 נק') להלן שני תרשימים שהתקבלו ממודל זה. מה ניתן ללמוד מהם?



ג. (7 נק') החוקר רצה לנסות לשפר את המודל ולכן חשב על רעיון להריץ מודל עם אותם שני מסבירים אך הפעם תוך התייחסות לאינטראקציה (ראו פלט להלן). חוו דעתכם על שינוי המודל לעומת המודל מסעיף א'. מה הסיבה לשינויים אלו לדעתך?

```
Call:
lm(formula = volume ~ Girth * Height, data = trees)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-6.5821 -1.0673  0.3026  1.5641  4.6649
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  69.39632   23.83575   2.911  0.00713 **
Girth        -5.85585    1.92134  -3.048  0.00511 **
Height       -1.29708    0.30984  -4.186  0.00027 ***
Girth:Height  0.13465    0.02438   5.524  7.48e-06 ***
```

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 2.709 on 27 degrees of freedom
Multiple R-squared:  0.9756,    Adjusted R-squared:  0.9728
F-statistic: 359.3 on 3 and 27 DF,  p-value: < 2.2e-16
```

ד. (7 נק') בשלב האחרון החליט החוקר לבצע טרנספורמציה לוגריתמית (ראו פלט להלן). מהי משמעות המקדמים במודל זה? האם ניתן היה לשער את הערכים של המקדמים הללו (או של חלקם) גם ללא נתונים (וללא שימוש בפונק' EXP)? האם לדעתך יש הצדקה לטרנספורמציה במקרה זה?

```
Call:
lm(formula = log(Volume) ~ log(Girth) + log(Height), data = trees)

Residuals:
    Min       1Q   Median       3Q      Max
-0.168561 -0.048488  0.002431  0.063637  0.129223

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -6.63162    0.79979  -8.292 5.06e-09 ***
log(Girth)   1.98265    0.07501  26.432 < 2e-16 ***
log(Height)  1.11712    0.20444   5.464 7.81e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.08139 on 28 degrees of freedom
Multiple R-squared:  0.9777,    Adjusted R-squared:  0.9761
F-statistic: 613.2 on 2 and 28 DF,  p-value: < 2.2e-16
```


ה. (7 נק') חשבו את ערך AIC ו BIC עבור כל אחד מהמודלים. מה ניתן ללמוד מההשוואה ביניהם?

שאלה מספר 2 (35 נק')

מהנדס ראשי של קניון במרכז באר שבע מנהל פרויקט של הכנסת מערכת קירור חדשה וברצונו ללמוד על הקשר בין צריכת חשמל (MW) של מערכת קירור הקניון לבין הטמפרטורה הממוצעת המתקבלת (°C). למען המטרה נאספו 25 תצפיות והתקבלו הערכים הבאים:

$$\begin{aligned}\sum x_i y_i &= 2814.408 & \sum y_i &= 401.492 & \sum x_i &= 300 \\ \sum y_i^2 &= 10257.256 & \sum x_i^2 &= 4900\end{aligned}$$

- (7 נק') חשבו את אמדי הריבועים הפחותים ומדד נקודתי לבחירתכם בו ניתן להשתמש לבחינת התאמת המודל לנתונים. נמקו את בחירתך.
- (7 נק') בקניון אחר הדומה בגודל ומערכת קירור לקניון שלנו ביקשו להשתמש במודל שבנינו כדי להעריך את הטמפרטורה. המערכת שלהם יכולה לקבל רק 8 או 12 (MW). מצאו את טווח הפרש הטמפרטורות שהם יכולים לקבל בין ערכים אלו.
- (7 נק') מה תוכלו להגיד על הנחות מודל רגרסיה לפי הפלטים הנ"ל:
(בגרף השמאלי הנתונים חולקו ל 5 קבוצות כשלכל אחת נבנה boxplot)



ד. (7 נק') המהנדס הוסיף משתנה נוסף (לחות) למודל וקיבל פלט:

```
call:
lm(formula = y ~ power + humidity)

Residuals:
    Min       1Q   Median       3Q      Max
-12.3697  -3.4420   0.2717   3.4378  12.2806

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  33.9762     4.1407   8.205 3.86e-08 ***
power       -1.6047     0.1879  -8.542 1.96e-08 ***
humidity      0.1711     0.2759   0.620  0.541
---
Signif. codes:
  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.678 on 22 degrees of freedom
Multiple R-squared:  0.8138,    Adjusted R-squared:  0.7969 
F-statistic: 48.08 on 2 and 22 DF,  p-value: 9.328e-09
```

חוו דעתכם על שינוי המודל לעומת המודל מסעיף א'. השוו באמצעות שתי דרכים שונות לפחות.

ה. (7 נק') כיצד ישתנה הפלט שהתקבל בסעיף ד' אם נתוני צריכת החשמל היו בקילו-ואט (KW) במקום במגה-ואט (MW)?



שאלה 3 (30 נק')

שתי סטטיסטיקאיות התקבלו לעבודה כ data scientists בחברה מובילה. במסגרת עבודתן התבקשו לנתח תוצאות של ניסוי שכלל $n=2m+1$ תצפיות, עם משתנה מסביר אחד, x , שתוכן על ידי סדרה חשבונית (כלומר מרווח קבוע d בין ערך לערך). סטטיסטיקאית A בחרה לבצע רגרסיה פולינומילית סטנדרטית מסדר שני (עם חותך), שבה המשתנים המסבירים הם $x_{i1}=x_i$ ו $x_{i2}=x_i^2$. סטטיסטיקאית B בחרה לבצע רגרסיה פולינומילית "אורתוגונלית" מסדר שני (עם חותך), שבה המשתנים המסבירים הם:

$$x_{i3} = \frac{x_i - \bar{x}}{d}; x_{i4} = \left(\frac{x_i - \bar{x}}{d}\right)^2 - \frac{m(m+1)}{3}$$

העזרו במבנה המטריצה $X^T X$

- א. (5 נק') הראו בעזרת דוגמא שהמטריצה $X_A^T X_A$ שתקבל סטטיסטיקאית A לא בהכרח אלכסונית.
ב. (5 נק') הראו שהמטריצה $X_B^T X_B$ שתקבל סטטיסטיקאית B תמיד אלכסונית. רמז: ידוע כי

$$\sum_{s=1}^k s^2 = \frac{(2k+1)(k+1)k}{6}$$

- ג. (10 נק') האם $SSE_A > SSE_B$, $SSE_A = SSE_B$, $SSE_A < SSE_B$ או שלא ניתן לדעת? מה המשמעות של תוצאה זו? (שימו לב למרחב הנפרש על ידי העמודות של X)
ד. (10 נק') האם $VIF_{2A} > VIF_{2B}$, $VIF_{2A} = VIF_{2B}$, $VIF_{2A} < VIF_{2B}$ או שלא ניתן לדעת? מה המשמעות של תוצאה זו?