

מודלים של רגרסיה לינארית

מועד א' סמסטר א' תשפ"א

חלק שני

שאלה 2 (28 נק': א-8, ב-5, ג-9, ד-6)

נתבונן במודל הרגרסיה הפשוטה שלמדנו בכיתה: $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$, כאשר $\varepsilon_i \sim N(0, \sigma^2)$

- א. הוכח כי $Cov(\hat{\beta}_1, \bar{Y}) = 0$.
- ב. חשב את $Cov(\hat{\beta}_1, \hat{\beta}_0)$.
- ג. נתון $n=82, \bar{X} = 50.68, \bar{Y} = 275.03, SXX = 67035, SST = 1678770, SXY = 335402$
חשב רווח חיזוי לתצפית חדשה עבורה ערך X הוא $x_0 = 40$
- ד. לו היינו משנים בסעיף הקודם את הנתון וערך X היה $x_0 = 45$, האם אורך הרווח היה גדול יותר או קטן יותר? נמק ללא חישובים

הערות עקרוניות: בסעיפים א-ב, ניתן להשתמש כמובן נוסחאות הרשומות בדף הנוסחאות. כמו כן, ניתן להשתמש בזהויות לגבי תוחלת שונות ושונות משותפת, כל עוד ציטטת אותם נכון.

בסעיף ד' אין לחשב מחדש רווח חיזוי ואז להשוות מספרים, אלא לתת נימוק עקרוני.


במקרה שהערך הדרוש מהטבלה לא מופיע בטבלה המצורפת, יש לבחור את הערך הקרוב ולציין זאת


שאלה 3 (28 נק': א-11, ב-9, ג-3, ד-3, ה-2)

גיל, משקל, גובה ו-10 מדידות היקף גוף נרשמו עבור 251 גברים. בנוסף אחוז השומן בגוף של כל אדם נאמד במדויק על ידי טכניקת שקילה מתחת למים. קובץ הנתונים מכיל את המשתנים הבאים:

Brozek - Percent body fat using Brozek's equation, $457/\text{Density} - 414.2$ (תלוי)
density - Density (gm/cm^3)
age - Age (yrs)
weight - Weight (lbs)
height - Height (inches)
adipos - Adiposity index = $\text{Weight}/\text{Height}^2$ (kg/m^2)
neck - Neck circumference (cm)
chest - Chest circumference (cm)
abdom - Abdomen circumference (cm) at the umbilicus and level with the iliac crest
hip - Hip circumference (cm)
thigh - Thigh circumference (cm)
knee - Knee circumference (cm)
ankle - Ankle circumference (cm)
biceps - Extended biceps circumference (cm)
forearm - Forearm circumference (cm)
wrist - Wrist circumference (cm) distal to the styloid processes

א. מה ניתן ללמוד מהתרשימים הבאים, על המודל והנחותיו? מה ניתן ללמוד על המולטי קולינאריות בין המנבאים השונים?





ב. חוקר התאים את הרגרסיה הבאה:


$\text{lm}(\text{brozek} \sim \text{age} + \text{weight} + \text{height} + \text{adipos} + \text{neck} + \text{chest} + \text{abdom} + \text{hip} + \text{thigh} + \text{knee} + \text{ankle} + \text{biceps} + \text{forearm} + \text{wrist})$





וקיבל את התוצאות הבאות:

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-49.73275	36.55914	-1.360	0.17502
age	0.05871	0.03007	1.952	0.05208
weight	-0.17327	0.10060	-1.722	0.08629
height	0.47077	0.50821	0.926	0.35523
adipos	0.77667	0.73440	1.058	0.29134
neck	-0.42834	0.21892	-1.957	0.05157
chest	-0.04253	0.09840	-0.432	0.66600
abdom	0.87034	0.08583	10.141	< 2e-16
hip	-0.22151	0.13816	-1.603	0.11020
thigh	0.23855	0.13594	1.755	0.08059
knee	-0.01276	0.23003	-0.055	0.95581
ankle	0.13557	0.20854	0.650	0.51625
biceps	0.15170	0.16002	0.948	0.34410
forearm	0.40486	0.18631	2.173	0.03077
wrist	-1.48070	0.49656	-2.982	0.00316

Residual standard error: 3.995 on 236 degrees of freedom
Multiple R-squared: 0.7475, Adjusted R-squared: 0.7325
F-statistic: 49.89 on 14 and 236 DF, p-value: < 2.2e-16







מה ניתן ללמוד הפלטים על נחיצות המסבירים? האם התוצאות מפתיעות ביחס לסעיף א' או עולות בקנה אחד עם הממצאים ב-א'? מה ניתן ללמוד על הנחות המודל? תצפיות חריגות?

ג. בעקבות הממצאים בשני הסעיפים הקודמים החוקרים החליטו להתאים מודל מעט שונה והתלבטו בין רגרסיית RIDGE ורגרסיית LASSO. מדוע הם עברו לאפיק זה? מה ההבדל בין שתי החלופות? במידה ונרצה גם לעשות גם "בחירת מודל" יחד עם התאמתו, איזו מהחלופות הייתם בוחרים (נמקו)?

ד. החוקר החליט להתאים רגרסיית LASSO וקיבל את הפלט הבא:



מה תהיה ההמלצה בעזרת פלטים אילו?

ה. החוקרים התאימו שני מודלים של רגרסיית LASSO, פעם אחת עם $\lambda=0.026$ ופעם שניה עם $\lambda=0.1$ וקבלו את התוצאות הבאות:

	OLS	LASSO $\lambda=0.026$	LASSO $\lambda=0.1$
(Intercept)	-49.7327	-12.9436	1.1784
age	0.0587	0.0548	0.0522
weight	-0.1733	-0.0655	0.0000
height	0.4708	-0.0888	-0.2621
adipos	0.7767	0.0000	0.0000
neck	-0.4283	-0.4121	-0.2657
chest	-0.0425	0.0000	0.0000
abdom	0.8703	0.8363	0.6612
hip	-0.2215	-0.1606	0.0000
thigh	0.2386	0.1813	0.0000
knee	-0.0128	0.0000	0.0000
ankle	0.1356	0.0973	0.0000
biceps	0.1517	0.1152	0.0000
forearm	0.4049	0.3931	0.2356

הסבירו את ההבדל בין התוצאות ואיך זה מתקשר לשני הסעיפים הראשונים של השאלה.

מודלים של רגרסיה לינארית - דף נוסחאות למבחן מסכם

הרגרסיה הפשוטה

המודל: $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$ כאשר $\varepsilon_i \sim N(0, \sigma^2)$ ב"ת.

X_i קבועים ידועים, $\beta_0, \beta_1, \sigma^2$ פרמטרים לא ידועים. Y_i נצפים.

$$SXX = \sum_{i=1}^n (X_i - \bar{X})^2, SXY = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$$
 סכומי ריבועים של המשתנים:

$$\hat{\beta}_1 = \frac{SXY}{SXX}, \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$
 אומדי הריבועים הפחותים:

$$Var(\hat{\beta}_1) = \frac{\sigma^2}{SXX}, Var(\hat{\beta}_0) = \frac{\sigma^2}{n} + \bar{X}^2 Var(\hat{\beta}_1)$$
 שוניות האומדים:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i = \bar{Y} + \hat{\beta}_1 (X_i - \bar{X})$$
 התחזיות:

$$SST = SSY, SSR = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2, SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$
 סכומי הריבועים במודל:

משוואות הנורמליות:

$$\sum_{i=1}^n e_i = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = 0$$

$$\sum_{i=1}^n e_i X_i = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) X_i = 0$$

$$MSE = \frac{SSE}{n-2} : \sigma^2 \text{ אחר"ל}$$

$$F = \frac{SSR}{MSE} \quad t_{\hat{\beta}_1} = \frac{\hat{\beta}_1}{\sqrt{MSE/SXX}}, t_{\hat{\beta}_0} = \frac{\hat{\beta}_0}{\sqrt{MSE\left(\frac{1}{n} + \frac{\bar{X}^2}{SXX}\right)}} : \text{סטטיסטיים}$$

רווח סמך לתוחלת תצפית חדשה עבורה ערך המשתנה המסביר הוא x_0 :

$$\bar{Y} + \hat{\beta}_1(x_0 - \bar{X}) \pm \sqrt{MSE\left(\frac{1}{n} + \frac{(x_0 - \bar{X})^2}{SXX}\right)} t_{(n-2, 1-\alpha/2)}$$

רווח חיזוי לתצפית חדשה עבורה ערך המשתנה המסביר הוא x_0 :

$$\bar{Y} + \hat{\beta}_1(x_0 - \bar{X}) \pm \sqrt{MSE\left(1 + \frac{1}{n} + \frac{(x_0 - \bar{X})^2}{SXX}\right)} t_{(n-2, 1-\alpha/2)}$$

מודל הרגרסיה המרובה

כאשר $Y_i = X_i\beta + \varepsilon_i$ הוא שורה באורך p .

בכתיבה מטריציונית: $Y = X\beta + \varepsilon$ כאשר $Y \in \mathbb{R}^n$ וקטור התצפיות, $\beta \in \mathbb{R}^p$ וקטור המקדמים, $X \in \mathbb{R}^{n \times p}$ מטריצת המשתנים המסבירים ו- $\varepsilon \in \mathbb{R}^n$ וקטור השגיאות, המקיים אותן הנחות כמו במודל הרגרסיה הפשוטה.

האר"פ $\hat{\beta} = (X^T X)^{-1} X^T Y$. מטריצת השוננויות המשותפות של האומדים: $Cov(\hat{\beta}) = \sigma^2 (X^T X)^{-1}$

וקטור התחזיות: $\hat{Y} = X\hat{\beta}$

סכומי ריבועים: $SSE = (Y - \hat{Y})^T (Y - \hat{Y})$, $SSR = \hat{Y}^T \hat{Y} - n\bar{Y}^2$, $SST = Y^T Y - n\bar{Y}^2$

הסקה על תוחלת תצפית עתידית $E(Y_0)$ (במודל עם חותר)

הסקה על הרמה הממוצעת של הפרטים המקיימים $\underline{X} = \underline{x}_0$, $\underline{C}^T = [1, \underline{x}_0^T]$

סטטיסטי המבחן:

$$t_{st} = \frac{C^T \hat{\beta} - C^T \beta|_{H_0}}{\sqrt{\hat{V}(C^T \hat{\beta})}}$$

$$V(C^T \hat{\beta}) = C^T V(\hat{\beta}) C = \sigma^2 C^T (X^T X)^{-1} C$$

ר"ס ברמת סמך $1-\alpha$ לתוחלת תצפית עתידית $E(Y_0)$: $E(Y_0) \in \underline{C}^T \hat{\beta} \pm t_{n-k-1, 1-\frac{\alpha}{2}} \sqrt{\hat{V}(\underline{C}^T \hat{\beta})}$

הסקה על תצפית עתידית Y_0 (במודל עם חותר)

נרצה לחזות את התגובה עבור פרט ספציפי אשר ערך המשתנה המסביר שלו הוא $\underline{x}_0$, נשתמש

בשארית $e_0 = Y_0 - \hat{Y}_0$ כך ש:

$$t_{st} = \frac{e_0 - 0}{\sqrt{\hat{V}(e_0)}} = \frac{(Y_0 - \hat{Y}_0) - 0}{\sqrt{\hat{\sigma}^2 (1 + \underline{C}^T (X^T X)^{-1} \underline{C})}}$$

רווח חיזוי ל- Y_0 (תצפית עתידית):

$$Y_0 \in \hat{Y}_0 \pm t_{n-k-1, 1-\frac{\alpha}{2}} \sqrt{\hat{V}(e_0)} = \underline{C}^T \hat{\beta} \pm t_{n-k-1, 1-\frac{\alpha}{2}} \sqrt{MSE \left(1 + \underline{C}^T (X^T X)^{-1} \underline{C} \right)}$$

השוואה בין מודל מלא ומודל חלקי באמצעות מבחן "F חלקי":

מודל חלקי (RM) - בעל p מקדמים ($p=k+1$)

מודל מלא (FM) - בעל $p+l$ מקדמים

-/ מספר המשתנים אותם נבחן להוצאה מהמודל

$$F_{1...l|l+1...l+p-1} = \frac{[SSR(X_1, \dots, X_k, X_{k+1}, \dots, X_{k+l}) - SSR(X_1, \dots, X_k)]/l}{SSE(X_1, \dots, X_k, X_{k+1}, \dots, X_{k+l})/(n-p-l)}$$

$$= \frac{[SSR(FM) - SSR(RM)]/l}{MSE(FM)} \sim F_{l, n-k-1}$$

מדדים לטיב מודל:

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \quad \text{מדד } R^2 \quad 1.$$

$$R_{adj}^2 = 1 - \frac{SSE/n-p}{SST/n-1} \quad \text{מדד } R_{adj}^2 \quad 2.$$

$$AIC = -2 \log(L) + 2p = n \ln(SSE/n) + 2p \quad \text{מדד AIC (מודל גרסיה)} \quad 3.$$

$$BIC = -2 \log(L) + \ln(n)p = n \ln(SSE/n) + \ln(n)p \quad \text{מדד BIC (מודל גרסיה)} \quad 4.$$

LOF

$$\sum_{j=1}^m \sum_{i=1}^{n_j} (Y_{ij} - \hat{Y}_j)^2 = \sum_{j=1}^m \sum_{i=1}^{n_j} (Y_{ij} - \bar{Y}_j)^2 + \sum_{j=1}^m n_j (\bar{Y}_j - \hat{Y}_j)^2$$

$$SSE = SSPE + SSLF$$

$$F_{st} = \frac{MSLF}{MSPE} = \frac{SSLF/n-m}{SSPE/m-2} \geq F_{m-2, n-m}^{1-\alpha}$$

גרסיה לוגיסטית

$\pi = \pi(X)$ - הסתברות להצלחה כתלות בווקטור המשתנים המסבירים X

$$\log\left(\frac{\pi(X_i)}{1-\pi(X_i)}\right) = X_i \beta \quad \text{המודל:}$$

בדיקת השערות לבדיקת ההשערה שחלק מה β הן 0:

$$H_0 : \beta_1 = \beta_2 = \dots \beta_l = 0$$


$$H_1 : ELSE$$

מבחן LRT

$$Dev = -2 \log(L(\hat{\beta})) \quad \text{כאשר } \chi_{st}^2 = Dev(RM) - Dev(FM) \sim \chi_l^2 \quad \text{הסטטיסטי הוא}$$


מבחן Wald: סטטיסטי מבוסס על תבניות ריבועיות של האומדים שברוח משפט קוקרן מפולגות חי בריבוע

התפלגות חי-ריבוע (בנקי וטבלה) דרגי χ^2



χ^2	0.005	0.010	0.025	0.050	0.100	0.250	0.500	0.750	0.900	0.950	0.975	0.990	0.995
1	0.003	0.015	0.082	0.393	0.158	0.102	0.455	1.32	2.71	3.84	5.02	6.63	7.88
2	0.010	0.020	0.054	0.103	0.211	0.575	1.39	2.77	4.61	5.99	7.38	9.21	10.6
3	0.017	0.036	0.084	0.216	0.352	1.21	2.37	4.11	6.58	7.81	9.35	11.3	12.8
4	0.027	0.054	0.136	0.284	0.484	1.06	3.36	5.39	7.78	9.49	11.1	13.3	14.9
5	0.042	0.084	0.234	0.378	0.711	0.831	4.35	6.63	9.24	11.1	12.8	15.1	16.7
6	0.078	0.136	0.344	0.558	1.064	0.988	5.35	7.88	10.6	12.6	14.4	16.8	18.5
7	0.189	0.270	0.475	0.872	1.24	1.68	6.35	9.04	12.0	14.1	16.0	18.5	20.3
8	0.338	0.468	0.675	1.24	1.68	2.17	7.34	10.2	13.4	15.5	17.5	20.1	22.0
9	0.558	0.738	1.064	1.64	2.20	2.83	8.34	11.4	14.7	16.9	19.0	21.7	23.6
10	0.872	1.16	1.60	2.17	2.83	3.58	9.34	12.5	16.0	18.3	20.5	23.2	25.2
11	1.357	1.85	2.60	3.05	3.82	4.58	10.3	13.7	17.3	19.7	21.9	24.7	26.8
12	1.903	2.60	3.57	4.40	5.40	6.30	11.3	14.8	18.5	21.0	23.3	26.2	28.3
13	2.601	3.57	4.91	5.89	6.94	7.94	12.3	16.0	19.8	22.4	24.7	27.7	29.8
14	3.49	4.66	5.68	6.75	7.79	8.81	13.3	17.1	21.1	23.7	26.1	29.1	31.3
15	4.60	5.62	6.58	7.70	8.65	9.79	14.3	18.2	22.3	25.0	27.5	30.6	32.8
16	5.14	6.25	7.26	8.36	9.31	10.9	15.3	19.4	23.5	26.3	28.8	32.0	34.3
17	5.70	6.90	7.99	8.91	10.0	11.9	16.3	20.5	24.8	27.6	30.2	33.4	35.7
18	6.26	7.59	8.67	9.59	10.6	12.8	17.3	21.6	26.0	28.9	31.5	34.8	37.2
19	6.84	8.28	9.35	10.1	11.7	13.7	18.3	22.7	27.2	30.1	32.9	36.2	38.6
20	7.43	8.90	9.99	10.9	12.4	14.6	19.3	23.8	28.4	31.4	34.2	37.6	40.0
21	8.03	9.54	10.6	11.8	13.2	15.5	20.3	24.9	29.6	32.7	35.5	38.9	41.4
22	8.64	10.2	11.3	12.3	14.0	16.3	21.3	26.0	30.8	33.9	36.8	40.3	42.8
23	9.26	10.9	12.0	13.1	14.8	17.2	22.3	27.1	32.0	35.2	38.1	41.6	44.2
24	9.89	11.6	12.7	13.8	15.7	18.0	23.3	28.2	33.2	36.4	39.4	43.0	45.6
25	10.6	12.4	13.4	14.6	16.6	18.9	24.3	29.3	34.4	37.7	40.6	44.3	46.9
26	11.2	13.1	14.1	15.4	17.3	20.8	25.3	30.4	35.6	38.9	41.9	45.6	48.3
27	11.8	13.8	14.8	16.2	18.1	21.7	26.3	31.6	36.7	40.1	43.2	47.0	49.6
28	12.5	14.5	15.5	16.9	18.9	22.7	27.3	32.6	37.9	41.3	44.5	48.3	51.0
29	13.1	15.2	16.2	17.7	19.8	23.6	28.3	33.7	39.1	42.6	45.7	50.0	52.3
30	13.8	16.0	16.8	18.5	20.6	24.5	29.3	34.8	40.3	43.8	47.0	50.9	53.7

לגות t של סטודנט (בגוף הטבלה - ערכי t)



P	.75	.90	.95	.975	.99	.995	.9995
0.1	1.000	3.078	6.314	12.706	31.821	63.657	636.619
0.2	.815	1.885	2.920	4.303	6.965	9.925	31.598
0.3	.765	1.638	2.353	3.182	4.541	5.841	12.941
0.4	.741	1.533	2.132	2.776	3.747	4.604	8.610
0.5	.727	1.476	2.015	2.571	3.365	4.032	6.859
0.6	.718	1.440	1.943	2.447	3.143	3.707	5.959
0.7	.711	1.415	1.895	2.365	2.998	3.499	5.405
0.8	.706	1.397	1.860	2.306	2.896	3.355	5.041
0.9	.703	1.383	1.833	2.262	2.821	3.250	4.781
1.0	.700	1.372	1.812	2.228	2.764	3.169	4.587
1.1	.697	1.363	1.796	2.201	2.718	3.106	4.437
1.2	.695	1.356	1.782	2.179	2.681	3.055	4.318
1.3	.694	1.350	1.771	2.160	2.650	3.012	4.221
1.4	.692	1.345	1.761	2.145	2.624	2.977	4.140
1.5	.691	1.341	1.753	2.131	2.602	2.947	4.073
1.6	.690	1.337	1.746	2.120	2.583	2.921	4.015
1.7	.689	1.333	1.740	2.110	2.567	2.898	3.965
1.8	.688	1.330	1.734	2.101	2.552	2.878	3.922
1.9	.688	1.328	1.729	2.093	2.539	2.861	3.883
2.0	.687	1.325	1.725	2.086	2.528	2.845	3.850
2.1	.686	1.323	1.721	2.080	2.518	2.831	3.819
2.2	.686	1.321	1.717	2.074	2.508	2.819	3.792
2.3	.685	1.319	1.714	2.069	2.500	2.807	3.767
2.4	.685	1.318	1.711	2.064	2.492	2.797	3.745
2.5	.684	1.316	1.708	2.060	2.485	2.787	3.725
2.6	.684	1.315	1.706	2.056	2.479	2.779	3.707
2.7	.684	1.314	1.703	2.052	2.473	2.771	3.690
2.8	.683	1.313	1.701	2.048	2.467	2.763	3.674
2.9	.683	1.311	1.699	2.045	2.462	2.756	3.659
3.0	.683	1.310	1.697	2.042	2.457	2.750	3.646
4.0	.681	1.303	1.684	2.021	2.423	2.704	3.551
6.0	.679	1.296	1.671	2.000	2.390	2.660	3.460
12.0	.677	1.289	1.658	1.980	2.358	2.617	3.373
∞	.674	1.282	1.645	1.960	2.326	2.576	3.291

F - Distribution ($\alpha = 0.05$ in the Right Tail)

df ₂	df ₁	Numerator Degrees of Freedom								
		1	2	3	4	5	6	7	8	9
Denominator Degrees of Freedom	1	161.45	199.50	215.71	224.58	230.16	233.99	236.77	238.88	240.54
	2	18.513	19.000	19.164	19.247	19.296	19.330	19.353	19.371	19.385
	3	10.128	9.5521	9.2766	9.1172	9.0135	8.9406	8.8867	8.8452	8.8123
	4	7.7086	9.9443	6.5914	6.3882	6.2561	6.1631	6.0942	6.0410	6.9988
	5	6.6079	5.7861	5.4095	5.1922	5.0503	4.9503	4.8759	4.8183	4.7725
	6	5.9874	5.1433	4.7571	4.5337	4.3874	4.2839	4.2067	4.1468	4.0990
	7	5.5914	4.7374	4.3468	4.1203	3.9715	3.8660	3.7870	3.7257	3.6767
	8	5.3177	4.4590	4.0662	3.8379	3.6875	3.5806	3.5005	3.4381	3.3881
	9	5.1174	4.2565	3.8625	3.6331	3.4817	3.3738	3.2927	3.2296	3.1789
	10	4.9646	4.1028	3.7083	3.4780	3.3258	3.2172	3.1355	3.0717	3.0204
	11	4.8443	3.9823	3.5874	3.3567	3.2039	3.0946	3.0123	2.9480	2.8962
	12	4.7472	3.8853	3.4903	3.2592	3.1059	2.9961	2.9134	2.8486	2.7964
	13	4.6672	3.8056	3.4105	3.1791	3.0254	2.9153	2.8321	2.7669	2.7144
	14	4.6001	3.7389	3.3439	3.1122	2.9582	2.8477	2.7642	2.6987	2.6458
	15	4.5431	3.6823	3.2874	3.0556	2.9013	2.7905	2.7066	2.6408	2.5876
	16	4.4940	3.6337	3.2389	3.0069	2.8524	2.7413	2.6572	2.5911	2.5377
	17	4.4513	3.5915	3.1968	2.9647	2.8100	2.6987	2.6143	2.5480	2.4943
	18	4.4139	3.5546	3.1599	2.9277	2.7729	2.6613	2.5767	2.5102	2.4563
	19	4.3807	3.5219	3.1274	2.8951	2.7401	2.6283	2.5435	2.4768	2.4227
	20	4.3512	3.4928	3.0984	2.8661	2.7109	2.5990	2.5140	2.4471	2.3928
	21	4.3248	3.4668	3.0725	2.8401	2.6848	2.5727	2.4876	2.4205	2.3660
	22	4.3009	3.4434	3.0491	2.8167	2.6613	2.5491	2.4638	2.3965	2.3419
	23	4.2793	3.4221	3.0280	2.7955	2.6400	2.5277	2.4422	2.3748	2.3201
	24	4.2597	3.4028	3.0088	2.7763	2.6207	2.5082	2.4226	2.3551	2.3002
	25	4.2417	3.3852	2.9912	2.7587	2.6030	2.4904	2.4047	2.3371	2.2821
	26	4.2252	3.3690	2.9752	2.7426	2.5868	2.4741	2.3883	2.3205	2.2655
	27	4.2100	3.3541	2.9604	2.7278	2.5719	2.4591	2.3732	2.3053	2.2501
	28	4.1960	3.3404	2.9467	2.7141	2.5581	2.4453	2.3593	2.2913	2.2360
	29	4.1830	3.3277	2.9340	2.7014	2.5454	2.4324	2.3463	2.2783	2.2229
	30	4.1709	3.3158	2.9223	2.6896	2.5336	2.4205	2.3343	2.2662	2.2107
	40	4.0847	3.2317	2.8387	2.6060	2.4495	2.3359	2.2490	2.1802	2.1240
	60	4.0012	3.1504	2.7581	2.5252	2.3683	2.2541	2.1665	2.0970	2.0401
	120	3.9201	3.0718	2.6802	2.4472	2.2899	2.1750	2.0868	2.0164	1.9588
	∞	3.8415	2.9957	2.6049	2.3719	2.2141	2.0986	2.0096	1.9384	1.8799

F - Distribution ($\alpha = 0.05$ in the Right Tail)

Denominator Degrees of Freedom	df ₂	Numerator Degrees of Freedom									
		df ₁ 10	12	15	20	24	30	40	60	120	∞
1	241.88	243.91	245.95	248.01	249.05	250.10	251.14	252.20	253.25	254.31	
2	19.396	19.413	19.429	19.446	19.454	19.462	19.471	19.479	19.487	19.496	
3	8.7855	8.7446	8.7029	8.6602	8.6385	8.6166	8.5944	8.5720	8.5494	8.5264	
4	5.9644	5.9117	5.8578	5.8025	5.7744	5.7459	5.7170	5.6877	5.6581	5.6281	
5	4.7351	4.6777	4.6188	4.5581	4.5272	4.4957	4.4638	4.4314	4.3985	4.3650	
6	4.0600	3.9999	3.9381	3.8742	3.8415	3.8082	3.7743	3.7398	3.7047	3.6689	
7	3.6365	3.5747	3.5107	3.4445	3.4105	3.3758	3.3404	3.3043	3.2674	3.2298	
8	3.3472	3.2839	3.2184	3.1503	3.1152	3.0794	3.0428	3.0053	2.9669	2.9276	
9	3.1373	3.0729	3.0061	2.9365	2.9005	2.8637	2.8259	2.7872	2.7475	2.7067	
10	2.9782	2.9130	2.8450	2.7740	2.7372	2.6996	2.6609	2.6211	2.5801	2.5379	
11	2.8536	2.7876	2.7186	2.6464	2.6090	2.5705	2.5309	2.4901	2.4480	2.4045	
12	2.7534	2.6866	2.6169	2.5436	2.5055	2.4663	2.4259	2.3842	2.3410	2.2962	
13	2.6710	2.6037	2.5331	2.4589	2.4202	2.3803	2.3392	2.2966	2.2524	2.2064	
14	2.6022	2.5342	2.4630	2.3879	2.3487	2.3082	2.2664	2.2229	2.1778	2.1307	
15	2.5437	2.4753	2.4034	2.3275	2.2878	2.2468	2.2043	2.1601	2.1141	2.0658	
16	2.4935	2.4247	2.3522	2.2756	2.2354	2.1938	2.1507	2.1058	2.0589	2.0096	
17	2.4499	2.3807	2.3077	2.2304	2.1898	2.1477	2.1040	2.0584	2.0107	1.9604	
18	2.4117	2.3421	2.2686	2.1906	2.1497	2.1071	2.0629	2.0166	1.9681	1.9168	
19	2.3779	2.3080	2.2341	2.1555	2.1141	2.0712	2.0264	1.9795	1.9302	1.8780	
20	2.3479	2.2776	2.2033	2.1242	2.0825	2.0391	1.9938	1.9464	1.8963	1.8432	
21	2.3210	2.2504	2.1757	2.0960	2.0540	2.0102	1.9645	1.9165	1.8657	1.8117	
22	2.2967	2.2258	2.1508	2.0707	2.0283	1.9842	1.9380	1.8894	1.8380	1.7831	
23	2.2747	2.2036	2.1282	2.0476	2.0050	1.9605	1.9139	1.8648	1.8128	1.7570	
24	2.2547	2.1834	2.1077	2.0267	1.9838	1.9390	1.8920	1.8424	1.7896	1.7330	
25	2.2365	2.1649	2.0889	2.0075	1.9643	1.9192	1.8718	1.8217	1.7684	1.7110	
26	2.2197	2.1479	2.0716	1.9898	1.9464	1.9010	1.8533	1.8027	1.7488	1.6906	
27	2.2043	2.1323	2.0558	1.9736	1.9299	1.8842	1.8361	1.7851	1.7306	1.6717	
28	2.1900	2.1179	2.0411	1.9586	1.9147	1.8687	1.8203	1.7689	1.7138	1.6541	
29	2.1768	2.1045	2.0275	1.9446	1.9005	1.8543	1.8055	1.7537	1.6981	1.6376	
30	2.1646	2.0921	2.0148	1.9317	1.8874	1.8409	1.7918	1.7396	1.6835	1.6223	
40	2.0772	2.0035	1.9245	1.8389	1.7929	1.7444	1.6928	1.6373	1.5766	1.5089	
60	1.9926	1.9174	1.8364	1.7480	1.7001	1.6491	1.5943	1.5343	1.4673	1.3893	
120	1.9105	1.8337	1.7505	1.6587	1.6084	1.5543	1.4952	1.4290	1.3519	1.2539	
∞	1.8307	1.7522	1.6664	1.5705	1.5173	1.4591	1.3940	1.3180	1.2214	1.0000	