

20.2.2025

ד"ר יקיר ברצ'נקו

מודלים של רגרסיה ליניארית

364-1-1061

שלוש שעות

מחשבון (טבלאות סטטיסטיות ודפי נוסחאות מצורפים)

תאריך הבחינה:

המרצה:

שם הקורס:

מספר קורס:

משך הבחינה:

חומר עזר:

מיועד לתלמידי הנדסת תעשייה וניהול.

שנה: 2025 סמסטר: א' מועד: א'

הנחיות חשובות:

- במבחן זה שלוש שאלות
- יש לפתור את כל השאלות, סך הנקודות עשוי להגיע ל-108, אך הציון הסופי המקסימלי במבחן הינו 100.
- יש ללוות את דרך הפתרון בהסברים מילוליים קצרים
- ניתן להשתמש בכל הנוסחאות והתוצאות שפותחו או הוצגו בכיתה ואין צורך להוכיח מחדש אלא אם כן זה נדרש במפורש

יש לכתוב את כל התשובות במחברת ולא על גיליון המבחן.

שאלה 1 (40 נקודות)

מאמן כושר העביר לחברת-ייעוץ טבלת נתונים במטרה לחקור את הקשר שבין **מרחק (מטרים)** ומשך הריצה (**דקות**) לבין כמות הקלוריות הנשרפות בזמן הריצה (**קילו-קלוריות בדקה**). לאחר מכן, התאים היועץ דני מודל רגרסיה מרובה על סמך 80 תצפיות וקיבל הפלט הבא:

```
lm(formula = cal ~ dist + time)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-91.826240	8.204333	-11.19	<2e-16***
dist	0.063619	0.002259	28.17	<2e-16***
time	1.314600	0.101810	12.91	<2e-16***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 24.08 on 77 degrees of freedom

Multiple R-squared: 0.9168, Adjusted R-squared: 0.9146

F-statistic: 424.1 on 2 and 77 DF, p-value: < 2.2e-16

היועצת רונית, הציגה מודל רגרסיה מרובה אחר, וקיבלה הפלט הבא:

```
lm(formula = cal ~ poly(dist, 2))
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	132.221	4.521	29.244	< 2e-16***
poly(dist, 2)1	628.605	40.440	15.544	< 2e-16***
poly(dist, 2)2	124.119	40.440	3.069	0.00296 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 40.44 on 77 degrees of freedom

Multiple R-squared: 0.7653, Adjusted R-squared: 0.7592

F-statistic: 125.5 on 2 and 77 DF, p-value: < 2.2e-16

א. (10 נקודות) מי לדעתכם צודק? הסתמכו על המדד/ים הרלוונטיים המופיעים בפלטים.

עידו, חברם בחברת הייעוץ, החליט לדבוק בפשטות והתאים מודל רגרסיה פשוטה למידול הקשר בין מרחק הריצה (x) לכמות הקלוריות הנשרפות (y). עבור המודל של עידו נתון כי $SST = 1410601$, וכן:


$$\sum_{i=1}^{80} x_i = 234294 \quad \sum_{i=1}^{80} x_i^2 = 804618562 \quad \sum_{i=1}^{80} y_i = 10577 \quad \sum_{i=1}^{80} y_i^2 = 1935077 \quad \sum_{i=1}^{80} x_i y_i = 37820014$$

- ב. (10 נקודות) חשבו האר"פים ואת סכומי ריבועי הרגרסיה במודל של עידו. כתבו המודל בצורה מפורשת.
 ג. (10 נקודות) בחנו בר"מ של 5% איזה מודל עדיף, המודל של רונית או המודל של עידו?
 ד. (10 נקודות) ניר, סטטיסטיקאי ומומחה לכושר-גופני, הגיע לבקר את חברו דני. ניר הביט במודל של דני ומיד העיר:
 "התוצאות שקיבלת משונות מאוד. פיזיולוגיה בסיסית ואמרת שריצה מהירה היא יותר מאומצת ושורפת יותר קלוריות".
 מדוע גרם לניר לחשוד? ומה יכול להיות מקור הבעיה (ומה הדבר הראשון שהייתם בודקים עם הלקוח מאמן הכושר)?
 רמז: עבור ההסבר הפשוט ביותר שימו לב למודגש בשאלה.

שאלה 2 (39 נקודות)

ענו על הסעיפים הבאים.

- א. האם איור 1 יכול להיות תרשים שאריות (אחרי רגרסיה פשוטה של y על x)? הסבירו את תשובתכם בקצרה.
 ב. טום טוען: "אם מתקבל תרשים שאריות שנראה כמו פרבולה (בדומה לאיור 1) אז בהכרח הקשר האמיתי בין x ל- y הוא לא-מונוטוני". האם טום צודק? ענו הסבירו בקצרה (ניתן ואף רצוי בעזרת איור).
 ג. בהמשך לסעיף הקודם, ענו על אחד מהסעיפים הבאים:
 ג1. אם עניתם בסעיף ב' "בהכרח לא-מונוטוני" אז כיצד תתקנו את הרגרסיה?
 ג2. אם עניתם בסעיף ב' "לא בהכרח לא-מונוטוני" אז כיצד תתקנו את הרגרסיה?



איור 1.

שאלה 3 (29 נקודות)

השאלה הבאה עוסקת במודל רגרסיה מרובה:

$$y_i = \beta_0 + \beta_1 x_{i,1} + \beta_2 x_{i,2} + \beta_3 x_{i,3} \dots + \beta_p x_{i,p} + \varepsilon_i$$


כאשר כל ε_i בלתי-תלוי באחרים, עם תוחלת 0. השונויות של השגיאות, ε_i , אינן שוות, ולכל ε_i יש שונות σ_i^2 אשר ידועה לנו.

נסמן את המטריצה האלכסונית $\text{Var}(\varepsilon) = \Sigma = \text{diag}(\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2)$ ובאופן דומה את המטריצה האלכסונית $K = \Sigma^{-1} = \text{diag}(1/\sigma_1^2, 1/\sigma_2^2, \dots, 1/\sigma_n^2)$. בעזרת K נגדיר אומד חדש ל- β :

$$\hat{\beta}_{WLS} = (X^T K X)^{-1} X^T K Y$$

- הראו שאומד הריבועים-הפחותים הרגיל ל- β (שנסמנו $\hat{\beta}_{OLS}$), עדיין חסר-הטיה. (7 נקודות)
 - מה היא (מטריצת) השונות של האומד החדש $\hat{\beta}_{WLS}$? נמקו. (7 נקודות)
 - הראו שהשונות של $\hat{\beta}_{WLS}$ יותר קטנה מאשר השונות של $\hat{\beta}_{OLS}$. (15 נקודות)
- רמז: יתכן שאתם מתכננים כעת למצוא את השונות של $\hat{\beta}_{OLS}$ ולהשוות בינהן, אבל אולי עדיף לנסות משהו יותר שאפתני וכללי! שימו לב ששני האומדים הינם אומדים לינאריים חסרי-הטיה, ונסו להכליל תוצאה שראינו.

בהצלחה!!!

TABLE	PERCENTILE VALUES (t_p) FOR STUDENT'S t DISTRIBUTION with n degrees of freedom (shaded area = p)	
-------	--	---

n	$t_{.995}$	$t_{.99}$	$t_{.975}$	$t_{.95}$	$t_{.90}$	$t_{.80}$	$t_{.75}$	$t_{.70}$	$t_{.60}$	$t_{.55}$
1	63.66	31.82	12.71	6.31	3.08	1.376	1.000	.727	.325	.158
2	9.92	6.96	4.30	2.92	1.89	1.061	.816	.617	.289	.142
3	5.84	4.54	3.18	2.35	1.64	.978	.765	.584	.277	.137
4	4.60	3.75	2.78	2.13	1.53	.941	.741	.569	.271	.134
5	4.03	3.36	2.57	2.02	1.48	.920	.727	.559	.267	.132
6	3.71	3.14	2.45	1.94	1.44	.906	.718	.553	.265	.131
7	3.50	3.00	2.36	1.90	1.42	.896	.711	.549	.263	.130
8	3.36	2.90	2.31	1.86	1.40	.889	.706	.546	.262	.130
9	3.25	2.82	2.26	1.83	1.38	.883	.703	.543	.261	.129
10	3.17	2.76	2.23	1.81	1.37	.879	.700	.542	.260	.129
11	3.11	2.72	2.20	1.80	1.36	.876	.697	.540	.260	.129
12	3.06	2.68	2.18	1.78	1.36	.873	.695	.539	.259	.128
13	3.01	2.65	2.16	1.77	1.35	.870	.694	.538	.259	.128
14	2.98	2.62	2.14	1.76	1.34	.868	.692	.537	.258	.128
15	2.95	2.60	2.13	1.75	1.34	.866	.691	.536	.258	.128
16	2.92	2.58	2.12	1.75	1.34	.865	.690	.535	.258	.128
17	2.90	2.57	2.11	1.74	1.33	.863	.689	.534	.257	.128
18	2.88	2.55	2.10	1.73	1.33	.862	.688	.534	.257	.127
19	2.86	2.54	2.09	1.73	1.33	.861	.688	.533	.257	.127
20	2.84	2.53	2.09	1.72	1.32	.860	.687	.533	.257	.127
21	2.83	2.52	2.08	1.72	1.32	.859	.686	.532	.257	.127
22	2.82	2.51	2.07	1.72	1.32	.858	.686	.532	.256	.127
23	2.81	2.50	2.07	1.71	1.32	.858	.685	.532	.256	.127
24	2.80	2.49	2.06	1.71	1.32	.857	.685	.531	.256	.127
25	2.79	2.48	2.06	1.71	1.32	.856	.684	.531	.256	.127
26	2.78	2.48	2.06	1.71	1.32	.856	.684	.531	.256	.127
27	2.77	2.47	2.05	1.70	1.31	.855	.684	.531	.256	.127
28	2.76	2.47	2.05	1.70	1.31	.855	.683	.530	.256	.127
29	2.76	2.46	2.04	1.70	1.31	.854	.683	.530	.256	.127
30	2.75	2.46	2.04	1.70	1.31	.854	.683	.530	.256	.127
40	2.70	2.42	2.02	1.68	1.30	.851	.681	.529	.255	.126
60	2.66	2.39	2.00	1.67	1.30	.848	.679	.527	.254	.126
120	2.62	2.36	1.98	1.66	1.29	.845	.677	.526	.254	.126
∞	2.58	2.33	1.96	1.645	1.28	.842	.674	.524	.253	.126

טבלת התפלגות F עבור $\alpha = 0.05$

df2/df1	1	2	3	4	5	6	7	8	9	10	12	15	20	24	30	40	60	120	INF
1	161.448	199.5	215.707	224.583	230.162	233.99	236.768	238.883	240.543	241.882	243.91	245.95	248.013	249.052	250.095	251.143	252.196	253.253	254.314
2	18.5128	19	19.1643	19.2468	19.2964	19.33	19.3532	19.371	19.3848	19.3959	19.413	19.4291	19.4458	19.4541	19.4624	19.4707	19.4791	19.4874	19.4957
3	10.128	9.552	9.2766	9.1172	9.0135	8.9406	8.8867	8.8452	8.8123	8.7855	8.7446	8.7029	8.6602	8.6385	8.6166	8.5944	8.572	8.5494	8.5264
4	7.7086	6.944	6.5914	6.3882	6.2561	6.1631	6.0942	6.041	5.9988	5.9644	5.9117	5.8578	5.8025	5.7744	5.7459	5.717	5.6877	5.6581	5.6281
5	6.6079	5.786	5.4095	5.1922	5.0503	4.9503	4.8759	4.8183	4.7725	4.7351	4.6777	4.6188	4.5581	4.5272	4.4957	4.4638	4.4314	4.3985	4.365
6	5.9874	5.143	4.7571	4.5337	4.3874	4.2839	4.2067	4.1468	4.099	4.06	3.9999	3.9381	3.8742	3.8415	3.8082	3.7743	3.7398	3.7047	3.6689
7	5.5914	4.737	4.3468	4.1203	3.9715	3.866	3.787	3.7257	3.6767	3.6365	3.5747	3.5107	3.4445	3.4105	3.3758	3.3404	3.3043	3.2674	3.2298
8	5.3177	4.459	4.0662	3.8379	3.6875	3.5806	3.5005	3.4381	3.3881	3.3472	3.2839	3.2184	3.1503	3.1152	3.0794	3.0428	3.0053	2.9669	2.9276
9	5.1174	4.257	3.8625	3.6331	3.4817	3.3738	3.2927	3.2296	3.1789	3.1373	3.0729	3.0061	2.9365	2.9005	2.8637	2.8259	2.7872	2.7475	2.7067
10	4.9646	4.103	3.7083	3.478	3.3258	3.2172	3.1355	3.0717	3.0204	2.9782	2.913	2.845	2.774	2.7372	2.6996	2.6609	2.6211	2.5801	2.5379
11	4.8443	3.982	3.5874	3.3567	3.2039	3.0946	3.0123	2.948	2.8962	2.8536	2.7876	2.7186	2.6464	2.609	2.5705	2.5309	2.4901	2.448	2.4045
12	4.7472	3.885	3.4903	3.2592	3.1059	2.9961	2.9134	2.8486	2.7964	2.7534	2.6866	2.6169	2.5436	2.5055	2.4663	2.4259	2.3842	2.341	2.2962
13	4.6672	3.806	3.4105	3.1791	3.0254	2.9153	2.8321	2.7669	2.7144	2.671	2.6037	2.5331	2.4589	2.4202	2.3803	2.3392	2.2966	2.2524	2.2064
14	4.6001	3.739	3.3439	3.1122	2.9582	2.8477	2.7642	2.6987	2.6458	2.6022	2.5342	2.463	2.3879	2.3487	2.3082	2.2664	2.2229	2.1778	2.1307
15	4.5431	3.682	3.2874	3.0556	2.9013	2.7905	2.7066	2.6408	2.5876	2.5437	2.4753	2.4034	2.3275	2.2878	2.2468	2.2043	2.1601	2.1141	2.0658
16	4.494	3.634	3.2389	3.0069	2.8524	2.7413	2.6572	2.5911	2.5377	2.4935	2.4247	2.3522	2.2756	2.2354	2.1938	2.1507	2.1058	2.0589	2.0096
17	4.4513	3.592	3.1968	2.9647	2.81	2.6987	2.6143	2.548	2.4943	2.4499	2.3807	2.3077	2.2304	2.1898	2.1477	2.104	2.0584	2.0107	1.9604
18	4.4139	3.555	3.1599	2.9277	2.7729	2.6613	2.5767	2.5102	2.4563	2.4117	2.3421	2.2686	2.1906	2.1497	2.1071	2.0629	2.0166	1.9681	1.9168
19	4.3807	3.522	3.1274	2.8951	2.7401	2.6283	2.5435	2.4768	2.4227	2.3779	2.308	2.2341	2.1555	2.1141	2.0712	2.0264	1.9795	1.9302	1.878
20	4.3512	3.493	3.0984	2.8661	2.7109	2.599	2.514	2.4471	2.3928	2.3479	2.2776	2.2033	2.1242	2.0825	2.0391	1.9938	1.9464	1.8963	1.8432
21	4.3248	3.467	3.0725	2.8401	2.6848	2.5727	2.4876	2.4205	2.366	2.321	2.2504	2.1757	2.096	2.054	2.0102	1.9645	1.9165	1.8657	1.8117
22	4.3009	3.443	3.0491	2.8167	2.6613	2.5491	2.4638	2.3965	2.3419	2.2967	2.2258	2.1508	2.0707	2.0283	1.9842	1.938	1.8894	1.838	1.7831
23	4.2793	3.422	3.028	2.7955	2.64	2.5277	2.4422	2.3748	2.3201	2.2747	2.2036	2.1282	2.0476	2.005	1.9605	1.9139	1.8648	1.8128	1.757
24	4.2597	3.403	3.0088	2.7763	2.6207	2.5082	2.4226	2.3551	2.3002	2.2547	2.1834	2.1077	2.0267	1.9838	1.939	1.892	1.8424	1.7896	1.733
25	4.2417	3.385	2.9912	2.7587	2.603	2.4904	2.4047	2.3371	2.2821	2.2365	2.1649	2.0889	2.0075	1.9643	1.9192	1.8718	1.8217	1.7684	1.711
26	4.2252	3.369	2.9752	2.7426	2.5868	2.4741	2.3883	2.3205	2.2655	2.2197	2.1479	2.0716	1.9898	1.9464	1.901	1.8533	1.8027	1.7488	1.6906
27	4.21	3.354	2.9604	2.7278	2.5719	2.4591	2.3732	2.3053	2.2501	2.2043	2.1323	2.0558	1.9736	1.9299	1.8842	1.8361	1.7851	1.7306	1.6717
28	4.196	3.34	2.9467	2.7141	2.5581	2.4453	2.3593	2.2913	2.236	2.19	2.1179	2.0411	1.9586	1.9147	1.8687	1.8203	1.7689	1.7138	1.6541
29	4.183	3.328	2.934	2.7014	2.5454	2.4324	2.3463	2.2783	2.2229	2.1768	2.1045	2.0275	1.9446	1.9005	1.8543	1.8055	1.7537	1.6981	1.6376
30	4.1709	3.316	2.9223	2.6896	2.5336	2.4205	2.3343	2.2662	2.2107	2.1646	2.0921	2.0148	1.9317	1.8874	1.8409	1.7918	1.7396	1.6835	1.6223
40	4.0847	3.232	2.8387	2.606	2.4495	2.3359	2.249	2.1802	2.124	2.0772	2.0035	1.9245	1.8389	1.7929	1.7444	1.6928	1.6373	1.5766	1.5089
60	4.0012	3.15	2.7581	2.5252	2.3683	2.2541	2.1665	2.097	2.0401	1.9926	1.9174	1.8364	1.748	1.7001	1.6491	1.5943	1.5343	1.4673	1.3893
120	3.9201	3.072	2.6802	2.4472	2.2899	2.175	2.0868	2.0164	1.9588	1.9105	1.8337	1.7505	1.6587	1.6084	1.5543	1.4952	1.429	1.3519	1.2539
inf	3.8415	2.996	2.6049	2.3719	2.2141	2.0986	2.0096	1.9384	1.8799	1.8307	1.7522	1.6664	1.5705	1.5173	1.4591	1.394	1.318	1.2214	1

טבלת F עבור $\alpha = 0.025$

120	60	40	30	24	20	15	12	10	9	8	7	6	5	4	3	2	df1=1	/
1014	1010	1006	1001	997.2	993.1	984.9	976.7	968.6	963.3	956.7	948.2	937.1	921.8	899.6	864.2	799.5	647.8	df1=1
39.49	39.48	39.47	39.47	39.46	39.45	39.43	39.41	39.4	39.39	39.37	39.36	39.33	39.3	39.25	39.17	39	38.51	2
13.95	13.99	14.04	14.08	14.12	14.17	14.25	14.34	14.42	14.47	14.54	14.62	14.73	14.88	15.1	15.44	16.04	17.44	3
8.309	8.36	8.411	8.461	8.511	8.56	8.657	8.751	8.844	8.905	8.98	9.074	9.197	9.365	9.605	9.979	10.65	12.22	4
6.069	6.123	6.175	6.227	6.278	6.329	6.428	6.525	6.619	6.681	6.757	6.853	6.978	7.146	7.388	7.764	8.434	10.01	5
4.904	4.959	5.012	5.065	5.117	5.168	5.269	5.366	5.461	5.523	5.6	5.696	5.82	5.988	6.227	6.599	7.26	8.813	6
4.199	4.254	4.309	4.362	4.415	4.467	4.568	4.666	4.761	4.823	4.899	4.995	5.119	5.285	5.523	5.89	6.542	8.073	7
3.728	3.784	3.84	3.894	3.947	4	4.101	4.2	4.295	4.357	4.433	4.529	4.652	4.817	5.053	5.416	6.06	7.571	8
3.392	3.449	3.505	3.56	3.614	3.667	3.769	3.868	3.964	4.026	4.102	4.197	4.32	4.484	4.718	5.078	5.715	7.209	9
3.14	3.198	3.255	3.311	3.365	3.419	3.522	3.621	3.717	3.779	3.855	3.95	4.072	4.236	4.468	4.826	5.456	6.937	10
2.944	3.004	3.061	3.118	3.173	3.226	3.33	3.43	3.526	3.588	3.664	3.759	3.881	4.044	4.275	4.63	5.256	6.724	11
2.787	2.848	2.906	2.963	3.019	3.073	3.177	3.277	3.374	3.436	3.512	3.607	3.728	3.891	4.121	4.474	5.096	6.554	12
2.659	2.72	2.78	2.837	2.893	2.948	3.053	3.153	3.25	3.312	3.388	3.483	3.604	3.767	3.996	4.347	4.965	6.414	13
2.552	2.614	2.674	2.732	2.789	2.844	2.949	3.05	3.147	3.209	3.285	3.38	3.501	3.663	3.892	4.242	4.857	6.298	14
2.461	2.524	2.585	2.644	2.701	2.756	2.862	2.963	3.06	3.123	3.199	3.293	3.415	3.576	3.804	4.153	4.765	6.2	15
2.383	2.447	2.509	2.568	2.625	2.681	2.788	2.889	2.986	3.049	3.125	3.219	3.341	3.502	3.729	4.077	4.687	6.115	16
2.315	2.38	2.442	2.502	2.56	2.616	2.723	2.825	2.922	2.985	3.061	3.156	3.277	3.438	3.665	4.011	4.619	6.042	17
2.256	2.321	2.384	2.445	2.503	2.559	2.667	2.769	2.866	2.929	3.005	3.1	3.221	3.382	3.608	3.954	4.56	5.978	18
2.203	2.27	2.333	2.394	2.452	2.509	2.617	2.72	2.817	2.88	2.956	3.051	3.172	3.333	3.559	3.903	4.508	5.922	19
2.156	2.223	2.287	2.349	2.408	2.465	2.573	2.676	2.774	2.837	2.913	3.007	3.128	3.289	3.515	3.859	4.461	5.872	20
2.114	2.182	2.246	2.308	2.368	2.425	2.534	2.637	2.735	2.798	2.874	2.969	3.09	3.25	3.475	3.819	4.42	5.827	21
2.076	2.145	2.21	2.272	2.332	2.389	2.498	2.602	2.7	2.763	2.839	2.934	3.055	3.215	3.44	3.783	4.383	5.786	22
2.041	2.111	2.176	2.239	2.299	2.357	2.467	2.57	2.668	2.731	2.808	2.902	3.023	3.184	3.408	3.751	4.349	5.75	23
2.01	2.08	2.146	2.209	2.269	2.327	2.437	2.541	2.64	2.703	2.779	2.874	2.995	3.155	3.379	3.721	4.319	5.717	24
1.981	2.052	2.118	2.182	2.242	2.301	2.411	2.515	2.614	2.677	2.753	2.848	2.969	3.129	3.353	3.694	4.291	5.686	25
1.954	2.026	2.093	2.157	2.217	2.276	2.387	2.491	2.59	2.653	2.729	2.824	2.945	3.105	3.329	3.67	4.266	5.659	26
1.93	2.002	2.069	2.133	2.195	2.253	2.364	2.469	2.568	2.631	2.707	2.802	2.923	3.083	3.307	3.647	4.242	5.633	27
1.907	1.98	2.048	2.112	2.174	2.232	2.344	2.448	2.547	2.611	2.687	2.782	2.903	3.063	3.286	3.626	4.221	5.61	28
1.886	1.959	2.028	2.092	2.154	2.213	2.325	2.43	2.529	2.592	2.669	2.763	2.884	3.044	3.267	3.607	4.201	5.588	29
1.866	1.94	2.009	2.074	2.136	2.195	2.307	2.412	2.511	2.575	2.651	2.746	2.867	3.027	3.25	3.589	4.182	5.568	30
1.724	1.803	1.875	1.943	2.007	2.068	2.182	2.288	2.388	2.452	2.529	2.624	2.744	2.904	3.126	3.463	4.051	5.424	40
1.581	1.667	1.744	1.815	1.882	1.945	2.061	2.169	2.27	2.334	2.412	2.507	2.627	2.786	3.008	3.343	3.925	5.286	60
1.433	1.53	1.614	1.69	1.76	1.825	1.945	2.055	2.157	2.222	2.299	2.395	2.515	2.674	2.894	3.227	3.805	5.152	120

$$COV(X, Y) = E[(X - \mu_x)(Y - \mu_y)] = E(XY) - \mu_x \mu_y$$

$$COV(X, Y) = COV(Y, X)$$

$$COV(aX + b, cY + d) = acCOV(X, Y)$$

$$COV(X + Y, Z) = COV(X, Z) + COV(Y, Z)$$

מקדם מתאם

$$\rho(X, Y) = \frac{COV(X, Y)}{\sqrt{V(X)}\sqrt{V(Y)}}$$

נוסחאות

$$SXY = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n (x_i - \bar{x})y_i = \sum_{i=1}^n (y_i - \bar{y})x_i = \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}$$

$$SXX = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n (x_i - \bar{x})x_i = \sum_{i=1}^n x_i^2 - n\bar{x}^2$$

$$SYX = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (y_i - \bar{y})y_i = \sum_{i=1}^n y_i^2 - n\bar{y}^2$$

$$s_X := \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2} \quad \text{סטיית תקן אמפירית:}$$

$$s_Y := \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2}$$

גרסיה פשוטה (משתנה מסביר אחד): $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$

התחזית לתצפית: $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$

השארית: $e_i = y_i - \hat{y}_i$

סכום ריבועי השאריות: $SSE = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$

פיתוח האר"פ $\hat{\beta}_0, \hat{\beta}_1$: Best Linear Unbiased Estimators=BLUE (בעלי שונות מינימלית, דואגים למזעור סכום ריבועי השאריות):

$$\frac{\partial SSE}{\partial \hat{\beta}_0} = \sum_{i=1}^n -2(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \rightarrow \sum_{i=1}^n e_i = 0$$

$$\sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = n\bar{y} - n\hat{\beta}_0 - \hat{\beta}_1 n\bar{x} = 0 \rightarrow \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\frac{\partial SSE}{\partial \hat{\beta}_1} = \sum_{i=1}^n 2(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) * (-x_i) = 0 \rightarrow \sum_{i=1}^n e_i x_i = 0 \rightarrow \hat{\beta}_1 = \frac{SXY}{SXX}$$

$$Y_i \sim N(\beta_0 + \beta_1 X_i, \sigma^2)$$

התפלגויות במודל עם חותר:

אחר לשונות:

$$\hat{\beta}_1 \sim N(\beta_1, \frac{\sigma^2}{SXX})$$

$$\hat{\sigma}^2 = MSE = \frac{SSE}{n-2} = \frac{\sum_{i=1}^n e_i^2}{n-2} = \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n-2}$$

$$\hat{\beta}_0 \sim N(\beta_0, \sigma^2 (\frac{1}{n} + \frac{\bar{x}^2}{SXX}))$$

$$\hat{Y}_i \sim N(\beta_0 + \beta_1 X_i, \sigma^2 (\frac{1}{n} + \frac{(X_i - \bar{x})^2}{SXX}))$$

משתנה ציר ורווח סמך ל

יש מ"מ נורמלי סטנדרטי: $z = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\sigma^2/SXX}} \sim N(0,1)$ אבל השונות לא ידועה, לכן צריך לעבור

לסטטיסטי t . לפי קוחרן: $g = \frac{SSE}{\sigma^2} = \frac{MSE(n-2)}{\sigma^2} \sim \chi_{n-2}^2$ וניצור סטטיסטי t בעזרת בנייה:

$$t = \frac{z}{\sqrt{\frac{g}{n-2}}} = \frac{\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\sigma^2/SXX}}}{\sqrt{\frac{MSE}{\sigma^2}}} = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{MSE/SXX}} = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{v(\hat{\beta}_1)}} \sim t_{n-2}$$

רווח סמך:

$$P(\mu \in \hat{\mu} \pm t_{n-1, 1-\alpha/2} \cdot \sqrt{\hat{V}(\hat{\mu})}) = P(|t| \leq t_{n-1, 1-\alpha/2}) = 1 - \alpha$$

$$\frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} \sim t_{n-1} \quad \text{באופן כללי:} \quad \hat{\beta}_1 \pm t_{n-2, 1-\alpha/2} \sqrt{\hat{V}(\hat{\beta}_1)}$$

בדיקת השערות על אומד השיפוע

השערה חד	השערה חד	השערה חד	
צדדית ימנית	צדדית שמאלית	צדדית	השערה דו
$H_1: \beta_1 > \beta_{1,0}$	$H_1: \beta_1 < \beta_{1,0}$	$H_1: \beta_1 \neq \beta_{1,0}$	צדדית
סטטיסטי המבחן	$t = \frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{\hat{V}(\hat{\beta}_1)}}$	כנ"ל	כנ"ל
אזור דחייה	$t \geq t_{n-2, 1-\alpha}$	$t \leq -t_{n-2, 1-\alpha}$	$ t \geq t_{n-2, 1-\alpha/2}$
P-VALUE	$P(t_{n-2} > t)$	$P(t_{n-2} \leq t)$	$2 * P(t_{n-2} > t)$

משתנה ציר ורווח סמך ל

$$\hat{\beta}_0 \pm t_{n-2, 1-\alpha/2} \sqrt{\hat{V}(\hat{\beta}_0)} \quad \text{רווח סמך:} \quad t = \frac{z}{\sqrt{\frac{g}{n-2}}} = \frac{\hat{\beta}_0 - \beta_0}{\sqrt{MSE(\frac{1}{n} + \frac{\bar{x}^2}{SXX})}} \sim t_{n-2}$$

בדיקת השערות על אומד החותר

השערה חד	השערה חד	השערה חד	
צדדית ימנית	צדדית שמאלית	צדדית	השערה דו
$H_1: \beta_0 > \beta_{0,0}$	$H_1: \beta_0 < \beta_{0,0}$	$H_1: \beta_0 \neq \beta_{0,0}$	צדדית
סטטיסטי המבחן	$t = \frac{\hat{\beta}_0 - \beta_{0,0}}{\sqrt{\hat{V}(\hat{\beta}_0)}}$	כנ"ל	כנ"ל
אזור דחייה	$t \geq t_{n-2, 1-\alpha}$	$t \leq -t_{n-2, 1-\alpha}$	$ t \geq t_{n-2, 1-\alpha/2}$
P-VALUE	$P(t_{n-2} > t)$	$P(t_{n-2} \leq t)$	$2 * P(t_{n-2} > t)$

רווח סמך והסקה על התוחלת (המותנה) של תצפית עתידית

רווח סמך לתוחלת סביב הממוצע מתבסס על טעות/שגיאת תקן של האומד (SE)

$$E(\hat{y}_i) = E(\hat{\beta}_0 + \hat{\beta}_1 x_i) = E(\hat{\beta}_0) + x_i E(\hat{\beta}_1) = \beta_0 + \beta_1 x_i = \mu_i \leftarrow \text{קבוע, } \hat{\beta}_0, \hat{\beta}_1, x_i$$

$$V(\hat{y}_i) = V(\hat{\beta}_0 + \hat{\beta}_1 x_i) = V(\hat{\beta}_0) + V(\hat{\beta}_1 x_i) + 2cov(\hat{\beta}_0, \hat{\beta}_1 x_i) = \sigma^2 \left(\frac{1}{n} + \frac{x_i^2}{SXX} \right) +$$

$$x_i^2 \left(\frac{\sigma^2}{SXX} \right) + 2x_i \left(\frac{-\sigma^2 \bar{x}}{SXX} \right) = \sigma^2 \left(\frac{1}{n} + \frac{x_i^2 - 2x_i \bar{x}}{SXX} \right) = \sigma^2 \left(\frac{1}{n} + \frac{(x_i - \bar{x})^2}{SXX} \right) \rightarrow$$

$$\hat{V}(\hat{y}_0) = MSE \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{SXX} \right) \quad \frac{\hat{y}_0 - \mu_0}{\sqrt{\hat{V}(\hat{y}_0)}} \sim t_{n-2}$$

רווח סמך לתוחלת המותנה: $\mu_0 \in \hat{y}_0 \pm t_{n-2, 1-\alpha/2} \sqrt{\hat{V}(\hat{y}_0)}$

רווח סמך והסקה על תצפית עתידית בודדת

$$e_0 = y_0 - \hat{y}_0$$

$$E(e_0) = E(y_0) - E(\hat{y}_0) = \mu_0 - \mu_0 = 0$$

$$V(e_0) = V(y_0) + V(\hat{y}_0) - 2cov(y_0, \hat{y}_0) = \sigma^2 + V(\hat{y}_0) - 0 = \sigma^2 + \sigma^2 \left(\frac{1}{n} + \frac{x_0^2}{SXX} \right) -$$

$$\frac{(x_0 - \bar{x})^2}{SXX} = \sigma^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{SXX} \right) \rightarrow \hat{V}(e_0) = MSE \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{SXX} \right)$$

$$z = \frac{e_0 - 0}{\sqrt{V(e_0)}} \sim N(0,1), \quad g = \frac{SSE}{\sigma^2} \sim \chi_{n-2}^2, \quad t = \frac{z}{\sqrt{\frac{g}{n-2}}} \sim t_{n-2}, \quad \frac{g}{n-2} = \frac{MSE}{\sigma^2} = \frac{\hat{\sigma}^2}{\sigma^2}$$

$$t = \frac{z}{\sqrt{g/(n-2)}} = \frac{e_0/\sqrt{V(e_0)}}{\sqrt{\hat{\sigma}^2/\sigma^2}} = \frac{e_0}{\sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{SXX} \right)}} = \frac{e_0}{\sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{SXX} \right)}} \sim t_{n-2}$$

רווח סמך לתצפית עתידית: $y_0 \in \hat{y}_0 \pm t_{n-2, 1-\alpha/2} \sqrt{\hat{V}(e_0)}$

פירוק סכום ריבועים

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 + \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

$$SST = SSE + SSR$$

הרעיון: כל סטייה של Y_i מ- $\bar{Y}$ ניתן לפרק לשני חלקים – הסטייה של Y_i מהקו $\hat{Y}_i$, והסטייה של $\hat{Y}_i$ מהממוצע $\bar{Y}$. כך אנחנו מקבלים שבתוך הפיזור יש מרכיב מוסבר (SSR) ומרכיב לא מוסבר (SSE). נעדיף SSR גדול וSSE קטן, כי כך מודל הרגרסיה מסביר יותר טוב.

מדד טיב התאמה R2 – אחוז השונות המוסבר/אחוז הפיזור המוסבר (לכאורה):

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \quad SSE = SST - SSR = SST - \hat{\beta}_1^2 * SXX$$

מקדם מתאם מדגמי של פירסון r:

$$\sigma_y^2 = E(y - E(y))^2 \rightarrow \hat{\sigma}_y^2 = \frac{1}{n-1} \sum (y_i - \bar{y})^2 = \frac{SYX}{n-1} = Syy, \quad \hat{\sigma}_x^2 = \frac{SXX}{n-1} = Sxx$$

$$\sigma_{xy}^2 = cov(x, y) = E((x - E(x))(y - E(y))) \rightarrow \hat{\sigma}_{xy}^2 = \frac{1}{n-1} \sum (x_i - \bar{x})(y_i - \bar{y}) =$$

$$\frac{SXY}{n-1} = Sxy$$

$$\rho = \frac{cov(x, y)}{\sqrt{\sigma_x^2 \sigma_y^2}} = \frac{\sigma_{xy}^2}{\sigma_x \sigma_y} \rightarrow \hat{\rho} = r = \frac{\frac{SXY}{n-1}}{\sqrt{\frac{SXX}{n-1} \frac{SYY}{n-1}}} = \frac{SXY}{\sqrt{SXX * SYY}} \quad -1 \leq r \leq 1$$

הקשר בין מקדם המתאם המדגמי r למדד טיב ההתאמה R2

$$r^2 = \frac{SXY^2}{SXX * SYY} = \frac{\frac{SXY^2}{SXX^2} * SXX}{\frac{SXX^2}{SXX^2} * \frac{SYY}{SXX}} = \frac{\hat{\beta}_1^2 SXX}{\frac{SXX}{SYY}} = \frac{SSR}{SYY} = \frac{SSR}{SST} = R^2 \quad R_{xy} = |r_{xy}|$$

$$r = \frac{SXY}{\sqrt{SXX * SYY}} * \frac{SXX}{SXX} = \frac{SXY}{SXX} * \sqrt{\frac{SXX}{SYY}} = \hat{\beta}_1 \sqrt{\frac{SXX}{SYY}} = \hat{\beta}_1 \frac{s_x}{s_y} \quad \text{הקשר בין מקדם המתאם r המדגמי לאומד ל-}\hat{\beta}_1$$

מבחן F = הסקה סטטיסטית לפי סכום ריבועים

ניתן לבדוק רק האם קיים קשר בין X ל- Y אך לא אם הקשר חיובי/שלילי

K=מספר המסבירים, בפשוטה K=1

טבלת ניתוח שונות (טבלת ANOVA)

מקור	סכום ריבועים SS	דרגות חופש df	ממוצע סכום ריבועים MS=SS/df	F	F _{crit}
מודל הרגרסיה	SSR	k	$MSR = \frac{SSR}{k}$	$F_{\alpha} = \frac{MSR}{MSE}$	$F_{1-\alpha, k, n-k-1}$
שאריות	SSE	n-k-1	$MSE = \frac{SSE}{n-k-1}$		
סה"כ	SST	n-1			

להתפלגות F יש שני פרמטרים – שתי דרגות חופש, אחד של המונה ואחד של המכנה.

$$F = \frac{MSR}{MSE} = \frac{SSR/1}{SSE/(n-2)} \sim F_{1, n-2} \quad (n \text{ תחת } H_0) \rightarrow \frac{SST}{\sigma^2} \sim \chi_{n-1}^2, \quad \frac{SSR}{\sigma^2} \sim \chi_1^2, \quad \frac{SSE}{\sigma^2} \sim \chi_{n-2}^2$$

הקשר בין Fst ל-R בריבוע

$$R^2 = \frac{SSR}{SST} = \frac{SSR}{SSR + SSE} = \frac{1}{1 + \frac{SSE}{SSR}} = \frac{1}{1 + \frac{(n-2)MSE}{kMSR}} = \frac{1}{1 + \frac{(n-2)}{kF_{\alpha}}}$$

הקשר בין מבחן F למבחן t

$$Z \sim N(1,0) \quad X \sim \chi_n^2 \quad T = \frac{Z}{\sqrt{X/n}} \sim t_n \quad T^2 = \left(\frac{Z}{\sqrt{X/n}} \right)^2 = \frac{Z^2}{X/n} = \frac{Z^2/1}{X/n} \sim F_{1,n}$$

$$t_{st}^2 = \left(\frac{\hat{\beta}_1}{\sqrt{\frac{MSE}{SXX}}} \right)^2 = \frac{\hat{\beta}_1^2}{\frac{MSE}{SXX}} = \frac{\left(\frac{SXY}{SXX} \right)^2}{\frac{MSE}{SXX}} = \frac{SXY^2}{MSE * SXX} \quad F_{st} = t_{st}^2$$

$$F_{st} = \frac{MSR}{MSE} = \frac{SSR}{MSE} = \frac{R^2 * SYY}{MSE} = \frac{r_{xy}^2 * SYY}{MSE} = \frac{\left(\frac{SXY}{\sqrt{SXX * SYY}} \right)^2 * SYY}{MSE} = \frac{SXY^2}{MSE * SXX}$$

גרסיה מרובה

מודל הרגרסיה המרובה: $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \varepsilon_i \quad \forall i$
 $Y = X\beta + \varepsilon$

$$\begin{matrix} \text{חותר} + \\ \text{מסבירים } k \\ \text{מסבירים} \end{matrix} \quad \begin{matrix} Y \\ X \\ \varepsilon \end{matrix} = \begin{matrix} \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix} \\ \begin{bmatrix} X_{11} & X_{12} & \dots & X_{1k} \\ X_{21} & X_{22} & \dots & X_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \dots & X_{nk} \end{bmatrix} \\ \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix} \\ \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix} \end{matrix}$$

וקטור התחזיות הוא: $\hat{y} = X\hat{\beta}$ וקטור השאריות הוא: $e = y - \hat{y} = y - X\hat{\beta}$

$$\hat{Y} = X\hat{\beta} = X(X^T X)^{-1} X^T Y = HY \quad \text{תחזיות}$$

$$\hat{\beta} = (X^T X)^{-1} X^T y \quad \text{אומדים}$$

$$E(Y) = X\beta \quad \text{cov}(Y) = \sigma^2 I_n \quad \text{SSE} = y^T y - \hat{\beta}^T X^T y$$

$$SSR = \sum (\hat{y}_i - \bar{y})^2 = \hat{\beta}^T X^T Y - n\bar{y}^2$$

כמו ברגרסיה פשוטה, גם ברגרסיה מרובה מתקיימות ההנחות על השגיאות:

$$E(\varepsilon_i) = 0 \quad V(\varepsilon_i) = \sigma^2 \quad \text{cov}(\varepsilon_i, \varepsilon_j) = 0 \quad \forall i \neq j$$

$$\text{cov}(\varepsilon) = \begin{bmatrix} V(\varepsilon_1) & \text{cov}(\varepsilon_1, \varepsilon_2) & \dots & \text{cov}(\varepsilon_1, \varepsilon_n) \\ \text{cov}(\varepsilon_2, \varepsilon_1) & V(\varepsilon_2) & \dots & \text{cov}(\varepsilon_2, \varepsilon_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{cov}(\varepsilon_n, \varepsilon_1) & \text{cov}(\varepsilon_n, \varepsilon_2) & \dots & V(\varepsilon_n) \end{bmatrix}$$

$$\hat{Y} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{bmatrix} = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix} \begin{bmatrix} \hat{\beta}_0 + \hat{\beta}_1 x_1 \\ \hat{\beta}_0 + \hat{\beta}_1 x_2 \\ \vdots \\ \hat{\beta}_0 + \hat{\beta}_1 x_n \end{bmatrix} = \begin{bmatrix} \hat{\beta}_0 + \hat{\beta}_1 x_1 \\ \hat{\beta}_0 + \hat{\beta}_1 x_2 \\ \vdots \\ \hat{\beta}_0 + \hat{\beta}_1 x_n \end{bmatrix}$$

$$E(\varepsilon) = \begin{bmatrix} E(\varepsilon_1) \\ E(\varepsilon_2) \\ \vdots \\ E(\varepsilon_n) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \mathbf{0} \quad \text{cov}(\varepsilon) = \begin{bmatrix} \sigma^2 & 0 & \dots & 0 \\ 0 & \sigma^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma^2 \end{bmatrix} = \sigma^2 I_n = \Sigma$$

המשוואות הנורמליות:

$$X^T Y - X^T X \hat{\beta} = X^T (Y - X\hat{\beta}) = X^T e = 0$$

המשמעות: וקטור השאריות ניצב לתת המרחב שגפרש על ידי המשתנים המסבירים.

נובע מכך שוקטור השאריות ניצב גם לוקטור התחזיות:

$$\sum \hat{y}_i e_i = \hat{Y}^T e = (X\hat{\beta})^T e = \hat{\beta}^T X^T e = 0$$

תוחלת ושונות של וקטור האומדים:

$\hat{\beta}$ הוא אח"ה:

$$E(\hat{\beta}) = E((X^T X)^{-1} X^T y) = ((X^T X)^{-1} X^T) E(y) = ((X^T X)^{-1} X^T X \beta) = I \beta = \beta$$

$$\text{cov}(\hat{\beta}) = \text{cov}((X^T X)^{-1} X^T Y) = (X^T X)^{-1} X^T \text{cov}(Y) (X^T X)^{-1} X^T X = (X^T X)^{-1} X^T I \sigma^2 X (X^T X)^{-1} = \sigma^2 (X^T X)^{-1}$$

$$\hat{\beta} \sim N(\beta, \sigma^2 (X^T X)^{-1})$$

קריטי	סטטיסטי	השערות	מבחן רגיל (מלא)
$F(k, n-k-1, 1-\alpha)$	$MSR = \frac{SSR/k}{MSE = SSE/(n-k-1)}$	$H_0: \beta_1 = \beta_2 = \dots = 0$ H_1 : אחרת	F
$F(\#, n-k-1(H_1), 1-\alpha)$	$\frac{(SSR_{(המלא)}) - SSR_{(המסומם)}}{MSE_{(המלא)}} / \#$ # מספר המשתנים שהודגו באותו שלב. (אם אין SSR אז לקחת SSE, ולהוסיף מינוס)	H_0 : המודל המצומצם: H_1 : המודל המלא: לרשום בהשערות את המודל: $y = \dots + \varepsilon$	F חלקי
$t_{(n-k-1, 1-\alpha)}$	$\frac{\hat{\beta}_i - (\beta_i)_{H_0}}{\sqrt{V(\hat{\beta}_i)}}$	$H_0: \beta_i = A$ $H_1: \beta_i \neq A$ ($<, >$)	t מבחן רגיל
במבחן זה צדדי: $1 - \frac{\alpha}{2}$	$\frac{C^T \hat{\beta} - (A)_{H_0}}{\sqrt{MSE \cdot [C^T (X^T X)^{-1} C]}}$ $C^T = [1 \ 4 \ 0 \ 1]$ (בנוסף מציין)	$H_0: \beta_0 + 4\beta_1 + \beta_3 = A$ $H_1: \beta_0 + 4\beta_1 + \beta_3 \neq A$ ($<, >$ או $\neq$)	t מבחן (קומבינציה של מס' β)

שימוש במדדים של טיב התאמה לבחירת מודלים:

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \quad 1.$$

P-מספר מקדמים במודל

n- מספר תצפיות

מדדים BIC, AIC בוחנים טיב התאמה של המודל

לנתונים מבחינת נראות. (ככל שהנראות יותר גדולה

כך ערך המדדים קטן יותר). AIC, BIC קונסים לפי מספר

פרמטרים BIC או לפי מספר תצפיות.

$$R^2_{adj} = 1 - \frac{SSE/(n-p)}{SST/(n-1)} \quad 2.$$

נרצה כאשר יש מספר שונה של משתנים מסבירים

$$AIC = n \log \left(\frac{SSE}{n} \right) + 2p \quad 3.$$

$$BIC = n \log \left(\frac{SSE}{n} \right) + p \log(n) \quad 4.$$

מבחן F חלקי

השוואה בין מודל מלא ומודל חלקי. מודל מלא FM בעל $k+1$ מקדמים, והחלקי RM בעל k . מספר המשתנים אותם נבחן להוצאה מהמודל.

$$F_{st} = \frac{SSR(FM) - SSR(RM)}{l \cdot MSE(FM)} = \frac{[SSR(FM) - SSR(RM)]/l}{SSE(FM)/(n-k-1)} \sim F_{l, n-k-1}$$

משום שידוע כי סכום הריבועים הכולל SST תמיד קבוע, ניתן לבצע מבחן F חלקי גם ע"י שימוש

SSE המתאימים:

$$F_{st} = \frac{SSE(RM) - SSE(FM)}{l \cdot MSE(FM)} \sim F_{l, n-k-1}$$

קריטריון $C_p - C_p$ Mallow's

סטטיסטי אחר המשמש ככלי לבחירת משתנים מסבירים ברגרסיה הינו

$$C_p = \frac{SSE_{RM}}{MSE_{FM}} - (n-2p)$$

טרנספורמציה:

קשר בין σ^2 ו- $E(Y)$	טרנספורמציה
קבוע	$f(y) = y$
$E(y)$	$f(y) = \sqrt{y}$
$E(y)[1 - E(y)]$	$f(y) = \arcsin(\sqrt{y})$
$[E(y)]^2$	$f(y) = \ln(y)$
$[E(y)]^3$	$f(y) = y^{-1/2}$

BOX-COX: כאשר לא יודעים מה הקשר בין התוחלת לשונות משתמים בטרנספורמציות

$$y(\lambda) = \begin{cases} (y^\lambda - 1)/\lambda, & \lambda \neq 0 \\ \ln(y), & \lambda = 0 \end{cases} \quad \text{box-cox}$$

$$\lim_{\lambda \rightarrow \infty} \frac{y^\lambda - 1}{\lambda} = \text{לפיטל} = \frac{\ln(y) \cdot y^\lambda}{1} = \ln(y)$$

מודל הרגרסיה לאחר טרנספורמציה יהיה $y_i(\lambda) = \beta_0 + \sum_{j=1}^k \beta_j x_{ij} + \varepsilon_i$

מקדם ניפוח השונות VIF:

$$S_{jj} = \sum (x_{ij} - \bar{x}_{ij})^2, v(\hat{\beta}_j) = \frac{\sigma^2}{S_{jj}} \cdot \frac{1}{1-R_j^2}$$

כאשר $\frac{1}{1-R_j^2}$ הינו מקדם ניפוח השונות. VIF.

הערך הקטן ביותר שיכול לקבל הוא 1 כאשר $R_j^2 = 0$

ככל שהמשתנה יותר מתואם - כך השונות תגדל לפי vif.

S_{jj} זה סכום הסטיות הריבועיות של המשתנה המסביר ה- j

R_j^2 זה מקדם המתאם המרובה בריבוע בין המשתנה המסביר ה- j לשאר ובין שאר

המסבירים. מדד ה VIF לכן מוגדר להיות: $VIF(\hat{\beta}_j) = \frac{1}{1-R_j^2}$

מבחן F:

משמעות H_0 - אין קשר בין המשתנה המוסבר לאף אחד מהמשתנים המסבירים.

$$H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$$

משמעות H_1 - קיים קשר ליניארי בין המשתנה המוסבר לבין לפחות אחד מהמשתנים המסבירים.
 $H_1: \text{Not } H_0$

הסקה על מקדמי הרגרסיה:

השערה חד צדדית	השערה חד צדדית שמאלית	השערה חד צדדית ימנית	סטטיסטי המבחן
$H_1: \beta_j \neq \beta_{j,0}$	$H_1: \beta_j < \beta_{j,0}$	$H_1: \beta_j > \beta_{j,0}$	$t^* = \frac{\hat{\beta}_j - \beta_{j,0}}{\sqrt{\hat{V}(\hat{\beta}_j)}}$
כנ"ל	כנ"ל	כנ"ל	
$ t^* \geq t_{n-p, 1-\alpha/2}$	$t^* \leq -t_{n-p, 1-\alpha}$	$t^* \geq t_{n-p, 1-\alpha}$	אזור דחייה
$2 * P(t_{n-p} > t^*)$	$P(t_{n-p} \leq t^*)$	$P(t_{n-p} > t^*)$	P-VALUE

הסקה על תוחלת תצפית עתידית $E(Y_0)$ (במודל עם חותר):

הסקה על הרמה הממוצעת של הפרטים המקיימים $\underline{X}_0 = \underline{x}_0$.

$$\underline{C}^t = [1, \underline{x}_0^t]$$

$$E(Y_0) = \beta_0 + \beta_1 x_{01} + \beta_2 x_{02} + \dots + \beta_k x_{0k} = \underline{C}^t \underline{\beta}$$

מבחן השערות על תוחלת תצפית עתידית $E(Y_0)$:

$$H_0: \underline{C}^t \underline{\beta} = \alpha \quad H_1: \text{else}$$

$$t_{st} = \frac{\underline{C}^t \hat{\underline{\beta}} - \alpha}{\sqrt{\hat{V}(\underline{C}^t \hat{\underline{\beta}})}} \sim t_{n-k-1}$$

רווח סמך בר"ב $(1-\alpha)$ לתוחלת תצפית עתידית $E(Y_0)$:

$$E(Y_0) \in \underline{C}^t \hat{\underline{\beta}} \pm t_{n-k-1, 1-\frac{\alpha}{2}} \sqrt{\hat{V}(\underline{C}^t \hat{\underline{\beta}})}$$

$$\hat{V}(\underline{C}^t \hat{\underline{\beta}}) = \underline{C}^t \hat{C} \hat{O} \hat{V}(\hat{\underline{\beta}}) \hat{C} = \hat{\sigma}^2 \underline{C}^t (X^t X)^{-1} \hat{C} = \text{MSE} \cdot \underline{C}^t (X^t X)^{-1} \hat{C}$$

הסקה על תצפית עתידית Y_0 (במודל עם חותר):

נרצה לחזות את התגובה עבור פרט ספציפי אשר ערך המשתנה המסביר שלו הוא $\underline{x}_0$.

$$\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_{01} + \hat{\beta}_2 x_{02} + \dots + \hat{\beta}_k x_{0k} = \underline{C}^t \hat{\underline{\beta}} \quad Y_0: \text{החיזוי עבור } Y_0$$

$$\underline{e}_0 = Y_0 - \hat{Y}_0 \quad \text{שארית החיזוי}$$

$$E(\underline{e}_0) = E(Y_0) - E(\hat{Y}_0) = \underline{C}^t \underline{\beta} - \underline{C}^t \underline{\beta} = 0 \quad \text{תוחלת שארית החיזוי}$$

$$V(\underline{e}_0) = V(Y_0 - \hat{Y}_0) = V(Y_0) + V(\hat{Y}_0) = V(Y_0) + V(\underline{C}^t \hat{\underline{\beta}}) = \sigma^2 (1 + \underline{C}^t (X^t X)^{-1} \hat{C})$$

$$\frac{\underline{e}_0 - 0}{\sqrt{V(\underline{e}_0)}} = \frac{(Y_0 - \hat{Y}_0) - 0}{\sqrt{\sigma^2 (1 + \underline{C}^t (X^t X)^{-1} \hat{C})}} \sim t_{n-k-1} \quad \text{בניית משתנה ציר}$$

בניית רווח חיזוי בר"ב $(1-\alpha)$ לתצפית עתידית:

$$Y_0 \in \hat{Y}_0 \pm t_{n-k-1, 1-\frac{\alpha}{2}} \sqrt{\hat{V}(\underline{e}_0)} = \underline{C}^t \hat{\underline{\beta}} \pm t_{n-k-1, 1-\frac{\alpha}{2}} \sqrt{\text{MSE}(1 + \underline{C}^t (X^t X)^{-1} \hat{C})}$$

חישוב מטריצות לרגרסיה מרובה:

$$x^t y = \begin{pmatrix} \sum y_i = n\bar{y} \\ \sum x_{1i} y_i \\ \vdots \\ \sum x_{ki} y_i \end{pmatrix} \quad x^t x = \begin{pmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{pmatrix} \quad y^t y = \sum y_i^2$$

חישוב מטריצות לרגרסיה במשתנה אחד

$$X^t X = \begin{pmatrix} n & n\bar{x} \\ n\bar{x} & \sum x_i^2 \end{pmatrix} \quad (X^t X)^{-1} = \begin{pmatrix} \frac{\sum x_i^2}{nSXX} & -\frac{\bar{x}}{SXX} \\ -\frac{\bar{x}}{SXX} & \frac{1}{SXX} \end{pmatrix} = \begin{pmatrix} \frac{1}{n} + \frac{\bar{x}^2}{SXX} & -\frac{\bar{x}}{SXX} \\ -\frac{\bar{x}}{SXX} & \frac{1}{SXX} \end{pmatrix}$$

$$\text{COV}(\hat{\underline{\beta}}) = \Sigma(\hat{\underline{\beta}}) = \begin{pmatrix} V(\hat{\beta}_0) & \text{COV}(\hat{\beta}_0, \hat{\beta}_1) & \dots & \text{COV}(\hat{\beta}_0, \hat{\beta}_k) \\ \text{COV}(\hat{\beta}_1, \hat{\beta}_0) & V(\hat{\beta}_1) & \dots & \vdots \\ \vdots & \vdots & \ddots & \text{COV}(\hat{\beta}_{k-1}, \hat{\beta}_k) \\ \text{COV}(\hat{\beta}_k, \hat{\beta}_0) & \dots & \dots & V(\hat{\beta}_k) \end{pmatrix}$$

תוחלת ושונות של התחזיות $\hat{Y} = X\hat{\beta}$:

$$E(\hat{Y}) = E(X\hat{\beta}) = X E(\hat{\beta}) = X \underline{\beta} = \underline{\mu}$$

$$\text{COV}(\hat{Y}) = \text{COV}(X\hat{\beta}) = \text{COV}(HY) = H \sigma^2 I H = \sigma^2 H$$

תוחלת ושונות של השאריות:

$$\underline{e} = Y - \hat{Y} = Y - X\hat{\beta} = Y - HY = (I - H)Y$$

$$E(\underline{e}) = E(Y - \hat{Y}) = E(Y) - E(\hat{Y}) = \underline{\mu} - \underline{\mu} = \underline{0}$$

$$\text{COV}(\underline{e}) = \text{COV}[(I - H)Y] = (I - H)I\sigma^2(I - H) = (I - H)\sigma^2$$

תכונות מטריצת ההטלה:

$$\underline{H} = \underline{x} * (\underline{x}^t \underline{x})^{-1} * \underline{x}^t$$

$$\underline{H}^t = (\underline{x}(\underline{x}^t \underline{x})^{-1} \underline{x}^t)^t = \underline{x}(\underline{x}^t \underline{x})^{-1} \underline{x}^t = \underline{H} \quad \text{סימטריה}$$

$$\underline{H}^2 = \underline{H} * \underline{H} = (\underline{x} * (\underline{x}^t \underline{x})^{-1} * \underline{x}^t) (\underline{x} * (\underline{x}^t \underline{x})^{-1} * \underline{x}^t) = \underline{x} * (\underline{x}^t \underline{x})^{-1} * \underline{x}^t = \underline{H}$$

$$(I - H)^2 = (I - H) * (I - H) = I - H - H + H^2 = I - 2H + H = (I - H)$$

סכומי הריבועים:

$$\text{SST} = \sum (y_i - \bar{y})^2 = Y^t Y - n\bar{y}^2 \quad \text{SSE} = Y^t Y - \hat{\underline{\beta}}^t X^t Y$$

$$\text{SSE} = \sum (y_i - \hat{y}_i)^2 = \sum e_i^2 = \underline{e}^t \underline{e} = [(I - H)Y]^t [(I - H)Y] = Y^t Y - Y^t \hat{Y} = Y^t (I - H)Y = Y^t Y - \hat{\underline{\beta}}^t X^t Y$$

$$\text{SSR} = \sum (\hat{y}_i - \bar{y})^2 = \hat{\underline{\beta}}^t X^t Y - n\bar{y}^2$$

$$\text{MSE} = \frac{\text{SSE}}{n - k - 1} \quad \hat{\sigma}^2 = \text{MSE} = \frac{\text{SSE}}{n - k - 1} \quad E(\hat{\sigma}^2) = E(\text{MSE}) = \sigma^2$$

הסקה על מקדם הרגרסיה β_i :

$$t_{st} = \frac{\hat{\beta}_i - \beta_{i,0}}{\sqrt{\hat{V}(\hat{\beta}_i)}} = \frac{\hat{\beta}_i - \beta_{i,0}}{\sqrt{\hat{C} \hat{O} \hat{V}(\hat{\underline{\beta}})_{i+1, i+1}}} = \frac{\hat{\beta}_i - \beta_{i,0}}{\sqrt{\text{MSE}(X^t X)^{-1}_{i+1, i+1}}} \sim t_{n-k-1}$$

רווח סמך בר"ב $(1-\alpha)$ ל- β_i :

$$\beta_i \pm t_{n-k-1, 1-\frac{\alpha}{2}} \sqrt{\hat{V}(\hat{\beta}_i)} = \beta_i \pm t_{n-k-1, 1-\frac{\alpha}{2}} \sqrt{\text{MSE}(X^t X)^{-1}_{i+1, i+1}}$$

מספר תנאי Condition Number:

נותן תמונה כללית כמה קרובים למולטיקולינאריות. מדד ליציבות לרגישות של חישוב מטריצה הופכית.

2 הגדרות:

1- עבור מטריצה סימטרית. אם A מטריצה סימטרית עם ערכים עצמיים

$$CN(A) = \frac{|\lambda_n|}{|\lambda_1|} = \frac{\max|\lambda_i|}{\min|\lambda_i|} \text{ אז } |\lambda_1| \leq \dots \leq |\lambda_n|$$

2- אם מטריצה B לא סימטרית אז $CN(B) = \sqrt{CN(B \cdot B^T)}$

ברגרסיה נחשב CN לפי הגדרה 2.

כאשר מספר התנאי גדול 30 נראה שיש מולטיקולינאריות.

תכונות נוספות של מטריצת ההטלה

חריגים

תצפיות חריגות, ישנם 2 מדדים כמותיים לזיהוי חריגים-מינוף והסטה.

$$H^t = H; H^2 = H \quad \text{תזכורת:}$$

$$h_{ii} = \sum_{j=1}^n h_{ij}h_{ji} = h_{ii}^2 + \sum_{j \neq i} h_{ij}^2 \geq 0$$

$$h_{ii} \geq h_{ii}^2 \Rightarrow h_{ii} \leq 1$$

בנוסף ניתן להראות (Weissberg, 2005) כי:

$$1/n \leq h_{ii} \leq 1/r$$

כאשר n הוא מספר התצפיות הכולל, ו- r הוא מספר התצפיות עם ערכי משתנים מסבירים זהים לתצפית i .

כמו כן, במודל עם חוקר, הוקטור $J = (1, 1, \dots, 1)^t$ מופיע במטריצה X ולכן $HJ = J \Rightarrow \sum_i h_{ii} = 1$

מינוף (Leverage)

מדד המינוף לוקח בחשבון משתנים מסבירים ולא משתנה מוסבר.

$$\hat{y}_i = \sum_{j=1}^n h_{ij}y_j = h_{ii}y_i + \sum_{j \neq i} h_{ij}y_j \quad \text{הנוסחה}$$

מציגה את $\hat{y}_i$ כמעין "שמוצע" של ערכי התצפיות y_j . כאשר h_{ii} הוא המשקל של התצפית עצמה y_i . במובן זה h_{ii} הוא מדד למינוף של תצפית i .

$$VAR(e) = \sigma^2(I - H) \Rightarrow VAR(e_i) = \sigma^2(1 - h_{ii})$$

משמעות נוספת של מדד המינוף – ככל שהערך קרוב לאחד, כך השונות של השארית קרובה לאפס, כלומר התחזית "מתנדנדת" ביחד עם התצפית. לעומת זאת כאשר המינוף קרוב לאפס, השונות של השארית קרובה לשונות של השגיאה σ^2 , שכן התחזית יציבה וקרובה לתוחלת.

הסטה

הסטה (Mean shift outlier model)

דרך אחת לזהות תצפית חריגה היא באמצעות הסטה משתנה דמה למודל שמפריד בין התצפית החשודה לשאר התצפיות. השערת האפס היא שהמקדם של משתנה דמה זה, δ , הוא אפס (תצפית לא חריגה). את החישוב ניתן לבצע על ידי מודל ללא תצפית i , בו הרכיבים מסומנים $X_{(i)}; \beta_{(i)}; \bar{Y}_{(i)}; \sigma_{(i)}^2$

$$\delta = y_i - \bar{y}_{(i)} \quad \text{האומד למקדם הוא:}$$

$$\bar{VAR}(\delta) = \sigma_{(i)}^2(1 + x_i^t (X_{(i)}^t X_{(i)})^{-1} x_i)$$

מסמנים את השארית המתוקנת ב $r_i = \frac{e_i}{\sigma_{(i)}\sqrt{1-h_{ii}}}$ ונקבלים סטטיסטי

$$t_i = \frac{y_i - \bar{y}_{(i)}}{\sqrt{VAR(\delta)}} = \frac{e_i}{\sigma_{(i)}\sqrt{1-h_{ii}}} = r_i \sqrt{\frac{n-p-1}{n-p-r_i^2}} \quad \text{מבחן } (n-p-1) \text{ ד.נ.}$$

השפעה (Influence – Cook's distance)

דרך אחרת לזהות תצפית חריגה היא על פי ההשפעה על התחזיות.

$$D_i = \frac{(\bar{Y}_{(i)} - \bar{Y})^t (\bar{Y}_{(i)} - \bar{Y})}{p\hat{\sigma}^2}$$

מדד זה נקרא Cook's Distance. ניתן לחשב מדד זה ללא חישוב מלא של מודל הרגרסיה ללא התצפית החסרה על פי הנוסחאות הבאות:

$$D_i = \frac{r_i^2}{p} \cdot \frac{h_{ii}}{1-h_{ii}} = \frac{e_i^2}{p\hat{\sigma}^2} \cdot \frac{h_{ii}}{(1-h_{ii})^2}$$

ערך סף אפשרי למדד זה הוא 1.

רגרסיה לוגיסטית

רגרסיה בה המשתנה המוסבר בינארי, כלומר המשתנה מקבל אחד משני ערכים אפשריים, נכנה אותם 0, 1, "כישלון", "יציאה".

$$E(y|X=x) = p(y=1|x) = \pi(x) \\ V(y|X=x) = \pi(x)(1-\pi(x))$$

רגרסיה לוגיסטית-אקספוננציאלית

נועדה למקרים בהם המשתנה המוסבר בינארי.

$$0 < \pi(x) = \frac{\exp(\beta_0 + \beta_1 x)}{1 + \exp(\beta_0 + \beta_1 x)} = \frac{1}{\exp(-\beta_0 - \beta_1 x) + 1} < 1$$

ניתן לראות שבמודל זה תמיד מקבלים π בין 0 ל-1.

עבור $\beta > 0$ אז $\lim_{x \rightarrow -\infty} \pi(x) = 0$ ו- $\lim_{x \rightarrow \infty} \pi(x) = 1$

עבור $\beta < 0$ אז $\lim_{x \rightarrow -\infty} \pi(x) = 1$ ו- $\lim_{x \rightarrow \infty} \pi(x) = 0$

עבור $\beta = 0$, אין "תלות" בין X ו- Y .

ההסתברות להצלחה כתלות במשתנים המסבירים:

$$E(Y) = \pi(x) = \frac{\exp(\alpha + \beta x)}{1 + \exp(\alpha + \beta x)}$$

יחס ההסתברויות בין הצלחה וכישלון: odds

$$\frac{\pi(x)}{1-\pi(x)} = \exp(\alpha + \beta x) = e^{\alpha} e^{\beta x} = e^{\alpha} (e^{\beta})^x = e^{\alpha + \beta x}$$

הפעלת log על odds מבין לביטוי לינארי ב- X :

$$\ln(OR(x)) = \ln\left(\frac{\pi(x)}{1-\pi(x)}\right) = \beta_0 + \beta_1 x$$

לבדיקת השערות במודל הרגרסיה הלוגיסטית ישנן שתי שיטות:

- שיטת LRT – שיטה היא הכללה של מבחן יחס הנראות וסטטיסטי המבחן הינו הפרש ה-DEVIANCE בין שני המודלים והוא בעל התפלגות χ^2 כאשר ד"ח הן הפרש מספר הפרמטרים בין שני המודלים.
- שיטת WALD – מבוססת על העובדה שאומדי נראות מקסימלית מתפלגים אסימפטוטית נורמלית. ולכן תבניות ריבועיות שלהם מתפלגות χ^2 . שוב ד"ח של הן הפרש מספר הפרמטרים בין שני המודלים.

השיטה המקובלת לאמידת הפרמטרים היא שיטת הנראות המקסימלית:

Deviance

כאשר: $Deviance = -2 \log(L(\hat{\beta}))$ סוג של מדד טיב התאמה, בודק את איכות המודל.

ההפרש מראה האם ההבדל מובהק או לא.

עבור n גדול: $\chi_{df}^2 \sim \chi_{df}^2$

$$LRT = \frac{L(fm)}{L(rm)}$$

$$X_{st}^2 = Deviance(RM) - Deviance(FM) = 2 \ln(Lf) - 2 \ln(Lr) \sim X_{df}^2$$

df מספר הפרמטרים הנוספים במודל המלא לעומת המודל החלקי.

השערות המבחן:

$$\begin{cases} H_0: \beta_1 = \dots = \beta_l \\ H_1: \text{Not Ho} \end{cases}$$

$$X_{st}^2 > X_{cr}^2 \quad \text{איזור דחייה}$$

גזירת ההסתברות

$$\begin{aligned} \frac{d\pi(x)}{dx} &= -\frac{1}{[\exp(-\beta_0 - \beta_1 x) + 1]^2} \cdot [\exp(-\beta_0 - \beta_1 x)] \cdot [-\beta_1] \\ &= \frac{\beta_1 \cdot \exp(-\beta_0 - \beta_1 x)}{[\exp(-\beta_0 - \beta_1 x) + 1]^2} \\ &= \frac{\beta_1 \pi(x)(1-\pi(x))}{1} \end{aligned}$$

#מנתי $\pi(x) = 0.5$

$$\begin{aligned} \pi(x) &= \frac{1}{\exp(-\beta_0 - \beta_1 x) + 1} = 0.5 \\ \exp(-\beta_0 - \beta_1 x) + 1 &= 2 \\ \exp(-\beta_0 - \beta_1 x) &= 1 \\ x &= \frac{-\beta_0}{\beta_1} \end{aligned}$$

בנקודה זו נקבל שהשיפוע הוא:

$$\frac{d\pi(x)}{dx} = \beta_1 \pi(x)(1-\pi(x)) = \frac{\beta_1}{4}$$

זהו גם השיפוע המקסימלי של הפונקציה (מתחילה באסימפטוטה, עולה לשיפוע מקסימלי ושואפת לאסימפטוטה השנייה). הפונקציה סימטרית ביחד לנקודה זו. שינוי של β_0 ישפיע על תזוזה על ציר x ושינוי של β_1 ישפיע על השיפוע.

אומדון הפרמטרים-נראות מקסימלית

$$L = \prod \pi(x_i)^{y_i} \cdot (1 - \pi(x_i))^{1-y_i}$$

$$\ln(L) = \sum y_i \ln(\pi(x_i)) + (1 - y_i) \ln(1 - \pi(x_i))$$

$$\frac{d\pi(x_i)}{d\beta_0} = -\frac{\exp(-\beta_0 - \beta_1 x)(-1)}{[1 + \exp(-\beta_0 - \beta_1 x)]^2} = \pi(x_i)(1 - \pi(x_i))$$

$$\frac{d\pi(x_i)}{d\beta_1} = -\frac{\exp(-\beta_0 - \beta_1 x)(-x_i)}{[1 + \exp(-\beta_0 - \beta_1 x)]^2} = x_i \pi(x_i)(1 - \pi(x_i))$$

גזירת פונקציית נראות מקסימלית:

- גזירה לפי β_0 : $\sum y_i = \sum \pi(x_i) = E(Y_i|x_i)$
- גזירה לפי β_1 : $\sum y_i x_i = \sum x_i \pi(x_i)$

נוסחאות למקרה הכללי:

$$\pi(x) = \frac{\exp(X \cdot \beta)}{1 + \exp(X \cdot \beta)}$$

$$\frac{\pi(x)}{1 - \pi(x)} = \exp(X \cdot \beta)$$

$$\log\left(\frac{\pi(x)}{1 - \pi(x)}\right) = (X \cdot \beta)$$

המשוואות הנורמליות

$$\begin{aligned} \frac{\partial l}{\partial \alpha} &= \sum_{i=1}^n \frac{y_i}{\pi(x_i)} \cdot \frac{\partial \pi(x_i)}{\partial \alpha} - \sum_{i=1}^n \frac{(1-y_i)}{(1-\pi(x_i))} \cdot \frac{\partial \pi(x_i)}{\partial \alpha} = 0 \\ \frac{\partial l}{\partial \beta} &= \sum_{i=1}^n \frac{y_i}{\pi(x_i)} \cdot \frac{\partial \pi(x_i)}{\partial \beta} - \sum_{i=1}^n \frac{(1-y_i)}{(1-\pi(x_i))} \cdot \frac{\partial \pi(x_i)}{\partial \beta} = 0 \end{aligned}$$